Introducció a la Investigació Operativa

Tema 5. Formulació i resolució dels models no lineals d'optimització

Catalina Bolancé Dept. Econometria, Estadística i Economia Espanyola

> Javier Heredia Dept. Estadística i Investigació Operativa

- Objectius del tema
- Introducció a la PNL
 - Definició d'un problema de PNL
- 3 Algorismes d'optimització no lineal
- 4 Formulació de problemes de programació no lineal
 - Problema de localització
 - Solució amb Solver
 - Solució amb SAS/OR
 - Optimització d'una cartera de valors
- 6 Anàlisi de sensibilitat
- 6 Algorisme del Gradient Reduït
 - Convexitat

Objectius específics del Tema 5

Formulació i resolució numèrica:						
5.1	Conèixer i entendre la formulació d'alguns exemples de problemes de					
	Programació No Lineal (PNL).					
5.2	Davant d'algun Problema de Presa de Decisions (PPD) associat a					
	un problema de (PNL), ser capaç de formular un model consistent					
	d'optimització (paràmetres, variables, funció objectiu i restric-					
	cions), de forma eficient, matemàticament correcta, clara i pa-					
	rametritzada.					
5.3	Conèixer i entendre les característiques més importants de les solu-					
	cions dels problemes de programació no lineal (PNL): ubicació de les					
	solucions òptimes sobre la regió factible; òptims locals-globals .					
5.4	Conèixer i entendre el concepte de problemes convexos i la seva					
	relació amb el càlcul d' òptims globals .					
5.5	Conèixer i entendre la relació entre preus ombra i multiplicadors de					
	Lagrange.					

Introducció a la PNL

- Un problema de PNL és un problema de programació matemàtica o optimització on la funció objectiu o alguna restricció és no lineal.
- La forma de formular i implementar els problemes de PNL és semblant a la dels problemes de PL.
- Els algorismes d'optimització que s'usen per a resoldre problemes de PNL són força diferents dels usats als problemes de PL.
- L'ús de "Solver" amaga aquesta diferència, però és important conèixer les dificultats intrínseques dels problemes de PNL.

Forma general d'un problema de PNL

max (o min)
$$f_0\left(x_1,x_2,\ldots,x_n\right) \qquad (1)$$
 Subjecte a:
$$f_1\left(x_1,x_2,\ldots,x_n\right) \leq b_1 \qquad (2)$$

$$\vdots \qquad \vdots \qquad \vdots$$

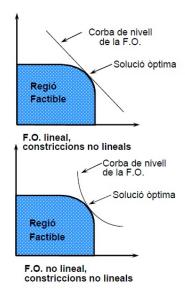
$$f_k\left(x_1,x_2,\ldots,x_n\right) \geq b_k \qquad (k)$$

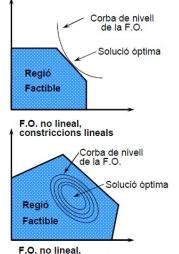
$$\vdots \qquad \vdots \qquad \vdots$$

$$f_m\left(x_1,x_2,\ldots,x_n\right) \leq b_m \qquad (m)$$

- $f_j(x_1, x_2, ..., x_n)$ és diferenciable $\forall j$.
- x_i és contínua $\forall i$.

Ubicació de les solucions òptimes sobre la regió factible dels problemes de PNL



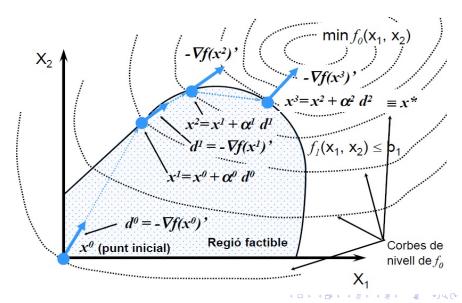


constriccions lineals

Algorisme **GRG**

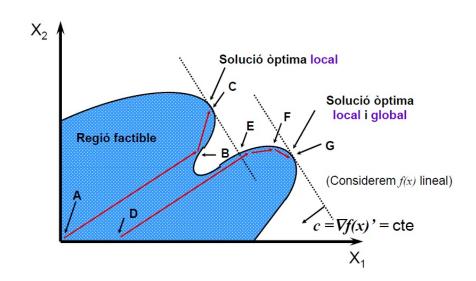
- Solver usa l'algorisme del Gradient Reduït Generalitzat (GRG) per a resoldre problemes de PNL.
- GRG també es pot usar per a resoldre problemes de PL, però és més lent que el mètode SIMPLEX.
- SAS/OR utilitza diferents algorismes per resoldre problemes de PNL.

Estratègia dels algorismes de PNL



8 / 49

Òptims locals i globals



Condicions de Karush-Kuhn-Tucker (KKT)

Condicions necessàries de 1er. ordre:

Sigui x^* mínim local de PNL, punt regular, llavors, es pot trobar el vector de multiplicadors de Lagrange, $\lambda \in \Re^m$ (m restriccions d'igualtat $h(\cdot)$) i $\mu \in \Re^l$ (l restriccions de desigualtat $g(\cdot)$) tals que:

- $\mu^{*T}g(x^*) = 0$
- **3** $\mu^* \geq 0$

Condició de regularitat

Condició de regularitat:

Es diu que el punt factible $x \in X$ és regular si els vectors gradient de les restriccions:

$$\nabla h_{i}(x)$$
, $i = 1, 2, ..., m$
 $\nabla g_{j}(x)$, $j \in J = \{j | g_{j}(x) = 0\}$

són linealment independents.

Comentaris sobre els algorismes de la PNL en Solver

- Els algorismes de PNL poden acabar en un *òptim local* i, fins i tot, molt excepcionalment, en un **punt estacionari**.
- L'òptim local proporcionat pels algorismes de PNL depèn del punt inicial x⁰.
- El punt inicial nul $x^0 = [0]$ pot donar problemes amb el programa *Solver*; cal evitar-lo!
- Quan sigui possible, és convenient usar punts inicials que tinguin aproximadament el mateix ordre de magnitud que el valor òptim esperat de les variables.

Comentaris sobre les solucions òptimes Solver

El criteri d'aturada de *Solver* per a problemes de PNL depèn de tres tests numèrics. *Solver* s'atura quan un d'aquests tres tests se satisfa, emetent un dels següents missatges:

- Solver found a solution. All constraints and optimality conditions are satisfied."
 - Solver ha trobat una solució òptima local. Si no es té la seguretat que aquesta sigui un òptim global (això passa, per exemple, si $f\left(x\right)$ és convexa i la regió factible també), es pot intentar millorar la solució reoptimitzant a partir de diferents punts inicials.
- "Solver has converged to the current solution. All constraints are satisfied."
 La funció objectiu ha canviat molt lentament en les últimes iteracions, però el punt final pot no satisfer les condicions d'optimalitat local. Això pot ser degut a un escalat deficient del problema. Per tal d'intentar evitar que Solver convergeixi a una solució subòptima es pot reduir el valor del paràmetre "Convergence" de la finestra "Options".
- Solver cannot improve the current solution. All constraints are satisfied." Aquest missatge indica que el model és degenerat i Solver està iterant ("cicling"). La degeneració es pot evitar, sovint, eliminant restriccions redundants.

Problemes de localització

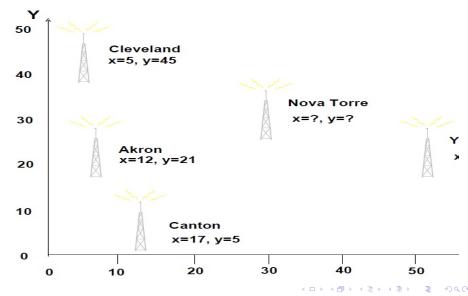
- Molts problemes de decisió impliquen l'obtenció de la localització òptima d'instal·lacions o centres de servei:
 - ► Plantes de producció
 - Magatzems
 - Estacions de bombers, ambulàncies, helicòpters,...
- Aquests problemes necessiten calcular distàncies entre dos punts (x_1, y_1) i (x_2, y_2) , ja sigui a la funció objectiu o a les restriccions:

Distància =
$$\sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}$$

Problema de localització: "Rappaport Communications"

- Rappaport Communications subministra servei de telefonia mòbil a diferents estats.
- Vol ampliar el seu servei a quatre noves ciutats.
- Pot aprofitar les torres de comunicacions ja existents, però n'ha de crear una de nova.
- La nova torre tindrà un radi de transmissió de 40 milles (64.374 km, aprox.).

Problema de localització: Gràfic de localització de les torres



Problema de localització: Variables de decisió i funció objectiu

Es minimitza la distància total des de la nova torre fins a les torres existents:

Variables de decisió:

 x_1 = Localització de la nova torre respecte l'eix X.

 y_1 = Localització de la nova torre respecte l'eix Y.

• Funció objectiu:

$$\min f(x_1, y_1) = \sqrt{(5 - y_1)^2 + (45 - y_1)^2} + \sqrt{(12 - x_1)^2 + (21 - y_1)^2} + \sqrt{(17 - x_1)^2 + (5 - y_1)^2} + \sqrt{(52 - x_1)^2 + (21 - y_1)^2}$$

Problema de localització: Definició de les restriccions

Cleveland:
$$\sqrt{(5-x_1)^2+(45-y_1)^2} \le 40$$

Akron:
$$\sqrt{(12-x_1)^2+(21-y_1)^2} \le 40$$

Canton:
$$\sqrt{(17-x_1)^2+(5-y_1)^2} \le 40$$

Youngstown:
$$\sqrt{(52-x_1)^2+(21-y_1)^2} \le 40$$

Problema de localització: Definició de les restriccions

min
$$f(x_1, y_1) = \sqrt{(5 - y_1)^2 + (45 - y_1)^2} + \sqrt{(12 - x_1)^2 + (21 - y_1)^2} + \sqrt{(17 - x_1)^2 + (5 - y_1)^2} + \sqrt{(52 - x_1)^2 + (21 - y_1)^2}$$

S. a:

$$\sqrt{(5-x_1)^2 + (45-y_1)^2} \le 40$$

$$\sqrt{(12-x_1)^2 + (21-y_1)^2} \le 40$$

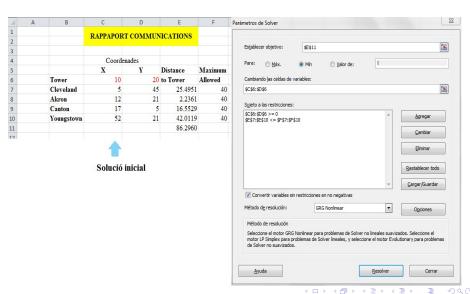
$$\sqrt{(17-x_1)^2 + (5-y_1)^2} \le 40$$

$$\sqrt{(52-x_1)^2 + (21-y_1)^2} \le 40$$

19 / 49

Bolancé () Investigació Operativa I

Problema de localització: Implementació del model amb Solver



Problema de localització: Solució del model amb *Solver* Mirar l'arxiu Exemple_T5.xlsx.

4	А	В	С	D	E	F
1			D-VDDVDUD	TCOMMIN	JCATIONS	
2			RAPPAPORT COMMUNICATIONS			
3						
4			Coordenades			
5			X	Y	Distance	Maximum
6		Tower	12.2001	21.0000	to Tower	Allowed
7		Cleveland	5	45	25.0568	40
8		Akron	12	21	0.2001	40
9		Canton	17	5	16.7045	40
10		Youngstown	52	21	39.7999	40
11					81.7612	
1.3						

Comentaris sobre els problemes de localització

- La formulació simplificada del problema de localització que hem vist pot no ser vàlida:
 - Pot haver-hi terrenys que no estiguin en venda.
 - ▶ Pot haver-hi terrenys on no es pot edificar (llacs,...).
- En aquests casos, la solució del model simplificat pot servir de començament per una anàlisi més acurada.
- Es poden afegir restriccions per a eliminar les zones on no es pot edificar.

Programació no lineal amb SAS/OR

El procediment que utilitzarem per a resoldre els models de programació no lineal (PNL) és el

PROC NLP

Aquest procediment té incorporat diferents algorismes d'optimització no lineal que es poden classificar en funció del tipus de restriccions del model: lineals o no lineals.

Programació no lineal amb SAS/OR

TFCH=name

TECHNIQUE=name

specifies the optimization technique. Valid values for it are as follows:

- CONGRA
- chooses one of four different conjugate gradient optimization algorithms, which can be more precisely specified with the <u>UPDATE</u>= option and modified with the <u>LINESEARCH</u>= option. When this option is selected, <u>UPDATE</u>=PB by default. For n > 400, CONGRA is the default optimization technique.
- DBI DOG

performs a version of double dogleg optimization, which can be more precisely specified with the <u>UPDATE</u>= option. When this option is selected, <u>UPDATE</u>=DBFGS by default.

- HYQUAN
- chooses one of three different hybrid quasi-Newton optimization algorithms which can be more precisely defined with the <u>VERSION=</u> option and modified with the <u>UNESEARCH=</u> option. By default, VERSION=2 and UPDATE=DBFGS.
- LEVMAR

performs the Levenberg-Marquardt minimization. For n < 40 , this is the default minimization technique for least-squares problems.

LICOMP

solves a quadratic program as a linear complementarity problem

NMSIMP

performs the Nelder-Mead simplex optimization method.

Problemes de PNL amb restriccions no lineals

- NONE
 - does not perform any optimization. This option can be used
 - · to do grid search without optimization
 - . to compute and display derivatives and covariance matrices which cannot be obtained efficiently with any of the optimization techniques
- NEWRAP
- performs the Newton-Raphson optimization technique. The algorithm combines a line-search algorithm with ridging. The line-search algorithm <u>LINESEARCH=</u>2 is the default.

 NORDING
- PRRIDG
 performs the Newton-Raphson optimization technique. For n. < 4() and non-linear least-squares, this is the default.
- QUADAS

performs a special quadratic version of the active set strategy.

QUANEW

chooses one of four quasi-Newton optimization algorithms which can be defined more precisely with the $\underline{ t uPDATE}$ = option and modified with the $\underline{ t uNESEARCH}$ = option. This is the default for 40 < n < 400 or if there are nonlinear constraints.

- TRUREG
- performs the trust region optimization technique

Problema de localització: Implementació del model amb SAS/OR

libname t4 '.':

```
□proc nlp tech=QUANEW;
min z;
parms x=0, y=0;
bounds x>=0, y>=0;
nlincon cl-c4<c0;
cl=((5-x)**2+(45-y)**2)**(1/2)-40;
c2=((12-x)**2+(21-y)**2)**(1/2)-40;
c3=((17-x)**2+(21-y)**2)**(1/2)-40;
c4=((52-x)**2+(21-y)**2)**(1/2)-40;
c4=((52-x)**2+(21-y)**2)**(1/2)-40;
c1=((52-x)**2+(21-y)**2)**(1/2)+((12-x)**2+(21-y)**2)**(1/2)+((17-x)**2+(5-y)**2)**(1/2)+((52-x)**2+(21-y)**2)**(1/2);
run;
</pre>
```

```
Eproc nlp tech=NMSIMF;
min z;
parms x=0, y=0;
bounds x>=0, y>=0;
nlincon cl-c4<c0;
cl-(15-x)**2+(45-y)**2)**(1/2)-40;
c2=((12-x)**2+(21-y)**2)**(1/2)-40;
c3=((17-x)**2+(5-y)**2)**(1/2)-40;
c3=((17-x)**2+(5-y)**2)**(1/2)-40;
c4=((52-x)**2+(21-y)**2)**(1/2)-40;
c2=((5-x)**2+(45-y)**2)**(1/2)+((12-x)**2+(21-y)**2)**(1/2)+((17-x)**2+(5-y)**2)**(1/2)+((52-x)**2+(21-y)**2)**(1/2);
rnn.</pre>
```

Problema de localització: Implementació del model amb SAS/OR

EXECUTAR L'ARXIU DE SAS Exemple_t5_1.SAS

Optimització d'una cartera de valors: *Portfolio Optimization*

Un assessor financer vol crear la cartera de valors de risc mínim que asseguri un valor esperat dels guanys de, com a mínim, un 12%. Les dades disponibles són:

	Guanys anuals			
Any	IBC	NMC	NBS	
1	11.2%	8.0%	10.9%	
2	10.8%	9.2%	22.0%	
3	11.6%	6.6%	37.9%	
4	-1.6%	18.5%	-11.8%	
5	-4.1%	7.4%	12.9%	
6	8.6%	13.0%	-7.5%	
7	6.8%	22.0%	9.3%	
8	11.9%	14.0%	48.7%	
9	12.0%	20.5%	-1.9%	
10	8.3%	14.0%	19.1%	
11	6.0%	19.0%	-3.4%	
12	10.2%	9.0%	43.0%	
Promig	7.64%	13.43%	14.93%	

Matriu de covariància					
	IBC	NMC	NBS		
IBC	0.00258	-0.00025	0.00440		
NMC	-0.00025	0.00276	-0.00542		
NBS	0.00440	-0.00542	0.003677		

NBS: valor amb major risc i benefici IBC: valor amb menor risc i benefici

Optimització d'una cartera de valors: Variables de decisió i funció objectiu

Variables de decisió:

 $p_1 = \%$ del fons invertit en IBC.

 $p_2 = \%$ del fons invertit en NMC.

 $p_3 = \%$ del fons invertit en NBS.

Funció objectiu. Es minimitza la variància de la cartera (risc):

$$\min f(p) = \sum_{i=1}^{n} \sigma_{i}^{2} p_{i}^{2} + 2 \sum_{i=1}^{n-1} \sum_{j=i+1}^{n} \sigma_{ij} p_{i} p_{j}$$

 $\sigma_i^2 = \text{ variància de la inversió } i$ (diagonal de la matriu de covariància) $\sigma_{ij} = \sigma_{ji} = \text{ covariància entre les inversions } i$ i j

Optimització d'una cartera de valors: Definició de les restriccions

• Valor esperat dels ingressos:

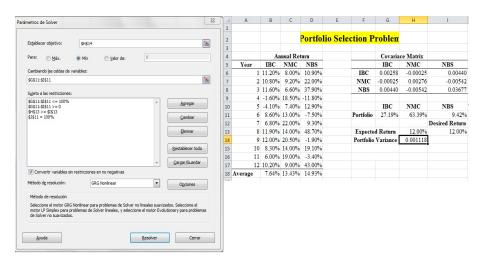
$$0.0764p_1 + 0.1343p_2 + 0.1493p_3 \ge 0.12$$

• Proporcions:

$$p_1 + p_2 + p_3 = 1$$

 $p_1, p_2, p_3 \ge 0$
 $p_1, p_2, p_3 \le 1$

Optimització d'una cartera de valors: Resolució del model



Objectius múltiples en l'optimització d'una cartera de valors

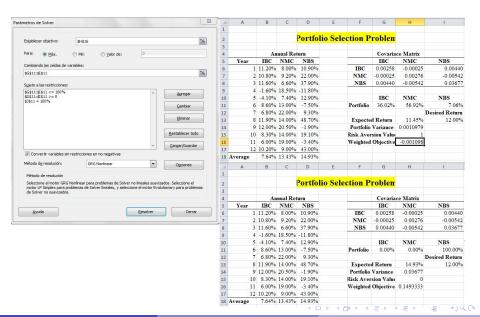
- En aquests problemes sovint es vol, simultàniament:
 - Minimitzar el risc (variància de la cartera).
 - Maximitzar el valor esperat dels ingressos.
- Aquests dos objectius es poden considerar simultàniament, fent:

$$\max f\left(x\right) = \quad (1-r) \times \text{Ingressos esperats } -r \times \text{Variància de la cartera} \\ \text{s.a.:} \quad p_1 + p_2 + \ldots + p_m = 1 \\ p_i > 0$$

- $0 \le r \le 1$ és el valor de rebuig del risc (definit per l'usuari):
 - ightharpoonup Si r=1, es maximitza la variància de la cartera.
 - ▶ Si r = 0, es maximitzen els ingressos esperats.

←□▶ ←□▶ ←□▶ ←□▶ □ ● ●

Resolució del model



Resolució del model

EXECUTAR L'ARXIU DE SAS Exemple_t5_2.SAS

Anàlisi de sensibilitat

Nom a PL	Nom a PNL	Significat	
Preu ombra (shadow price)	Multiplicadors de Lagrange (<i>Lagrange</i> <i>Multipliers</i>)	Valor marginal dels recursos	
Cost reduït (reduced cost)	Gradient reduït (<i>re-duced gradient</i>)	Canvi en la funció objectiu provocat per petits canvis del valor òptim de les variables de decisió	

• La informació d'anàlisi de sensibilitat és molt menor als problemes de PNL que als de PL.

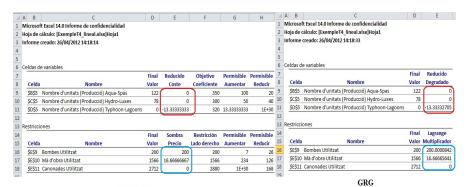
Comparació entre l'anàlisi de sensibilitat de PL i PNL (I)

- Considerem el problema de l'empresa "Blue Ridge Hot Tubs".
- Es resol amb l'algorisme de SIMPLEX i del GRG.

Comparació entre l'anàlisi de sensibilitat de PL i PNL

4	A	В	С	D	E	F	
1							
2			BLUE RIDGE HOT TUBS				
3							
4	NOM DELS PRODUCTES	Aqua-Spas	Hydro-Luxes	Typhoon-Lagoons			
5	Nombre d'unitats (Producció)	122	78	0	Benefici total		
6	Benefici unitari	\$350	\$300	\$320	\$66,100		
7							
8	Renstriccions				Utilitzat	Disponible	
9	Bombes	1	1	1	200	200	
10	Mà d'obra	9	6	8	1566	1566	
11	Canonades	12	16	13	2712	2880	
12							

Comparació entre l'anàlisi de sensibilitat de PL i PNL



SIMPLEX

Resolució de problemes de PNL

- L'algorisme del Gradient Reduït Generalitzat (GRG) és el procediment matemàtic usat per Solver per a resoldre problemes de PNL.
- Per al cas de problemes de PNL amb restriccions lineals (PNLrl):
 Gradient Reduït (GR).
- Definim:
 - 1) La forma estàndard d'un problema de PNLrl.
 - 2) Hipòtesi de no degeneració (HND).
- Seguirem l'evolució de l'algorisme del GRG a través del Solver.

Modificació del problema "Blue Ridge Hot Tubs"

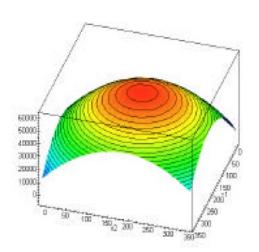
- Considereu que el departament de màrqueting ha detectat un efecte de saturació de mercat que fa que les vendes de jacuzzis disminueixin amb la producció:
 - La taxa de creixement dels beneficis disminueix amb x_1 i x_2 .
 - S'ha de reformular la funció objectiu:

$$z = c'x = 350x_1 + 300x_2$$

$$\downarrow$$

$$f(x) = 350x_1 + 300x_2 - 0.875x_1^2 - 0.8x_2^2$$

Modificació del problema "Blue Ridge Hot Tubs"



A. Forma estàndard d'un problema PNLrl

Forma estàndard d'un problema de PNLrl:

$$(PNLrI) = \begin{cases} min & f(x) \\ s.a.: & Ax = b \\ & x \ge 0 \end{cases}$$

• Pas a la forma estàndard:

$$\max f(x) \longrightarrow \min - f(x)$$

- La resta, com a PL.
- Exemple: "Blue Ridge Hot Tubs"

$$(\textit{PNLrI}) = \left\{ \begin{array}{ll} \textit{min } f\left(x\right) = & -350x_1 - 300x_2 + 0.875x_1^2 + 0.8x_2^2 \\ \textit{s.a.}: & x_1 + x_2 + x_3 = 200 \\ & 9x_1 + 6x_2 + x_4 = 1566 \\ & 12x_1 + 16x_2 + x_5 = 2880 \\ & x_i \geq 0, \ i = 1, 2, 3, 4, 5 \end{array} \right.$$

B. Hipòtesi de no degeneració (I)

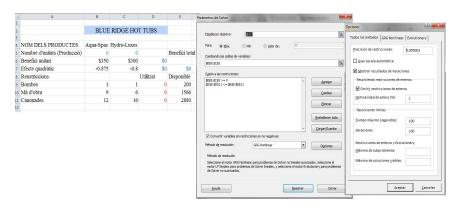
- **Hipòtesi de no degeneració**: Considereu el problema de *PNLrI* en forma estàndard. La hipòtesi de no degeneració considera que, sobre qualsevol vector $x \in \Re^n$ factible, *PNLrI* és possible definir una partició de les components de x en m variables bàsiques (x_B) i n-m variables no bàsiques (x_N) de forma que:
 - La matriu bàsica B associada a x_B és no singular.
 - Les variables bàsiques NO estan a fita inferior: $x_B > 0$.

Mètode del GR

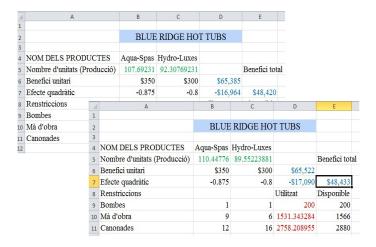
- El mètode del GR és un algorisme que permet resoldre problemes de *PNLrl* en forma estàndard basant-se en la següent estratègia:
 - **1** Es troba una solució factible inicial x (solució actual).

 - 3 Si x no és la solució òptima, cal trobar, si existeix, una nova solució factible que millori el valor de la funció objectiu, i es considera aquesta com a nova solució actual:
 - **1** Càlcul d'una direcció factible i de descens: Δx
 - 2 Exploració lineal: α*
 - 3 Actualització de la solució actual: $x = x + \alpha^* \Delta x$
 - Anada a 2.

L'algorisme del Gradient Reduït: Resolució amb Solver (I)

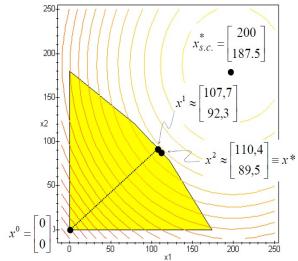


L'algorisme del Gradient Reduït: Resolució amb Solver (II)



L'algorisme del Gradient Reduït: Resolució amb Solver (III)

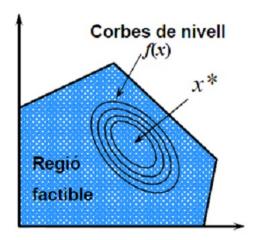
• Representació gràfica:



Convexitat

- L'algorisme del GRG que implementa Solver només assegura trobar punts extrems:
 - Convergeix a un punt que satisfa les condicions necessàries de 1er. ordre de mínim local (condicions de Karush-Kuhn-Tucker).
- Convexitat: tot punt extrem és mínim global si el problema de PNL és convex; és a dir, si:
 - La funció objectiu f(x) és convexa.
 - ► El conjunt factible *X* és convex.
- Exemple: minimització d'una funció quadràtica definida positiva sobre un poliedre.

Convexitat



Solució amb SAS/OR del problema "Blue Ridge Hot Tubs" modificat

EXECUTAR L'ARXIU DE SAS Exemple_t5_RHT.SAS