

BLOC 2= Tema 2 + Tema 3. Estimació Puntual  
+ Estimació per intervals.  
TEMA 3. Intervals de confiança

- 3.1** Concepte d'interval de confiança.
- 3.2** Interval de confiança per a la mitjana: cas normal i cas general.
- 3.3** Interval de confiança per a una proporció.
- 3.4** Intervals de confiança per a la variància. Cas normal
- 3.5** Intervals calculats amb R.

## 3.1 Concepte d'interval de confiança

Un **interval de confiança (IC)** per a un paràmetre  $\theta$  (no observable) és un tipus d'estimació de  $\theta$ , complementari a l'estimació puntual donada per  $\hat{\theta}$ .

Un interval de confiança es calcula **a partir de les observacions**, i per tant difereix de mostra a mostra.

Un interval de confiança **freqüentment** inclou el valor del paràmetre d'interès  $\theta$ .

La freqüència en que l'interval observat conté el paràmetre es determina pel **nivell de confiança**.

Si es construïssin molts intervals de confiança a partir de molts anàlisis de les dades per separat, la proporció de tals intervals que contenen el veritable valor del paràmetre  $\theta$  coincidiria amb el nivell de confiança donat.

# Interval de confiança per $\mu$ a partir d'una m.a.s de $X \sim N(\mu, 1), \sigma^2 = 1$ amb nivell de confiança del 99%

Ja sabem que  $\bar{X}$  és un bon estimador de  $\mu$ . Ara ens plantegem trobar un interval  $[\bar{X} - a, \bar{X} + a]$  amb **nivell de confiança**  $1 - \alpha = 0.99$ , és a dir,  $\text{Prob}\{\bar{X} - a \leq \mu \leq \bar{X} + a\} = 0.99$  per un cert valor  $a$ .


**Com trobem a?** En aquest cas ho resollem a partir d'una mostra  $X_1, X_2, X_3, X_4$ .

- 1 Calculem  $\bar{X} = \frac{1}{n} \sum_{i=1}^4 X_i$ . En realitat hauriem d'escriure  $\bar{X}_4$ , pero s'omet ara per fer-ho mes senzill de llegir.
- 2 Com que  $\bar{X} \sim N(\mu, 1/4)$ , estandaritzant  $\frac{\bar{X} - \mu}{1/2} = Z \sim N(0, 1)$
- 3  $0.99 = \text{Prob}\{\bar{X} - a \leq \mu \leq \bar{X} + a\} = \text{Prob}\{-2a \leq \frac{\bar{X} - \mu}{1/2} \leq 2a\}$   
 $0.99 = \text{Prob}\{-2a \leq Z \leq 2a\} = 1 - 2\text{Prob}\{Z \geq 2a\} \implies$   
 $\text{Prob}\{Z \geq 2a\} = 0.005 = \alpha/2$
- 4  $z_{\alpha/2} = z_{0.005} = 2.575 \implies 2a = 2.575 \implies a = 1.2875$
- 5  $\text{Prob}\{-2.575 \leq \frac{\bar{X} - \mu}{1/2} \leq 2.575\} = 0.99$
- 6  $[\bar{X} - 1.2875, \bar{X} + 1.2875]$  **interval de confiança per  $\mu$  amb nivell de confiança del 99%**


# Trobant els valors de les cues a les taules

AQUÍ, NORMALMENTE, AL NÚMERO IMPORTANTE LO LLAMAMOS  $\alpha$ , Y MIDE LA DIFERENCIA ENTRE EL NIVEL DESEADO DE CONFIANZA Y CERTEZA. POR EJEMPLO, CUANDO EL NIVEL DE CONFIANZA ES 95%, O 0.95,  $\alpha$  ES 0.05. ASÍ QUE HABLAMOS DEL NIVEL DE CONFIANZA  $(1 - \alpha) \cdot 100\%$ .


ENCONTRAR EL NIVEL DE CONFIANZA  $(1 - \alpha) \cdot 100\%$  IMPLICA OBSERVAR LA CURVA DE LA NORMAL TIPIFICADA Y BUSCAR LOS PUNTOS  $\pm z$  ENTRE LOS QUE EL ÁREA ES  $1 - \alpha$ .



ESTE PUNTO, LLAMADO  $z_{\frac{\alpha}{2}}$ , ES EL VALOR  $z$  MÁS ALLÁ DEL CUAL EL ÁREA ES  $0.025 = \frac{\alpha}{2}$ .



ESTO PASA PORQUE CORTAMOS LAS «COLAS» DE LOS DOS EXTREMOS DE LA CURVA, QUE TIENEN UN ÁREA TOTAL DE  $\frac{\alpha}{2} + \frac{\alpha}{2} = \alpha$ .



PODEMOS CALCULAR  $z_{\frac{\alpha}{2}}$  DIRECTAMENTE A PARTIR DE LA TABLA DE LA NORMAL TIPIFICADA (PÁGINA 84). ES EL PUNTO CON LA PROPIEDAD

$$Pr(z \geq z_{\frac{\alpha}{2}}) = \frac{\alpha}{2}$$

EN ESTE CASO,

$$Pr(z \geq z_{0.025}) = 0.025$$

$z$	-2.5	-2.4	-2.3	-2.2	-2.1
$F(z)$	0,006	0,008	0,011	0,014	0,018
$z$	-2.0	-1.9	-1.8	-1.7	-1.6
$F(z)$	0,023	0,029	0,036	0,045	0,055
$z$	-1.5				
$F(z)$	0,067	0,084			



$1 - z_{0.005}$   
SE  
ENCUENTRA  
EN ESTE  
INTERVALO!

# Interval de confiança amb nivell de confiança del 99%

Suposem que hem observat:

$x_1 = 3.4, x_2 = 1.9, x_3 = 2.8, x_4 = 4.1 \Rightarrow \bar{x} = 3.05$ . Estimem  $\mu$  per  $\bar{X}$  i l'estimació serà  $\bar{x} = 3.05$  amb  $S^2 = \sum_{i=1}^4 (x_i - \bar{x})^2 / 3 = 0.87$ ,  $S = 0.93$ .

Amb les dades de l'exemple l'interval

$[3.05 - 1.2875, 3.05 + 1.2875] = [1.7625, 4.3375]$  conté  $\mu$  amb una confiança del 99%.

Fixem-nos que els extrems de l'interval de confiança depenen de:

- 1 Les dades  $x_1 = 3.4, x_2 = 1.9, x_3 = 2.8, x_4 = 4.1 \Rightarrow \bar{x} = 3.05$
- 2 La desviació estàndard. En aquest cas  $\sigma = 1$  coneguda
- 3 El nivell de confiança  $1 - \alpha$ . En aquest cas  $\alpha = 0.01$
- 4 La llei de  $\bar{X}$ . En aquest cas  $\bar{X} \sim N(\mu, 1/4)$
- 5  $\alpha = 0.01$  i  $\bar{X} \sim N(\mu, 1/4) \Rightarrow z_{\alpha/2} = 2.575$

El preu que hem pagat per aconseguir una CONFIANÇA del 99%, en comptes d'un 95%, ha estat un interval MÉS AMPLE i per tant menys precisió per estimar  $\mu$ :

passem de  $[2.05, 4.05]$  (confiança 95%) a

$[1.76, 4.34]$  (confiança 99%)

# Definició interval de confiança: FORMALMENT

## Definició

Sigui  $X_1, X_2, \dots, X_n \sim X \sim$  model probabilístic que depèn de  $\theta$ .  
Un **interval de confiança**  $[\hat{\theta}_1, \hat{\theta}_2]$  **amb nivell de confiança**  $100(1 - \alpha)\%$  per a  $\theta$  és un interval **aleatori** tal que  
 $\text{Prob}\{[\hat{\theta}_1, \hat{\theta}_2] \text{ conte } \theta\}$  amb probabilitat  $1 - \alpha$ .

Els extrems de l'interval  $\hat{\theta}_1$  i  $\hat{\theta}_2$  es calculen a partir de

- les dades mostrals  $(x_1, x_2, \dots, x_n)$
- el nivell de confiança  $100(1 - \alpha)\%$

En l'exemple anterior, el paràmetre  $\theta = \mu$

- per un nivell de confiança del  $1 - \alpha = 99\%$   
 $\hat{\mu}_1 = \hat{\mu}_1(X_1, X_2, \dots, X_n, 0.99) = \bar{X} - 1.2875$  i  
 $\hat{\mu}_2 = \hat{\mu}_2(X_1, X_2, \dots, X_n, 0.99) = \bar{X} + 1.2875 \Rightarrow$   
 $[\bar{X} - 1.2875, \bar{X} + 1.2875]$
- per un nivell de confiança del  $1 - \alpha = 95\%$   
 $\hat{\mu}_1 = \hat{\mu}_1(X_1, X_2, \dots, X_n, 0.95) = \bar{X} - 1$  i  
 $\hat{\mu}_2 = \hat{\mu}_2(X_1, X_2, \dots, X_n, 0.95) = \bar{X} + 1 \Rightarrow [\bar{X} - 1, \bar{X} + 1]$

LLEGIR PEÑA 8.1 PÀGINES 319-321

# Per que funcionen els intervals de confiança?

$X_1, X_2, \dots, X_n \sim X \sim$  model probabilístic que depèn de  $\theta$

Busquem un interval  $[\hat{\theta}_1, \hat{\theta}_2]$  tal que  $\hat{\theta}_1 \leq \theta \leq \hat{\theta}_2$

$\hat{\theta}_1$  i  $\hat{\theta}_2$  es calculen a partir de la mostra  $X_1, X_2, \dots, X_n$  de forma tal que si:


- agafessim MOLTES mostres,
- totes de la mateixa grandària  $n$
- per cada una fessim un interval  $\hat{\theta}_1^{(i)} \leq \theta \leq \hat{\theta}_2^{(i)}$
- podriem afirmar que el  $100(1 - \alpha)\%$  (per exemple 95%) dels intervals construïts contindrien  $\theta$ , el veritable valor del paràmetre.

Veiem-ho gràficament



# Interpretant el nivell de confiança

ESTA PÁGINA MUESTRA LOS RESULTADOS DE UNA SIMULACIÓN POR ORDENADOR DE VEINTE MUESTRAS DE TAMAÑO  $n = 1.000$ . SUPONEMOS QUE EL VALOR REAL DE  $p = 0.5$ . EN LA PARTE SUPERIOR PUEDES VER LA DISTRIBUCIÓN MUESTRAL DE  $\hat{p}$  (NORMAL, CON MEDIA  $p$  Y  $\sigma = \sqrt{\frac{p(1-p)}{n}}$ ). EN LA PARTE INFERIOR SE ENCUENTRAN LOS INTERVALOS DE CONFIANZA DE CADA MUESTRA, AL 95%. COMO MEDIDA, UNO DE CADA VEINTE (O UN 5%) DE ESTOS INTERVALOS NO INCLUIRÁ EL PUNTO  $p = 0.5$ .



## 3.2 Interval de confiança per a $\mu$ : cas normal i cas general

Sigui  $X_1, \dots, X_n$  una m.a.s. de  $X$ . Distingim els següents 3 casos:

- 1 Interval de confiança per a la mitjana d'una  $N(\mu, \sigma^2)$  amb  $\sigma^2$  coneguda  $\Rightarrow$  Prova  $Z$ . Fet a l'apartat 3.1.
- 2 Interval de confiança per a la mitjana d'una  $N(\mu, \sigma^2)$  amb  $\sigma^2$  desconeguda  $\Rightarrow$  Prova  $t$  de Student
- 3 Interval de confiança per a la mitjana  $\mu$  amb  $\sigma^2$  desconeguda i  $n > 30 \Rightarrow$  Prova  $Z$

# Interval de confiança per a $\mu$ quan les dades són $N(\mu, \sigma^2)$ amb $\sigma^2$ coneguda. Com a 3.1 amb $\alpha$ i $\sigma^2$ qualsevols

Sigui  $X_1, \dots, X_n$  una m.a.s. de  $X \sim N(\mu, \sigma^2)$ , amb  $\sigma^2$  coneguda.

Interval de confiança de nivell de confiança  $1 - \alpha$  pel paràmetre  $\mu$ .

- Escollim  $1 - \alpha \Rightarrow$  Calculem  $\alpha/2$
- Determinem  $z_{\alpha/2}$  fent servir que  $Z \sim N(0, 1)$

$$\text{Prob}\left(-z_{\alpha/2} < Z < z_{\alpha/2}\right) = 1 - \alpha$$

- $X \sim N(\mu, \sigma^2) \Rightarrow \bar{X} \sim N(\mu, \frac{\sigma^2}{n}) \Rightarrow Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1) \Rightarrow$

$$\text{Prob}\left(-z_{\alpha/2} < \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} < z_{\alpha/2}\right) = 1 - \alpha$$

$$\text{Prob}\left(-z_{\alpha/2} \frac{\sigma}{\sqrt{n}} < \bar{X} - \mu < z_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha$$

$$\text{Prob}\left(\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}} < \mu < \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha$$

# Interval de confiança per a $\mu$ quan les dades són $N(\mu, \sigma^2)$ i $\sigma^2$ coneguda

- Interval de confiança de nivell de confiança  $1 - \alpha$ :

$$\left( \bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right)$$

- Donades les dades:  $x_1, x_2, \dots, x_n$ , calculem  $\bar{x}$ , l'interval

$$\left( \bar{x} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{x} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right)$$

conté a la mitjana  $\mu$  amb probabilitat  $1 - \alpha$ .

- Usualment expressem:

$$IC_{1-\alpha}(\mu) = \bar{x} \pm z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$$

**Exemple:** Si  $\sigma = 1.5$ ,  $n = 12$  i  $\bar{x} = 3.6$ ,

$$1 - \alpha = 0.95 \Rightarrow z_{\alpha/2} = z_{0.05/2} = 1.96$$

$$\left( 3.6 - 1.96 \frac{1.5}{\sqrt{12}}, 3.6 + 1.96 \frac{1.5}{\sqrt{12}} \right) = (2.751, 4.449) \text{ és un interval de}$$

confiança al 95% per la mitjana poblacional  $\mu$ .

# Interval de confiança per a $\mu$ quan les dades són $N(\mu, \sigma^2)$ i $\sigma^2$ desconeguda

Sigui  $X_1, \dots, X_n$  una m.a.s. de  $X \sim N(\mu, \sigma^2)$ , amb  $\sigma^2$  desconeguda. **Interval de confiança de nivell de confiança  $1 - \alpha$  pel paràmetre  $\mu$ .**

- Escollim  $1 - \alpha \Rightarrow$  Calculem  $\alpha/2$
- Calculem  $S^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n-1}$
- L'estadístic

$$T_{n-1} = \sqrt{n} \frac{\bar{X} - \mu}{S} = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}$$

es distribueix com una  $t$  de Student amb  $n - 1$  g.ll.

- Es tracta de trobar  $a$  i  $b$  tal que

$$\text{Prob}\left(a < \frac{\bar{X} - \mu}{S/\sqrt{n}} < b\right) = 1 - \alpha$$

- En comptes de  $Z$  usarem  $t_{n-1}$

**LLEGIR PEÑA 8.3.2 PÀGINES 325-326**

# LECTURA INDEPENDENT: t de Student amb notació matemàtica

- $Y, Z$  v.a.'s independents
- $Z \sim N(0, 1)$
- $Y \sim \chi^2_\nu$

la distribució de la v.a.  $t_\nu = \frac{Z}{\sqrt{Y/\nu}}$  s'anomena **distribució t de Student amb  $\nu$  graus de llibertat**

- Quan  $n$  és gran,  $t_{n-1}$  s'aproxima MOLT a una  $N(0, 1)$
- Amb efectes pràctics es pot fer servir la Normal en comptes de la t.
- Per  $\alpha/2 = 0.025$  ( $\Rightarrow 1 - \alpha/2 = 0.975$ ),  $t_{30;0.975} = 2.042$ ,  $t_{35;0.975} = 2.030$ ,  $t_{60;0.975} = 2.00$ ,  $t_{90;0.975} = 1.987$ , i quan  $n \rightarrow \infty$   $t_{n;0.975} = 2.045 \approx z_{0.975} = 1.96$

# Interval de confiança amb nivell de confiança $1 - \alpha$ per a $\mu$ basat en una $t$ de Student

Sigui  $X_1, \dots, X_n$  una m.a.s. de  $X \sim N(\mu, \sigma^2)$ , amb  $\sigma^2$  desconeguda.

- Escollim  $1 - \alpha \Rightarrow$  calculem  $\alpha/2$
- Trobem  $a$  i  $b$  tal que

$$\text{Prob}\left(a < \frac{\bar{X} - \mu}{S/\sqrt{n}} < b\right) = 1 - \alpha$$

Com?

- Degut a la simetria de  $t$  de Student repartim  $\alpha$  de forma equànim a cada cua assignant  $\alpha/2$ .
- Calculem el percentil  $t_{n-1; 1-\frac{\alpha}{2}}$ . Definim  $a = -t_{n-1; 1-\frac{\alpha}{2}}$  i  $b = t_{n-1; 1-\frac{\alpha}{2}}$

- 

$$\text{Prob}\left(-t_{n-1; 1-\frac{\alpha}{2}} < t_{n-1} = \frac{\bar{X} - \mu}{S/\sqrt{n}} < t_{n-1; 1-\frac{\alpha}{2}}\right) = 1 - \alpha$$

# Interval de confiança basat en una t de Student

Fent servir les mateixes manipulacions que abans obtenim

$$\text{Prob}\left(-t_{n-1;1-\alpha/2} < t_{n-1} = \frac{\bar{X} - \mu}{S/\sqrt{n}} < t_{n-1;1-\alpha/2}\right) = 1 - \alpha$$

$$\text{Prob}\left(-t_{n-1;1-\alpha/2} \frac{S}{\sqrt{n}} < \bar{X} - \mu < t_{n-1;1-\alpha/2} \frac{S}{\sqrt{n}}\right) = 1 - \alpha$$

$$\text{Prob}\left(\bar{X} - t_{n-1;1-\alpha/2} \frac{S}{\sqrt{n}} < \mu < \bar{X} + t_{n-1;1-\alpha/2} \frac{S}{\sqrt{n}}\right) = 1 - \alpha$$

L'interval de confiança amb nivell de confiança  $1 - \alpha$  per a la mitjana  $\mu$  és

$$\left(\bar{X} - t_{n-1;1-\alpha/2} \frac{S}{\sqrt{n}}, \bar{X} + t_{n-1;1-\alpha/2} \frac{S}{\sqrt{n}}\right)$$



## EXERCICI VOLUNTARI 2: Alçada dels estudiants del Grau d'Estadística

Les alçades dels dels estudiants del Grau d'Estadística UB-UPC es distribueixen com una Normal  $(\mu_A, \sigma_A^2)$ .

- 1 A quants estudiants haurem de mesurar si, amb una probabilitat del 95% (o superior), volem estimar la mitjana  $\mu_A$  de l'alçada amb una precisió de 3cm?. Supposeu que la desviació estàndar de les alçades és  $\sigma_A = 8.5\text{cm}$ .
- 2 A quants estudiants haurem de mesurar si, amb una probabilitat del 95% (o superior), volem l'estimació de  $\mu_A$  amb una precisió  $0.64\sigma_A$  cm i l'estimació de  $\sigma_A$  amb una precisió de  $0.8\sigma_A$  cm.
- 3 Suposat que l'alçada mitjana de la població d'estudiants és de  $\mu_A = 174$  cm amb desviació estàndar  $\sigma_A = 8.5\text{cm}$ , simuleu (genereu), amb R, aleatòriament  $n = 50$  alçades d'aquesta població. Podeu fer servir la funció `rnorm(n,mu,sigma)=rnorm(50,174,8.5)`.

## EXERCICI VOLUNTARI 2: Alçada dels estudiants del Grau d'Estadística

Calculeu  $\sum_{i=1}^{50} x_i$  i  $\sum_{i=1}^{50} x_i^2$  amb les 50 dades simulades i feu servir aquests valors per construir els següents intervals de confiança per la mitjana poblacional de les alçades dels estudiants  $\mu_A$  :

- 4 Calculeu intervals de confiança per  $\mu_A$  al 90% i al 95%, suposant que  $\sigma_A = 8.5\text{cm}$ .
- 5 Calculeu intervals de confiança per  $\mu_A$  al 90% i al 95%, estimant la desviació estàndar de la població a partir de les dades simulades
- 6 Entre quins valors es troba la mitjana poblacional de l'alçada dels estudiants del Grau d'Estadística i perquè?

## EXERCICI VOLUNTARI 2: Alçada dels estudiants del Grau d'Estadística


Simuleu  $k = 100$  mostres d'alçades de grandària  $n = 50$  a partir d'una variable aleatòria Normal de mitjana  $\mu_A = 174$  cm i desviació estàndar  $\sigma_A = 8.5$ cm.

- 7 Calculeu els  $k = 100$  intervals de confiança per  $\mu_A$  al 90% deduïts de les 100 mostres simulades havent estimat la desviació estàndar de la població a partir de les dades simulades
- 8 Quina proporció d'intervals conté el valor 174? Noteu que heu generat dades d'una normal amb mitjana  $\mu_A = 174$ .
- 9 Escriviu amb les vostres pròpies paraules el que enteneu per interval de confiança a partir de les conclusions d'aquest exercici.

RESOLEU-LO i LLIUREU-LO EL DIVENDRES 1 D'ABRIL

## Exemple Bismut: element químic, Bi, nombre atòmic 83

El contingut de bismut en un aliatge en 10 mostres és (en ppm):  
19.7, 21.4, 12.5, 13.8, 13.5, 20.4, 18.2, 16.6, 15.2, 16.3



$$\bar{x} = \frac{\sum_{i=1}^{10} x_i}{10} = \frac{167.6}{10} = 16.76$$

$$S^2 = \frac{1}{9} \left( \sum_{i=1}^{10} x_i^2 - 10(16.76)^2 \right) = \frac{85.704}{9} = 9.52 \Rightarrow S = 3.08$$

La mitjana del contingut de Bismut en aquest aliatge és de 16.76 ppm amb una desviació estàndar de 3.086 ppm.

# Interval de confiança al 95% pel contingut mig de Bismut

Un interval de confiança al 95%  $\implies 1 - \alpha = 0.95$

L'interval de confiança general és:

$$\left( \bar{x} - t_{n-1;1-\alpha/2} \frac{S}{\sqrt{n}}, \bar{x} + t_{n-1;1-\alpha/2} \frac{S}{\sqrt{n}} \right)$$

que traduït al nostre exemple serà:

$$\left( 16.76 - t_{9;1-0.05/2} \frac{3.086}{\sqrt{10}}, 16.76 + t_{9;1-0.05/2} \frac{3.086}{\sqrt{10}} \right)$$
$$(16.76 - 2.208, 16.76 + 2.208) = (14.552, 18.968)$$

Com que  $n = 10$ , hem mirat a la taula de la distribució de la  $t$  d'Student amb  $n - 1 = 10$  g.ll.:  $t_{9;0.975} = 2.2622$  i com  $1 - \alpha = 0.95$  hem agafat  $\alpha/2 = 0.025$ .)

# Interval de confiança al 99% pel contingut mig de Bismut

Si ara en volguéssim un interval de confiança al 99%, en aquest cas  $\alpha = 1 - 0.99 = 0.01$  i només cal que substituïm  $t_{9;0.975} = 2.208$  per  $t_{9;0.995} = 3.2498$  i l'interval quedaria de la forma:

$$\left( 16.76 - t_{9;1-0.01/2} \frac{3.086}{\sqrt{10}}, 16.76 + t_{9;1-0.01/2} \frac{3.086}{\sqrt{10}} \right) = \\ (16.76 - t_{9;0.995} 0.976, 16.76 + t_{9;0.995} 0.976)$$

per tant s'obté l'interval

$$(13.588, 19.932)$$

Comparem-lo amb l'interval de confiança al 95%: (14.552, 18.968). Notem que continua centrat en la mitjana 16.76 però l'interval s'ha fet més gran ja que estem exigint més precisió al resultat.

# Interval de confiança per a la mitjana: cas general

Sigui  $X_1, X_2, \dots, X_n \sim X$  i **no coneixem la distribució de  $X$** , podria ser exponencial, lognormal, normal, etc.

Sigui  $\mu$  la mitjana de la població ( $E(X) = \mu$ ) i  $\sigma^2$  la variància de la població ( $\sigma^2 = \text{Var}(X)$ .)

**Volem un interval de confiança amb nivell de confiança  $1 - \alpha$  per  $\mu$ .**

Ens basarem en el **Teorema Central del Límit (TCL)** i en la **Llei dels Grans Nombres (LGN)** que ens assegurin, per mostres de grandària  $n$  gran, que

- La mitjana mostral  $\bar{X} \sim N(\mu, \sigma^2/n)$  (TCL)
- La variància mostral  $S^2$  es comporta com  $\sigma^2$  (LGN)
- 

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim N(0, 1)$$

- Podem determinar el valor  $z_{\alpha/2}$  de manera que

$$\text{Prob}\left(-z_{\alpha/2} < \frac{\bar{X} - \mu}{S/\sqrt{n}} < z_{\alpha/2}\right) = 1 - \alpha.$$

# Interval de confiança per a la mitjana: cas general

Per a mostres grans de qualsevol població, l'interval

$$\left( \bar{x} - z_{\alpha/2} \frac{S}{\sqrt{n}}, \bar{x} + z_{\alpha/2} \frac{S}{\sqrt{n}} \right)$$

obtingut a partir d'un valor qualsevol de  $\bar{x}$ , conté a la mitjana  $\mu$  amb una probabilitat  $1 - \alpha$  i per tant

$$IC_{1-\alpha}(\mu) = \bar{x} \pm z_{\alpha/2} \frac{S}{\sqrt{n}}$$

és un interval de confiança per  $\mu$  de nivell  $1 - \alpha$ .

**LLEGIR PEÑA 8.4 PÀGINA 326**



### 3.3 Interval de confiança per a una proporció

Sigui  $p$  la **proporció desconeguda** d'una certa característica  $C$  en una població. Com fer per estimar-la?

- Prenem una mostra  $X_1, X_2, \dots, X_n$  mostra aleatòria de  $X$  on  $X = 1$  si l'individu presenta  $C$ ,  $X = 0$  si l'individu no presenta  $C$
- De fet  $X \sim \text{Bern}(p)$
- Estimem  $p$  mitjançant la proporció d'individus que presenten  $C \Rightarrow \hat{p} = \frac{\sum_{i=1}^n X_i}{n} = \bar{X}$
- Recordem que  $\sum_{i=1}^n X_i \sim \text{Bin}(n, p)$  = nombre d'individus que verifiquen la característica d'interès i  
 $\text{Var}(\sum_{i=1}^n X_i) = np(1 - p)$
- $\text{Var}(\hat{p}) = \text{Var}\left(\frac{\sum_{i=1}^n X_i}{n}\right) = \frac{\text{Var}(\sum_{i=1}^n X_i)}{n^2} = \frac{p(1-p)}{n}.$

# Interval de confiança per a una proporció per $n$ gran

Suposem que ens basem en un nombre d'individus prou gran, posem  $n > 30$

- Pel Teorema Central del Límit,  $\sum_{i=1}^n X_i \sim N(np, np(1-p))$
- $\hat{p} \sim N(p, \frac{p(1-p)}{n})$
- $\frac{\hat{p}-p}{\sqrt{\frac{p(1-p)}{n}}} \sim N(0, 1)$
- $\frac{\hat{p}-p}{\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}} \sim N(0, 1)$
- Un interval de confiança per  $p$  amb un nivell de confiança  $100(1-\alpha)\%$  ve donat per:

$$\left( \hat{p} - z_{\alpha/2} \frac{\sqrt{\hat{p}(1-\hat{p})}}{\sqrt{n}}, \hat{p} + z_{\alpha/2} \frac{\sqrt{\hat{p}(1-\hat{p})}}{\sqrt{n}} \right)$$

Recordem que es vol estimar el percentatge de nens obesos en la comunitat Americana-Latina (no mexicana) i Americana-Xinesa. A l'article parlant de la Prevalença de sobrepes.

- *Overweight prevalence*=Prevalença de sobrepes: quantifica la proporció de nens obesos en un període donat
- Com es defineix el sobrepes infantil?
- Hi ha el mateix llindar per qualsevol edat?
- Hi ha el mateix llindar per nens i nenes?
- La resposta és negativa: El llindar de sobrepes infantil és específic per grups d'edat i per gènere

# HEALTHY FOR LIFE: Interval de confiança per la prevalença de sobrepes

If a simple random sample design had been used, overweight prevalence could have been estimated by  $\hat{p} = x/n$ , where  $x$  is the number of overweight children in the sample or relevant subsample (e.g., children aged 2–5) and  $n$  is the total sample or subsample size. However, the sample design employed needs to be taken into account for the analysis.

In a simple random sample, the variance of  $\hat{p}$  could have been estimated by  $\hat{p}(1-\hat{p})/n$ , and 95% confidence intervals given by  $\hat{p} \pm 1.96\sqrt{\hat{p}(1-\hat{p})/n}$ . The use of the sample weights to

L'interval de confiança per la prevalença és:

$$(LI, LS) = \left( \hat{p} - z_{\alpha/2} \frac{\sqrt{\hat{p}(1-\hat{p})}}{\sqrt{n}}, \hat{p} + z_{\alpha/2} \frac{\sqrt{\hat{p}(1-\hat{p})}}{\sqrt{n}} \right)$$

on  $LI$  i  $LS$  indiquen el límit inferior i superior de l'interval.

# Healthy for Life: Intervals de confiança per la prevalença

- A partir de les dades de l'article ( $n = 2474$ )
- 990 nens: 490 nens i 500 nenes entre 2 i 5 anys
- 1484 nens: 740 nens i 744 nenes entre 6 i 11 anys
- NS: nombre de nens/nenes a cada categoria amb sobrepes
- **LI i LS el límit inferior i superior de l'interval de confiança per la proporció de sobrepes al 95%.**

Els intervals de confiança per la **prevalença de sobrepes** (proporció de nens/nenes amb sobrepes) en cada categoria d'edat.

	EDAT	n	NS	$\hat{p}$	$\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$	LI	LS
Both	2-5	990	216	0.218	0.0131	0.1925	0.2439
Both	6-11	1484	353	0.238	0.0111	0.2162	0.2595
Nens	2-5	490	112	0.229	0.0190	0.1914	0.2658
Nens	6-11	740	172	0.232	0.0155	0.2020	0.2629
Nenes	2-5	500	104	0.208	0.0182	0.1724	0.2436
Nenes	6-11	744	181	0.243	0.0157	0.2124	0.2741

# LECTURA INDEPENDIENT. Obesitat infantil

A la WHO: World Health Organization (Organización Mundial de la Salud (OMS))

<http://www.who.int/mediacentre/factsheets/fs311/es/index.html>

**¿Qué son la obesidad y el sobrepeso?** *La obesidad y el sobrepeso se definen como una acumulación anormal o excesiva de grasa que puede ser perjudicial para la salud. El índice de masa corporal (IMC) -el peso en kilogramos dividido por el cuadrado de la talla en metros ( $\text{kg}/\text{m}^2$ )- es una indicación simple de la relación entre el peso y la talla que se utiliza frecuentemente para identificar el sobrepeso y la obesidad en **los adultos**, tanto a nivel individual como poblacional. La OMS define sobrepeso cuando  $\text{IMC} \geq 25$ , y obesidad cuando  $\text{IMC} \geq 30$ . Los nuevos Patrones de crecimiento infantil presentados por la OMS en abril de 2006 incluyen tablas del IMC para lactantes y niños de hasta 5 años. **La medición del sobrepeso y la obesidad en niños de 5 a 14 años es difícil porque no hay una definición normalizada de la obesidad infantil que se aplique en todo el mundo.***

# LECTURA INDEPENDENT. Índex Masa Corporal infantil

Consulteu el CDC: Center for Disease Control.

<http://www.cdc.gov/healthyweight/assessing/bmi>

**Calculating and interpreting BMI for children and teens involves the following steps:**

1. *Obtain accurate height and weight measurements.*
2. *Calculate the BMI and percentile using the Child and Teen BMI Calculator.*
3. *Review the calculated BMI-for-age percentile and results.*

*BMI is both age-and sex-specific for children and teens because:.*

- *The amount of body fat changes with age.*
  - *The amount of body fat differs between girls and boys.*
4. *Find the weight status category for the calculated BMI-for-age percentile as shown in the following table:*
    - Underweight  $\Leftrightarrow$  Less than the 5th percentile
    - Healthy weight  $\Leftrightarrow$  5th percentile to less than the 85th percentile
    - Overweight  $\Leftrightarrow$  85th to less than the 95th percentile
    - Obese  $\Leftrightarrow$  Equal to or greater than the 95th percentile

### 3.4 Interval de confiança per la variança d'una població normal

Sigui  $X \sim N(\mu, \sigma^2)$  i volem construir l'interval de confiança per  $\sigma^2$  a partir d'una mostra  $X_1, \dots, X_n \sim X$ .

Calcularem la variància mostral  $S^2$  i farem servir la distribució  $\chi^2$  amb  $n - 1$  graus de llibertat, tenint en compte que

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$$

Es tracta de trobar  $a$  i  $b$  tal que

$$\mathbf{P}\left(a < \frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2 < b\right) = 1 - \alpha$$

En aquest cas la llei  $\chi^2$  amb  $n - 1$  graus de llibertat no és simètrica, i per tant encara que repartim  $1 - \alpha$  entre les dues cues, no podem fer com abans  $a = -b$ , sino que haurem de trobar dos valors diferents  $a = \chi_{n-1; \alpha/2}^2$  i  $b = \chi_{n-1; 1-\alpha/2}^2$ .

**LLEGIR PEÑA 8.5 PÀGINES 327-330**



# Interval de confiança per la variància d'una Normal

Els dos valors diferents  $a = \chi_{n-1;\alpha/2}^2$  i  $b = \chi_{n-1;1-\alpha/2}^2$  són tals que

$$\mathbf{P}\left(\frac{(n-1)S^2}{\sigma^2} < \chi_{n-1;\alpha/2}^2 = a\right) = \frac{\alpha}{2}$$

$$\mathbf{P}\left(\frac{(n-1)S^2}{\sigma^2} < \chi_{n-1;1-\alpha/2}^2 = b\right) = 1 - \frac{\alpha}{2}$$

i per tant

$$\text{Prob}\left(a = \chi_{n-1;\alpha/2}^2 < \frac{(n-1)S^2}{\sigma^2} < \chi_{n-1;1-\alpha/2}^2 = b\right) = 1 - \alpha$$

o equivalentment

$$\text{Prob}\left(\frac{1}{b} = \frac{1}{\chi_{n-1;1-\alpha/2}^2} < \frac{\sigma^2}{(n-1)S^2} < \frac{1}{\chi_{n-1;\alpha/2}^2} = \frac{1}{a}\right) = 1 - \alpha$$

# Interval de confiança per la variància d'una Normal

Manipulem aquesta expressió per tal “d'aïllar”  $\sigma^2$ . Teniem

$$\text{Prob}\left(\frac{1}{\chi^2_{n-1;1-\alpha/2}} < \frac{\sigma^2}{(n-1)S^2} < \frac{1}{\chi^2_{n-1;\alpha/2}}\right) = 1 - \alpha$$

o, el que és el mateix

$$\text{Prob}\left(\frac{(n-1)S^2}{\chi^2_{n-1;1-\alpha/2}} < \sigma^2 < \frac{(n-1)S^2}{\chi^2_{n-1;\alpha/2}}\right) = 1 - \alpha$$

Obtenim, doncs, **l'interval de confiança per  $\sigma^2$ :**

$$IC_{1-\alpha}(\sigma^2) = \left( \frac{(n-1)S^2}{\chi^2_{n-1;1-\alpha/2}}, \frac{(n-1)S^2}{\chi^2_{n-1;\alpha/2}} \right)$$

Notem que l'interval no és simètric respecte del valor de  $S^2$ .

## Exemple Bismut

Recordem que  $n = 10$ ,  $\bar{x} = 16.76$  i  $S^2 = 9.52$  i un interval de confiança al 95% per  $\mu$  és  $(14.552, 18.968)$ .

Troben a la taula de la  $\chi^2_9$ :

$$a = \chi^2_{n-1;\alpha/2} = \chi^2_{9;0.025} = 2.70$$

$$b = \chi^2_{n-1;1-\alpha/2} = \chi^2_{9;0.975} = 19.02$$

i per tant l'interval de confiança per  $\sigma^2$  al 95% serà:

$$\left( \frac{9 \cdot 9.52}{19.02}, \frac{9 \cdot 9.52}{2.7} \right) = \left( \frac{85.68}{19.02}, \frac{85.68}{2.7} \right) = (4.505, 31.73)$$

En resum, les dades recollides del bismut indiquen que la millor estimació de la mitjana  $\mu$  de l'aliatge de Bismut és 16.76 ppm i l'interval  $(14.5, 19)$  conté  $\mu$  amb alta probabilitat. La millor estimació de la desviació típica és 3.08 ( $\sqrt{9.52}$ ) i l'interval  $(2.12, 5.63) = (\sqrt{4.5}, \sqrt{31.7})$  conté  $\sigma$  amb alta probabilitat.