

La desigualdad de Cramer-Rao

-1-

Sea $X \sim f(x, \theta)$ con $x \in X$ (espacio muestral que podemos pensar incluido en \mathbb{R}^k)

y $\theta \in \Theta$ (espacio de parámetros que podemos pensar incluido en \mathbb{R}^m)

f es una densidad de probabilidad (para fijar ideas podemos pensar que X es absolutamente continua, aunque no es imprescindible)

$$\int_X f(x, \theta) dx = 1$$

Sea X_1, \dots, X_n las variables aleatorias muestrales correspondientes a una muestra aleatoria simple de tamaño " n " i.e. X_1, \dots, X_n i.i.d X
la densidad conjunta de X_1, \dots, X_n será pues:

$$\tilde{f}(x_1, \dots, x_n, \theta) = f(x_1, \theta) \cdot \dots \cdot f(x_n, \theta)$$

Supongamos además que el soporte de la densidad no depende de θ .
es la adherencia del subconjunto del dominio donde la densidad es positiva

Sea $U = U(X_1, \dots, X_n)$ un estimador de θ . Tendremos en notación matricial

$$U = \begin{pmatrix} U_1 \\ \vdots \\ U_m \end{pmatrix} \quad \theta = \begin{pmatrix} \theta_1 \\ \vdots \\ \theta_m \end{pmatrix}$$

El sesgo será:

$$B(\theta) = E_\theta(U) - \theta = \begin{pmatrix} E_\theta(U_1) \\ \vdots \\ E_\theta(U_m) \end{pmatrix} - \begin{pmatrix} \theta_1 \\ \vdots \\ \theta_m \end{pmatrix}$$

Calculemos:

$$\frac{\partial}{\partial \theta_\beta} B_\alpha(\theta) = \frac{\partial}{\partial \theta_\beta} (E_\theta(U_\alpha) - \theta_\alpha) = \frac{\partial}{\partial \theta_\beta} E_\theta(U_\alpha) - \delta_{\alpha\beta}$$

$$\text{donde } \delta_{\alpha\beta} = \begin{cases} 1 & \text{si } \alpha = \beta \\ 0 & \text{si } \alpha \neq \beta \end{cases} \quad (\text{deltas de Kronecker})$$

$$\text{y } \frac{\partial}{\partial \theta_\beta} E_\theta(U_\alpha) = \frac{\partial}{\partial \theta_\beta} \int_{X^n} U_\alpha(x_1, \dots, x_n) \tilde{f}(x_1, \dots, x_n, \theta) dx_1 \dots dx_n$$

$$\begin{aligned} &= \int_{X^n} U_\alpha(x_1, \dots, x_n) \frac{\partial \ln \tilde{f}(x_1, \dots, x_n, \theta)}{\partial \theta_\beta} \tilde{f}(x_1, \dots, x_n) dx_1 \dots dx_n = \\ &= E_\theta \left(U_\alpha(X_1, \dots, X_n) \frac{\partial \ln \tilde{f}(X_1, \dots, X_n, \theta)}{\partial \theta_\beta} \right) \end{aligned}$$

asumimos las condiciones de regularidad necesarias para garantizar

Por tanto tendremos:

$$\frac{\partial}{\partial \theta_\beta} B_\alpha(\theta) + \delta_{\alpha\beta} = E_\theta \left(u_\alpha(x_1, \dots, x_m) \frac{\partial \ln \tilde{f}(x_1, \dots, x_m, \theta)}{\partial \theta_\beta} \right)$$

pero como

$$\begin{aligned} E_\theta \left(\frac{\partial \ln \tilde{f}(x_1, \dots, x_m, \theta)}{\partial \theta_\beta} \right) &= \int_{\mathcal{X}^m} \frac{\partial \ln \tilde{f}(x_1, \dots, x_m, \theta)}{\partial \theta_\beta} \tilde{f}(x_1, \dots, x_m, \theta) dx_1 \dots dx_m = \\ &= \int_{\mathcal{X}^m} \frac{\partial \tilde{f}(x_1, \dots, x_m, \theta)}{\partial \theta_\beta} dx_1 \dots dx_m = \\ &= \frac{\partial}{\partial \theta_\beta} \underbrace{\left(\int_{\mathcal{X}^m} \tilde{f}(x_1, \dots, x_m, \theta) dx_1 \dots dx_m \right)}_{=1} = 0 \end{aligned}$$

tendremos que

$$E_\theta \left(u_\alpha(x_1, \dots, x_m) \frac{\partial \ln \tilde{f}(x_1, \dots, x_m, \theta)}{\partial \theta_\beta} \right) = E_\theta \left((u_\alpha(x_1, \dots, x_m) - \theta_\alpha - B_\alpha(\theta)) \frac{\partial \ln \tilde{f}(x_1, \dots, x_m, \theta)}{\partial \theta_\beta} \right)$$

ya que θ_α y $B_\alpha(\theta)$ no dependen de x_1, \dots, x_m y pueden "salir fuera" de la esperanza al desarrollar el término derecho.
por tanto, de momento, podemos escribir:

$$\frac{\partial}{\partial \theta_\beta} B_\alpha(\theta) + \delta_{\alpha\beta} = E_\theta \left((u_\alpha(x_1, \dots, x_m) - \theta_\alpha - B_\alpha(\theta)) \frac{\partial \ln \tilde{f}(x_1, \dots, x_m, \theta)}{\partial \theta_\beta} \right) \quad (1)$$

A partir de esta expresión tendremos:

$$\sum_{\alpha=1}^m \left\{ \frac{\partial}{\partial \theta_\alpha} B_\alpha(\theta) + \underbrace{\delta_{\alpha\alpha}}_{=1} \right\} = \sum_{\alpha=1}^m E_\theta \left((u_\alpha - \theta_\alpha - B_\alpha(\theta)) \frac{\partial \ln \tilde{f}(x_1, \dots, x_m, \theta)}{\partial \theta_\alpha} \right)$$

$$\left(\sum_{\alpha=1}^m \frac{\partial}{\partial \theta_\alpha} B_\alpha(\theta) \right) + m = E_\theta \left(\sum_{\alpha=1}^m (u_\alpha - \theta_\alpha - B_\alpha(\theta)) \frac{\partial \ln \tilde{f}(x_1, \dots, x_m, \theta)}{\partial \theta_\alpha} \right)$$

Si introducimos el vector columna:

$$\frac{\partial \ln \tilde{f}(x_1, \dots, x_m, \theta)}{\partial \theta} = \begin{pmatrix} \frac{\partial \ln \tilde{f}(x_1, \dots, x_m, \theta)}{\partial \theta_1} \\ \vdots \\ \frac{\partial \ln \tilde{f}(x_1, \dots, x_m, \theta)}{\partial \theta_m} \end{pmatrix}$$

podemos observar que:

$$\sum_{\alpha=1}^m (U_{\alpha} - \theta_{\alpha} - B_{\alpha}(\theta)) \frac{\partial \ln \tilde{f}(x_1, \dots, x_m, \theta)}{\partial \theta_{\alpha}} = (U - \theta - B(\theta)) \cdot \frac{\partial \ln \tilde{f}(x_1, \dots, x_m, \theta)}{\partial \theta}$$

↑
producto escalar

por lo que tendremos:

$$m + \sum_{\alpha=1}^m \frac{\partial}{\partial \theta_{\alpha}} B_{\alpha}(\theta) = E_{\theta} \left((U - \theta - B(\theta)) \cdot \frac{\partial \ln \tilde{f}(x_1, \dots, x_m, \theta)}{\partial \theta} \right) \quad (2)$$

Recordemos que dados dos vectores $|V \cdot W| \leq \|V\| \|W\|$

(Desigualdad de
Cauchy-Schwarz)

por tanto:

$$\begin{aligned} \left| m + \sum_{\alpha=1}^m \frac{\partial}{\partial \theta_{\alpha}} B_{\alpha}(\theta) \right| &= \left| E_{\theta} \left((U - \theta - B(\theta)) \cdot \frac{\partial \ln \tilde{f}(x_1, \dots, x_m, \theta)}{\partial \theta} \right) \right| \\ &\leq E_{\theta} \left(\left| (U - \theta - B(\theta)) \cdot \frac{\partial \ln \tilde{f}(x_1, \dots, x_m, \theta)}{\partial \theta} \right| \right) \\ &\quad \uparrow \\ &\text{ya que } |E(X)| \leq E(|X|) \quad (\text{siempre que } E(|X|) \text{ exista}) \end{aligned}$$

$$\leq E_{\theta} \left(\|U - \theta - B(\theta)\| \left\| \frac{\partial \ln \tilde{f}(x_1, \dots, x_m, \theta)}{\partial \theta} \right\| \right)$$

↑
Cauchy-Schwarz

$$\leq \sqrt{E_{\theta}(\|U - \theta - B(\theta)\|^2)} \sqrt{E_{\theta}(\left\| \frac{\partial \ln \tilde{f}(x_1, \dots, x_m, \theta)}{\partial \theta} \right\|^2)}$$

↑
Cauchy-Schwarz de nuevo:

$$|E(XY)| \leq \sqrt{E(X^2)} \sqrt{E(Y^2)}$$

la "esperanza del producto"
es un producto escalar
en un espacio vectorial
conveniente de variables aleatorias

Elevando al cuadrado:

$$\left(n + \sum_{\alpha=1}^m \frac{\partial}{\partial \theta_{\alpha}} B_{\alpha}(\theta) \right)^2 \leq E_{\theta} \left(\| u - \theta - B(\theta) \|^2 \right) E_{\theta} \left(\left\| \frac{\partial \ln \tilde{f}(x_1 - x_m, \theta)}{\partial \theta} \right\|^2 \right) \quad (3)$$

pero:

$$\| u - \theta - B(\theta) \|^2 = \| u - \theta \|^2 + \| B(\theta) \|^2 - 2(u - \theta) \cdot B(\theta)$$

y al tomar esperanza, teniendo en cuenta que $E_{\theta}(u - \theta) = B(\theta)$

$$\| B(\theta) \|^2 = B(\theta) \cdot B(\theta) \quad \text{resultará:}$$

$$E_{\theta} \left(\| u - \theta - B(\theta) \|^2 \right) = E_{\theta} \left(\| u - \theta \|^2 \right) - \| B(\theta) \|^2 \quad (4)$$

pero $E_{\theta} \left(\| u - \theta \|^2 \right)$

es el error cuadrático medio del estimador

Introducamos ahora la denominada matriz de información de Fisher correspondiente a X . Es una matriz $m \times m$

$$I(\theta) = (I_{ij}(\theta))_{m \times m} \quad \text{definida por} \quad I_{ij}(\theta) = E_{\theta} \left(\frac{\partial \ln f(x, \theta)}{\partial \theta_i} \frac{\partial \ln f(x, \theta)}{\partial \theta_j} \right)$$

y la matriz de información de Fisher correspondiente a toda la muestra:

$$\tilde{I}(\theta) = (\tilde{I}_{ij}(\theta))_{m \times m} \quad \text{tal que} \quad \tilde{I}_{ij}(\theta) = E_{\theta} \left(\frac{\partial \ln \tilde{f}(x_1 - x_m, \theta)}{\partial \theta_i} \frac{\partial \ln \tilde{f}(x_1 - x_m, \theta)}{\partial \theta_j} \right)$$

observar que $I(\theta)$ y $\tilde{I}(\theta)$ son simétricas.

Observar que al ser $\tilde{f}(x_1 - x_m, \theta) = f(x_1, \theta) \cdot \dots \cdot f(x_m, \theta)$

tendremos que

$$\frac{\partial \ln \tilde{f}(x_1 - x_m, \theta)}{\partial \theta_i} = \sum_{\lambda=1}^m \frac{\partial \ln f(x_{\lambda}, \theta)}{\partial \theta_i}$$

y por tanto:

$$\tilde{I}_{ij}(\theta) = E_{\theta} \left(\left\{ \sum_{\lambda=1}^m \frac{\partial \ln f(x_{\lambda}, \theta)}{\partial \theta_i} \right\} \left\{ \sum_{r=1}^m \frac{\partial \ln f(x_r, \theta)}{\partial \theta_j} \right\} \right) = \sum_{\lambda=1}^m \sum_{r=1}^m E_{\theta} \left(\frac{\partial \ln f(x_{\lambda}, \theta)}{\partial \theta_i} \frac{\partial \ln f(x_r, \theta)}{\partial \theta_j} \right),$$

Observación:

No confundir la matriz de información de Fisher $I(\theta)$, $\tilde{I}(\theta)$, I_{θ} , \tilde{I}_{θ} con la matriz identidad I o I_m

pero $\frac{\partial \ln f(x_\lambda, \theta)}{\partial \theta_i}$ y $\frac{\partial \ln f(x_\gamma, \theta)}{\partial \theta_j}$ son independientes si $\lambda \neq \gamma$

-5-

por tanto, teniendo en cuenta que

$$\begin{aligned} E_\theta \left(\frac{\partial \ln f(x, \theta)}{\partial \theta_i} \right) &= \int \frac{\partial \ln f(x, \theta)}{\partial \theta_i} f(x, \theta) dx = \int \frac{\partial f(x, \theta)}{\partial \theta_i} dx = \\ &= \frac{\partial}{\partial \theta_i} \underbrace{\int f(x, \theta) dx}_{=1} = 0 \end{aligned}$$

resultará:

$$\begin{aligned} \tilde{I}_{ij}(\theta) &= \sum_{\lambda=1}^m E_\theta \left(\frac{\partial \ln f(x_\lambda, \theta)}{\partial \theta_i} \frac{\partial \ln f(x_\lambda, \theta)}{\partial \theta_j} \right) = \\ &= \sum_{\lambda=1}^m I_{ij}(\theta) = n I_{ij}(\theta) \quad (5) \end{aligned}$$

Por tanto:

$$\begin{aligned} E_\theta \left(\left\| \frac{\partial \ln \tilde{f}(x_1 - x_m, \theta)}{\partial \theta} \right\|^2 \right) &= E_\theta \left(\sum_{\alpha=1}^m \left(\frac{\partial \ln \tilde{f}(x_1 - x_m, \theta)}{\partial \theta_\alpha} \right)^2 \right) = \\ &= \sum_{\alpha=1}^m E_\theta \left(\left(\frac{\partial \ln \tilde{f}(x_1 - x_m, \theta)}{\partial \theta_\alpha} \right)^2 \right) \\ &= \sum_{\alpha=1}^m \tilde{I}_{\alpha\alpha}(\theta) = \sum_{\alpha=1}^m n I_{\alpha\alpha}(\theta) \\ &= n \operatorname{tr}(I(\theta)) \quad (6) \end{aligned}$$

Si combinamos ahora (3), (4) y (6) obtendremos

$$\left(m + \sum_{\alpha=1}^m \frac{\partial}{\partial \theta_\alpha} B_\alpha(\theta) \right)^2 \leq (E_\theta(\|u - \theta\|^2) - \|B(\theta)\|^2) n \operatorname{tr}(I(\theta))$$

igual a:

$$E_{\theta}(\|u - \theta\|^2) \geq \|B(\theta)\|^2 + \frac{\left(m + \sum_{\alpha=1}^m \frac{\partial}{\partial \theta_{\alpha}} B_{\alpha}(\theta)\right)^2}{n \operatorname{tr}(I(\theta))} \quad (7)$$

Como

$$E_{\theta}(\|u - \theta\|^2) = \underbrace{\operatorname{tr}(\operatorname{cov}_{\theta}(u))}_{\text{error cuadrático medido}} + \|B(\theta)\|^2$$

podemos escribir también:

Observen que:

$$E_{\theta}(\|u - \theta\|^2) = E_{\theta}(\|u - E_{\theta}(u) + E_{\theta}(u) - \theta\|^2) =$$

$$= E_{\theta}(\|u - E_{\theta}(u) + B(\theta)\|^2) = E_{\theta}(\|u - E_{\theta}(u)\|^2) + \|B(\theta)\|^2$$

$$\text{pero } E_{\theta}(\|u - E_{\theta}(u)\|^2) = E_{\theta}(\operatorname{tr}((u - E_{\theta}(u))(u - E_{\theta}(u))^t)) = \operatorname{tr} E_{\theta}((u - E_{\theta}(u))(u - E_{\theta}(u))^t) = \operatorname{tr}(\operatorname{cov}_{\theta}(u))$$

$$\operatorname{tr}(\operatorname{cov}_{\theta}(u)) \geq \frac{\left(m + \sum_{\alpha=1}^m \frac{\partial}{\partial \theta_{\alpha}} B_{\alpha}(\theta)\right)^2}{n \operatorname{tr}(I(\theta))} \quad (8)$$

Consideremos el caso particular u insesgado. Entonces

$$B(\theta) = 0 \quad \frac{\partial B_{\alpha}(\theta)}{\partial \theta_{\alpha}} = 0 \quad \text{y tendremos:}$$

$$E_{\theta}(\|u - \theta\|^2) \geq \frac{m^2}{n \operatorname{tr}(I(\theta))} \quad (9)$$

• bien:

$$\operatorname{tr}(\operatorname{cov}_{\theta}(u)) \geq \frac{m^2}{n \operatorname{tr}(I(\theta))} \quad (10)$$

Otro caso particular: si θ es unidimensional, $m=1$, entonces:

$\operatorname{cov}_{\theta}(u) = \operatorname{var}_{\theta}(u)$ (la matriz de covarianzas es 1×1 y su único elemento es la varianza de $u = (u_1)$ (no pondremos subíndice a u ya que sólo tiene una componente))

$$I(\theta) = (I_{11}(\theta))$$

$$I(\theta) = E_{\theta}\left(\left(\frac{\partial \ln f(x, \theta)}{\partial \theta}\right)^2\right)$$

$$B'(\theta) = \partial B_1(\theta) / \partial \theta_1$$

(no pondremos índices a θ ni a $I(\theta)$, ni a $B(\theta)$)

Por tanto para $m=1$ tendremos:

$$E_{\theta}((u-\theta)^2) \geq B(\theta)^2 + \frac{(1+B'(\theta))^2}{n I(\theta)} \quad (11)$$

o bien:

$$\text{var}_{\theta}(u) \geq \frac{(1+B'(\theta))^2}{n I(\theta)} \quad (12)$$

Si además u es insesgado:

$$E_{\theta}((u-\theta)^2) = \text{var}_{\theta}(u) \geq \frac{1}{n I(\theta)} \quad (13)$$

Las expresiones (12) y (13) son las conocidas desigualdades (para $m=1$) de Cramér-Rao, y las cotas inferiores correspondientes se conocen como cotas de Cramér-Rao. Para el caso multidimensional tendremos las expresiones (7), (8) y (9) o (10).

Para llegar a estas expresiones hemos requerido ciertas "condiciones de regularidad" para el modelo: soporte independiente del parámetro θ , derivadas parciales de f respecto θ_{α} existentes, información de Fisher existente, etc..

NOTA adicional I:

En cálculo vectorial, dado un vector $(Y_1(x_1, \dots, x_m), \dots, Y_m(x_1, \dots, x_m))$ se define el operador "divergencia del vector" (respecto un sistema de coordenadas cartesianas) como:

$$\text{div } Y = \sum_{\alpha=1}^m \frac{\partial Y_{\alpha}}{\partial x_{\alpha}}$$

desde esta óptica, la expresión $\sum_{\alpha=1}^m \frac{\partial}{\partial \theta_{\alpha}} B_{\alpha}(\theta)$ puede ser entendida como la "divergencia del sesgo"

$$\text{div } B = \sum_{\alpha=1}^m \frac{\partial}{\partial \theta_{\alpha}} B_{\alpha}(\theta)$$

podiendo escribir (7), (8) de forma más compacta como:

$$E_{\theta}(\|u - \theta\|^2) \geq \|B_{\theta}\|^2 + \frac{(m + \text{div}(B_{\theta}))^2}{n \text{tr}(I_{\theta})} \quad (14)$$

donde hemos escrito B_{θ} y I_{θ} en vez de $B(\theta)$ y $I(\theta)$ por simplificar la notación. También:

$$\text{tr}(\text{cov}_{\theta}(u)) \geq \frac{(m + \text{div}(B_{\theta}))^2}{n \text{tr}(I_{\theta})} \quad (15)$$

Nota adicional II:

En el caso multidimensional, $m > 1$, las desigualdades de Cramer-Rao pueden expresarse de forma matricial.

Si introducimos la matriz Δ $m \times m$ definida por

$$\Delta_{\theta} = \left(\frac{\partial}{\partial \theta_{\beta}} B_{\alpha}(\theta) + \delta_{\alpha\beta} \right) \quad (\text{ver (1)}) \quad \begin{array}{l} \alpha \text{ índice de fila} \\ \beta \text{ índice de columna} \end{array}$$

podemos reescribir (1) en forma matricial como

$$\begin{aligned} \Delta_{\theta} &= E_{\theta} \left((u - \theta - B(\theta)) \left(\frac{\partial \ln \tilde{f}(x_1, \dots, x_m, \theta)}{\partial \theta} \right)^t \right) = \\ &= E_{\theta} \left(u \left(\frac{\partial \ln \tilde{f}(x_1, \dots, x_m, \theta)}{\partial \theta} \right)^t \right) \end{aligned}$$

Si definimos el vector Y , $m \times 1$, igual a:

$$Y = u - \Delta_{\theta} \tilde{I}^{-1}(\theta) \frac{\partial \ln \tilde{f}(x_1, \dots, x_m, \theta)}{\partial \theta}$$

donde suponemos implícitamente que $\tilde{I}(\theta)$ posee inversa.

Por otra parte sabemos que dados dos vectores aleatorios V y W

resulta:

$$\begin{aligned} \text{cov}(V+W) &= \text{cov}(V) + \text{cov}(W) + E \left((V - E(V)) (W - E(W))^t \right) \\ &\quad + E \left((W - E(W)) (V - E(V))^t \right) \end{aligned}$$

siempre que éstas existan.

Por tanto tendremos:

$$\begin{aligned} \text{cov}_\theta(Y) &= \text{cov}_\theta(u) + \text{cov}_\theta\left(\Delta_\theta \tilde{I}^{-1}(\theta) \frac{\partial \ln \tilde{f}(x_1 - x_n, \theta)}{\partial \theta}\right) \\ &\quad - E_\theta\left(u \left(\frac{\partial \ln \tilde{f}(x_1 - x_n, \theta)}{\partial \theta}\right)^t \tilde{I}^{-1}(\theta) \Delta_\theta^t\right) \\ &\quad - E_\theta\left(\Delta_\theta \tilde{I}^{-1}(\theta) \frac{\partial \ln \tilde{f}(x_1 - x_n, \theta)}{\partial \theta} u^t\right) \end{aligned}$$

pero

$$\begin{aligned} \text{cov}_\theta\left(\Delta_\theta \tilde{I}^{-1}(\theta) \frac{\partial \ln \tilde{f}(x_1 - x_n, \theta)}{\partial \theta}\right) &= E_\theta\left(\Delta_\theta \tilde{I}^{-1}(\theta) \frac{\partial \ln \tilde{f}(x_1 - x_n, \theta)}{\partial \theta} \cdot \left(\frac{\partial \ln \tilde{f}(x_1 - x_n, \theta)}{\partial \theta}\right)^t \tilde{I}^{-1}(\theta) \Delta_\theta^t\right) \\ &= \Delta_\theta \tilde{I}^{-1}(\theta) E_\theta\left(\underbrace{\frac{\partial \ln \tilde{f}(x_1 - x_n, \theta)}{\partial \theta} \left(\frac{\partial \ln \tilde{f}(x_1 - x_n, \theta)}{\partial \theta}\right)^t}_{\tilde{I}(\theta)}\right) \tilde{I}^{-1}(\theta) \Delta_\theta^t \\ &= \Delta_\theta \tilde{I}_\theta^{-1} \Delta_\theta^t \end{aligned}$$

mientras que

$$\begin{aligned} E_\theta\left(u \left(\frac{\partial \ln \tilde{f}(x_1 - x_n, \theta)}{\partial \theta}\right)^t \tilde{I}^{-1}(\theta) \Delta_\theta^t\right) &= \\ &= E_\theta\left(u \left(\frac{\partial \ln \tilde{f}(x_1 - x_n, \theta)}{\partial \theta}\right)^t\right) \tilde{I}^{-1}(\theta) \Delta_\theta^t = \\ &= \Delta_\theta \tilde{I}^{-1}(\theta) \Delta_\theta^t \end{aligned}$$

y su transpuesta

$$E_\theta\left(\Delta_\theta \tilde{I}^{-1}(\theta) \frac{\partial \ln \tilde{f}(x_1 - x_n, \theta)}{\partial \theta} u^t\right) = \Delta_\theta \tilde{I}^{-1}(\theta) \Delta_\theta^t$$

Por tanto:

$$\text{cov}_\theta(Y) = \text{cov}_\theta(u) - \Delta_\theta \tilde{I}^{-1}(\theta) \Delta_\theta^t$$

Además, como $\tilde{I}(\theta) = n I(\theta)$ resulta que

$$\tilde{I}(\theta)^{-1} = \frac{1}{n} I(\theta)^{-1}$$

Al ser $\text{cov}_\theta(Y)$, como cualquier matriz de covarianzas, definida o semidefinida positiva, tendremos:

$$0 \leq \text{cov}_\theta(Y) = \text{cov}_\theta(U) - \frac{1}{n} \Delta_\theta I(\theta)^{-1} \Delta_\theta^t$$

o de forma equivalente

$$\text{cov}_\theta(U) \geq \frac{1}{n} \Delta_\theta I_\theta^{-1} \Delta_\theta^t \quad (16)$$

donde hemos escrito I_θ en vez de $I(\theta)$ por simplicidad.

En el caso que U sea insesgado, $\Delta_\theta = I_m$ (la identidad $m \times m$) por tanto tendremos:

$$\text{cov}_\theta(U) \geq \frac{1}{n} I_\theta^{-1} \quad (17)$$

OBSERVACION :

Si A y B son matrices simétricas $A \leq B \Leftrightarrow B - A$ es definida o semidefinida positiva (valores propios no negativos
 $x^t (B - A) x \geq 0 \quad \forall x$ vector $m \times 1$)

OBSERVACION FINAL :

Puede comprobarse que si U es tal que puede escribirse como:

$$\sum_{i=1}^m \frac{\partial \ln f(x_i, \theta)}{\partial \theta} = K(\theta, n) (U(x_1 \dots x_n) - \theta) \quad (18)$$

donde K es una matriz $m \times m$ no singular, entonces:

U es insesgado para θ y además alcanza la cota de Cramér-Rao

Observar que si se cumple (18), como

$$E_{\theta} \left(\frac{\partial \ln f(x_i, \theta)}{\partial \theta} \right) = 0 \quad \text{resulta}$$

$$0 = E_{\theta} (K(\theta, m) (U(x_1 - x_m) - \theta)) = K(\theta, m) (E_{\theta} (U(x_1 - x_m)) - \theta)$$

por tanto al ser $K(\theta, m)$ regular,

$$0 = E_{\theta} (U(x_1 - x_m)) - \theta = B(\theta)$$

U es insesgado: $B(\theta) = 0$ y Δ_{θ} , la matriz introducida en la página 8, es $\Delta_{\theta} = I_m$ (identidad $m \times m$)

Además, observar que

$$\sum_{i=1}^n \frac{\partial \ln f(x_i, \theta)}{\partial \theta} = \frac{\partial \ln \tilde{f}(x_1 \dots x_m, \theta)}{\partial \theta}$$

↓ no confundir con la matriz de información de Fisher I_{θ} , etc.

por tanto, tomando covarianzas tendremos:

$$\begin{aligned} \text{cov}_{\theta} \left(\frac{\partial \ln \tilde{f}(x_1 \dots x_m, \theta)}{\partial \theta} \right) &= E_{\theta} \left(\frac{\partial \ln \tilde{f}(x_1 \dots x_m, \theta)}{\partial \theta} \left(\frac{\partial \ln \tilde{f}(x_1 \dots x_m, \theta)}{\partial \theta} \right)^t \right) \\ &= \tilde{I}(\theta) \end{aligned}$$

(ya que $E_{\theta} \left(\frac{\partial \ln \tilde{f}(x_1 \dots x_m, \theta)}{\partial \theta} \right) = 0$)

por tanto

$$\tilde{I}(\theta) = \text{cov}_{\theta} (K(\theta, m) (U(x_1 - x_m) - \theta)) =$$

$$= \text{cov}_{\theta} (K(\theta, m) U(x_1 - x_m)) =$$

$$= K(\theta, m) \text{cov}_{\theta}(U) K(\theta, m)^t \quad (19)$$

(recordar $\text{cov}(Ax + c) = A \text{cov}(x) A^t$)
si A y c son constantes: no dependen de la v.a. x

Por otra parte, de (18) obtenemos:

$$\frac{\partial \ln \tilde{f}(x_1 \dots x_m, \theta)}{\partial \theta} \left(\frac{\partial \ln \tilde{f}(x_1 \dots x_m, \theta)}{\partial \theta} \right)^t = K(\theta, m) (U(x_1 - x_m) - \theta) \left(\frac{\partial \ln f(x_1 - x_m, \theta)}{\partial \theta} \right)^t$$

tomando esperanzas:

$$\tilde{I}(\theta) = K(\theta, m) E_{\theta} \left((U(x_1 - x_m) - \theta) \left(\frac{\partial \ln f(x_1 - x_m, \theta)}{\partial \theta} \right)^t \right) \quad (20)$$

Escribiendo matricialmente (1), teniendo en cuenta que $B(\theta) = 0$ y $\Delta_m = I$, resulta:

$$I_m = E_{\theta} \left((u - \theta) \left(\frac{\partial \ln \tilde{f}(x_1, \dots, x_n, \theta)}{\partial \theta} \right)^t \right) \quad (21)$$

por tanto combinando (20) y (21) resulta:

$$\tilde{I}(\theta) = K(\theta, n) \overset{\text{matriz identidad}}{I_m} = K(\theta, n) \quad (22)$$

En otras palabras, si u satisface la condición (18) concluimos que u es insesgado y $\text{cov}_{\theta}(u) = \tilde{I}_{\theta}^{-1} = \frac{1}{n} I_{\theta}^{-1}$

NOTA: observar que si se cumple (18), entonces

$$\underline{K(\theta, n) = \tilde{I}(\theta) = n I(\theta)} \quad (23)$$