

Suficiencia

Sea X una variable aleatoria k -dimensional con función de densidad $f(x, \theta)$ (discreta o absolutamente continua) donde, para fijar ideas, $x \in \mathbb{R}^k$, $\theta \in \Theta \subset \mathbb{R}^m$.

Sean X_1, \dots, X_n iid X (variables aleatorias muestrales, correspondientes a una muestra aleatoria simple de tamaño n)

Definición 1

Sea $T = T(X_1, \dots, X_n)$ un estadístico (posiblemente multidimensional). Diremos que T es suficiente para el modelo (o para el parámetro θ) si y sólo si la distribución conjunta de (X_1, \dots, X_n) condicionada a T no depende de θ .

Definición 2 (equivalente)

Sea $S = S(X_1, \dots, X_n)$ un estadístico cualquiera. Diremos que T es suficiente para el modelo si y sólo si $E_\theta(S|T)$ (la esperanza de S condicionada a T) no depende del parámetro θ , sea cual sea el estadístico S .

Interpretación:

Si la distribución conjunta de (X_1, \dots, X_n) condicionada a T no depende de θ , significa que conociendo T , el conocimiento de X_1, \dots, X_n no aporta información suplementaria sobre θ .

Ejemplo 1:

Sea $X \sim \text{Poisson}(\lambda)$ $\lambda > 0$. Comprobar que $T = \sum_{i=1}^n X_i$ es suficiente para dicho modelo.

Hemos de hallar la ley conjunta de (X_1, \dots, X_n) condicionada a T . Puesto que en este caso la distribución conjunta es discreta, las densidades de probabilidad son simplemente probabilidades condicionadas:

$$\underbrace{\tilde{f}(x_1, \dots, x_n, \lambda)}_{\text{densidad conjunta}} = \prod_{i=1}^n \left(e^{-\lambda} \frac{\lambda^{x_i}}{x_i!} \right) = e^{-n\lambda} \frac{\lambda^{\sum_{i=1}^n x_i}}{x_1! \cdot \dots \cdot x_n!}$$

$$P_\lambda(X_1 = x_1, \dots, X_n = x_n) = P_\lambda([X_1 = x_1] \cap [X_2 = x_2] \cap \dots \cap [X_n = x_n])$$

Sucesos independientes

siempre que $(x_1, \dots, x_n) \in \mathbb{N}^n$
(cero en caso contrario)

Para calcular la conjunta x_1, \dots, x_m condicionada a T , tendremos que calcular:

$$\begin{aligned} \tilde{f}_{(x_1, \dots, x_m) | T}(x_1, \dots, x_m, \lambda) &= P_\lambda([X_1 = x_1] \cap \dots \cap [X_m = x_m] | [T = t]) \\ &= \frac{P_\lambda([X_1 = x_1] \cap \dots \cap [X_m = x_m] \cap [T = t])}{P_\lambda(T = t)} \quad (1) \end{aligned}$$

para $(x_1, \dots, x_m) \in \mathbb{N}^m$ y $t \in \mathbb{N}$ (podemos elegir $\tilde{f}_{(x_1, \dots, x_m) | T}$ igual a cero en caso contrario).

Observar que $T = \sum_{i=1}^m X_i$, al ser suma de distribuciones de Poisson independientes, seguirá una distribución de Poisson de parámetro suma de parámetros: $m\lambda$

Por tanto: $P_\lambda(T = t) = e^{-m\lambda} \frac{(m\lambda)^t}{t!}$

Por otra parte, si $\sum_{i=1}^m x_i = t$, entonces $[X_1 = x_1] \cap \dots \cap [X_m = x_m] \subset [T = t]$

y por tanto al ser $[X_1 = x_1] \cap \dots \cap [X_m = x_m] \cap [T = t] = [X_1 = x_1] \cap \dots \cap [X_m = x_m]$ tendremos:

$$\tilde{f}_{(x_1, \dots, x_m) | T}(x_1, \dots, x_m, \lambda) = \frac{P_\lambda([X_1 = x_1] \cap \dots \cap [X_m = x_m])}{P_\lambda(T = t)}$$

$$= \frac{P_\lambda(X_1 = x_1) P_\lambda(X_2 = x_2) \dots P_\lambda(X_m = x_m)}{P_\lambda(T = t)}$$

$$= \frac{e^{-\lambda} \frac{\lambda^{x_1}}{x_1!} e^{-\lambda} \frac{\lambda^{x_2}}{x_2!} \dots e^{-\lambda} \frac{\lambda^{x_m}}{x_m!}}{e^{-m\lambda} \frac{(m\lambda)^t}{t!}}$$

$$= \frac{e^{-m\lambda} \lambda^{\sum_{i=1}^m x_i} t!}{x_1! \dots x_m! e^{-m\lambda} (m\lambda)^t} = \frac{t!}{x_1! \dots x_m!} \left(\frac{1}{m}\right)^t$$

(ya que $\sum_{i=1}^m x_i = t$)

y en el caso de que $\sum_{i=1}^m x_i \neq t$ entonces:

$$\underline{[X_1 = x_1] \cap \dots \cap [X_m = x_m] \cap [T = t] = \emptyset}$$

y por tanto $\tilde{f}_{(x_1, \dots, x_m) | T} = 0$

En resumen, la densidad condicionada de (X_1, \dots, X_m) dado T es:

$$\tilde{f}_{(x_1, \dots, x_m) | T=t}(x_1, \dots, x_m) = \frac{t!}{x_1! \dots x_m!} \left(\frac{1}{m}\right)^t \quad (2)$$

siempre que $(x_1, \dots, x_m) \in \mathbb{N}^m$ y $t = \sum_{i=1}^m x_i$

y cero en caso contrario. Observar que dicha densidad no depende de λ : por tanto T es un estadístico suficiente para el modelo Poisson.

Para determinar si un estadístico es suficiente tenemos el criterio de factorización de Neyman-Fisher:

Si la función de densidad conjunta de la muestra (X_1, \dots, X_m) puede factorizarse como:

$$\tilde{f}(x_1, \dots, x_m, \theta) = g(T(x_1, \dots, x_m), \theta) h(x_1, \dots, x_m) \quad (3)$$

\swarrow función de $T(x_1, \dots, x_m)$ y θ \swarrow función sólo de x_1, \dots, x_m

entonces el estadístico: $T = T(x_1, \dots, x_m)$ es un estadístico suficiente para el modelo considerado (o para θ).

Ejemplo 2:

$X \sim$ Poisson de parámetro λ . Entonces, teniendo en cuenta (1)

tenemos:

$$\tilde{f}(x_1, \dots, x_m, \lambda) = e^{-m\lambda} \lambda^{\sum_{i=1}^m x_i} \frac{1}{x_1! \dots x_m!} \quad (4)$$

Si introducimos:

$$T(x_1, \dots, x_m) = \sum_{i=1}^m x_i \quad h(x_1, \dots, x_m) = \frac{1}{x_1! \dots x_m!}$$

$$y \quad g(T(x_1, \dots, x_n), \lambda) = e^{-n\lambda} \lambda^{T(x_1, \dots, x_n)}$$

resulta que (4) puede escribirse como:

$$\tilde{f}(x_1, \dots, x_n, \lambda) = g\left(\sum_{i=1}^n x_i, \lambda\right) h(x_1, \dots, x_n)$$

y por el criterio de factorización de Neyman-Fisher podemos separar que $T(x_1, \dots, x_n) = \sum_{i=1}^n x_i$ es un estadístico suficiente para el modelo (ya lo habíamos comprobado a partir de la definición)

Ejemplo 3:

$X \sim \text{Uniforme}(\alpha, \beta) \quad \alpha < \beta$

$$f(x, \alpha, \beta) = \frac{1}{\beta - \alpha} \mathbb{1}_{[\alpha, \beta]}(x)$$

recordar

$$\mathbb{1}_A(x) = \begin{cases} 1 & \Leftrightarrow x \in A \\ 0 & \Leftrightarrow x \notin A \end{cases}$$

$$\tilde{f}(x_1, \dots, x_n, \alpha, \beta) = \prod_{i=1}^n \left(\frac{1}{\beta - \alpha} \mathbb{1}_{[\alpha, \beta]}(x_i) \right) = \frac{1}{(\beta - \alpha)^n} \mathbb{1}_{(-\infty, \beta]}(x_{(n)}) \cdot \mathbb{1}_{[\alpha, \infty)}(x_{(1)})$$

si introducimos $h(x_1, \dots, x_n) = 1$

$$g((x_{(1)}, x_{(n)}), (\alpha, \beta)) = \frac{1}{(\beta - \alpha)^n} \mathbb{1}_{(-\infty, \beta]}(x_{(n)}) \mathbb{1}_{[\alpha, \infty)}(x_{(1)})$$

resulta que

$$\tilde{f}(x_1, \dots, x_n, \alpha, \beta) = g\left(\underbrace{(x_{(1)}, x_{(n)})}_{T(x_1, \dots, x_n)}, (\alpha, \beta)\right) h(x_1, \dots, x_n)$$

Por tanto el estadístico:

$$T = T(x_1, \dots, x_n) = (x_{(1)}, x_{(n)}) = (\min\{x_1, \dots, x_n\}, \max\{x_1, \dots, x_n\})$$

es un estadístico suficiente para el modelo Uniforme entre α y β .

Teorema de Rao-Blackwell

$$X \sim f(x, \theta) \quad x \in \mathbb{R}^k \quad \theta \in \Theta \subset \mathbb{R}^m$$

X_1, \dots, X_n iid X (las variables aleatorias muestrales de una muestra aleatoria simple de tamaño n)

Sea $T = T(X_1, \dots, X_n)$ un estadístico suficiente para el modelo

Sea $U = U(X_1, \dots, X_n)$ un estimador insesgado de $\psi(\theta)$ una función paramétrica de θ (posiblemente multidimensional), entonces

$\varphi(T) \equiv E_\theta(U|T)$ es un estadístico insesgado de $\psi(\theta)$

y además: (observar que $\varphi(T)$ no depende de θ ya que T es un estadístico suficiente)

$$E_\theta(\|\varphi(T) - \psi(\theta)\|^2) \leq E_\theta(\|U - \psi(\theta)\|^2) \quad (4)$$

(en particular si $\psi(\theta)$ es unidimensional podemos escribir:

$$\text{Var}_\theta(\varphi(T)) \leq \text{Var}_\theta(U)$$

Interpretación:

El Teorema de Rao-Blackwell permite obtener, a partir de un estimador insesgado de $\psi(\theta)$, otro estimador insesgado de $\psi(\theta)$ con riesgo (error cuadrático medio) menor. (Mejora de Rao-Blackwell)

Observar que $\varphi(T)$ no puede ser mejorado aplicando de nuevo

Rao-Blackwell pues $E_\theta(\varphi(T)|T) = \varphi(T)$

Si se exige una nueva propiedad al estadístico T entonces podremos asegurar algo más: que la mejora obtenida por Rao-Blackwell es óptima. Previamente:
(y, esencialmente, única)

Definición 3

Sea $X \sim f(x, \theta) \quad x \in \mathbb{R}^k, \theta \in \Theta \subset \mathbb{R}^m \quad X_1, \dots, X_n$ iid X

$S = S(X_1, \dots, X_n)$ un estadístico diremos que es completo para el modelo anterior si y sólo si se cumple la propiedad siguiente:

$$E_\theta(\varphi(S)) = 0 \quad \forall \theta \in \Theta \Rightarrow \varphi(S) = 0 \text{ con probabilidad 1 (5)} \\ (\text{o bien casi seguramente})$$

Ejemplo 4:

$X \sim \text{Poisson}$ de parámetro λ X_1, \dots, X_n i.i.d X

Si $T = T(X_1, \dots, X_n) = \sum_{i=1}^n X_i$ comprobar que

es un estadístico completo para el modelo Poisson. En efecto como $T \sim \text{Poisson}(n\lambda)$ resulta:

$$E_{\lambda}(\varphi(T)) = \sum_{k=0}^{\infty} \varphi(k) P(T=k) = \sum_{k=0}^{\infty} \varphi(k) e^{-n\lambda} \frac{(n\lambda)^k}{k!}$$

por tanto:

$$E_{\lambda}(\varphi(T)) = 0 \iff \sum_{k=0}^{\infty} \varphi(k) e^{-n\lambda} \frac{(n\lambda)^k}{k!} = 0$$

igual a:

$$e^{-n\lambda} \sum_{k=0}^{\infty} \varphi(k) \frac{(n\lambda)^k}{k!} = 0$$

equivalente a:

$$\sum_{k=0}^{\infty} \frac{\varphi(k)}{k!} n^k \lambda^k = 0$$

si esto ocurre para todo $\lambda > 0$ y si llamamos $a_k = \frac{\varphi(k)}{k!} n^k$

resulta:

$$\sum_{k=0}^{\infty} a_k \lambda^k = 0 \quad \forall \lambda > 0$$

es decir tenemos una "serie de potencias" en λ igual a cero para todo valor de la variable λ : por propiedades de las series de potencias ello sólo es posible si $a_k = 0$ para todo $k \in \mathbb{N}$

(pensar en un polinomio de cualquier grado igual a cero para todo valor de su variable independiente; ¿cuáles serían sus coeficientes?)

por tanto:

$$a_k = \frac{\varphi(k)}{k!} n^k = 0 \quad \forall k \in \mathbb{N}$$

ello implica que $\varphi(k) = 0 \quad \forall k \in \mathbb{N}$

por tanto

$$\varphi(T) = 0$$

para T natural, pero T toma valores naturales con probabilidad 1 ya que $T \sim \text{Poisson}(n\lambda)$

T es completo para el modelo

Ejemplo 5:

$$X \sim \exp(\alpha) \quad X_1, \dots, X_m \text{ i.i.d } X$$

$$\alpha > 0$$

Comprobar que $T = \sum_{i=1}^m X_i$ es completo para el modelo exponencial

$$T \sim \text{Gamma}(\alpha, m)$$

$$E_{\alpha}(\varphi(T)) = \int_0^{\infty} \varphi(t) \frac{1}{\Gamma(m)} t^{m-1} \alpha^m e^{-\alpha t} dt$$

Si $E_{\alpha}(\varphi(T)) = 0 \quad \forall \alpha > 0$ entonces:

$$\int_0^{\infty} \varphi(t) \frac{1}{\Gamma(m)} t^{m-1} \alpha^m e^{-\alpha t} dt = 0 \quad \forall \alpha > 0$$

igual a:

$$\int_0^{\infty} \varphi(t) t^{m-1} e^{-\alpha t} dt = 0 \quad \forall \alpha > 0$$

ello es igual a decir que la transformada de Laplace de la función $\varphi(t) t^{m-1}$ es idénticamente nula: por propiedades de la transformada de Laplace se deduce que la función es nula en el intervalo $[0, \infty)$ por tanto

$$\varphi(t) t^{m-1} = 0 \quad \forall t > 0$$

$\varphi(T) = 0$ para $T > 0$, lo que ocurre con probabilidad 1 para el modelo exponencial.

T es completo para el modelo

Nota: La transformada de Laplace de una función $g(t)$ es

$$\mathcal{L}(g)(s) = \int_0^{\infty} g(t) e^{-st} dt \quad (6) \quad (\text{véase textos de análisis matemático estándar o buscar en internet Wikipedia etc., para propiedades})$$

puede entenderse como una "medida ponderada" según la función e^{-st} (donde s es variable).

Teorema de Lehmann-Scheffé'

$$X \sim f(x, \theta) \quad x \in \mathbb{R}^k \quad \theta \in \Theta \subset \mathbb{R}^m$$

X_1, \dots, X_n i.i.d X

$T = T(X_1, \dots, X_n)$ un estadístico eficiente y completo para el modelo

Sea $U = U(T)$ un estadístico función de T tal que

$$\underline{E_\theta(U) = \psi(\theta)}$$
 para una cierta función paramétrica (posiblemente multidimensional)

Entonces U es el estimador insesgado de $\psi(\theta)$ con UMR
mínimo riesgo cuadrático (y único en el sentido de que cualquier
 otro estimador insesgado de $\psi(\theta)$ con el mismo riesgo diferirá de U
 sólo en un conjunto de probabilidad cero).

Observación:

Como consecuencia de Lehmann-Scheffé', si partimos de un estimador
insesgado de $\psi(\theta)$ y lo mejoramos (en el sentido de reducir su riesgo)
 a partir del Teorema de Rao-Blackwell, basándonos en un estadístico
no sólo eficiente, sino completo, el estadístico "mejorado" así obtenido
 es el de mínimo riesgo cuadrático. (En el caso de que $\psi(\theta)$ sea
 un escalar, habremos obtenido el estimador UMV del parámetro
 $\psi(\theta)$).

unbiased minimum variance

Nota:

en algunos textos UMV se indica por UMVU (uniformly

y UMR se indica por UMRU

(uniformly minimum

risk unbiased)

el adjetivo "uniformly" indica que
 la propiedad de mínimo riesgo (dentro
 de la clase de estimadores insesgados)
 es una propiedad que ocurre
 con independencia del valor de θ

minimum
variance
unbiased)

Ejemplo 6

- Hallar el estimador UMVU de $P(X=0)$ donde $X \sim \text{Poisson}(\lambda)$, basándonos en una muestra de tamaño n , X_1, \dots, X_n i.i.d X .
aleatoria simple

Sabemos que $T = \sum_{i=1}^n X_i$ es un estadístico suficiente y completo.

Para hallar el estimador UMVU (uniformly minimum variance unbiased) de $P(X=0)$ bastará encontrar un estimador insesgado de dicha probabilidad y luego aplicar Rao-Blackwell y Lehmann-Scheffé.

Observar que

$$P(X=0) = e^{-\lambda}$$

Para hallar un estimador insesgado de $\psi(\lambda) = e^{-\lambda}$ consideraremos el indicador del suceso $X_1=0$, $\mathbb{1}_{\{X_1=0\}}$. Como todo indicador,

$$\underline{E(\mathbb{1}_A) = P(A)}, \text{ por tanto } E_{\lambda}(\mathbb{1}_{\{X_1=0\}}) = P_{\lambda}(X_1=0) = e^{-\lambda}$$

por tanto $\mathbb{1}_{\{X_1=0\}}$ es un estimador insesgado de $\psi(\lambda)$

Apliquemos Rao-Blackwell:

$$\varphi(t) = E_{\lambda}(\mathbb{1}_{\{X_1=0\}} | T=t) = P_{\lambda}(X_1=0 | T=t) = \frac{P_{\lambda}([X_1=0] \cap [T=t])}{P(T=t)}$$

con $t \in \mathbb{N}$

El suceso $[X_1=0] \cap [T=t]$ es igual al suceso

$$[X_1=0] \cap \left[\sum_{j=2}^n X_j = t \right]$$

Observar además que $X_1 \sim P(\lambda)$, $T \sim P(n\lambda)$ y

$\sum_{j=2}^n X_j \sim P((n-1)\lambda)$, por tanto, al ser $[X_1=0]$ y $\left[\sum_{j=2}^n X_j = t \right]$

independientes, tendremos:

$$\begin{aligned} \varphi(t) &= \frac{P_{\lambda}(X_1=0) P_{\lambda}\left(\sum_{j=2}^n X_j = t\right)}{P(T=t)} = \\ &= \frac{e^{-\lambda} e^{-(n-1)\lambda} \frac{((n-1)\lambda)^t}{t!}}{e^{-n\lambda} \frac{(n\lambda)^t}{t!}} = \left(1 - \frac{1}{n}\right)^t \end{aligned}$$

Por tanto el estadístico:

$$\left[p(T) = \left(1 - \frac{1}{n}\right)^T \right] \quad (7)$$

es un estimador insesgado de $e^{-\lambda}$ y como es función de un estadístico suficiente y completo del modelo, por Lehmann-Scheffé se tratará del estimador UMVU de $e^{-\lambda}$.

Observación: puesto que $T = \sum_{i=1}^n X_i = \frac{1}{n} \bar{X}_n$, vemos que (7)

puede escribirse como:

$$p(T) = \left(1 - \frac{1}{n}\right)^{\bar{X}_n n}$$

y como $\bar{X}_n \xrightarrow{c.p.} \lambda$ (ley de los grandes números)

$$\text{y } \lim_{n \rightarrow \infty} \left(1 - \frac{1}{n}\right)^{a n} = e^{-a}$$

se puede demostrar que $\left(1 - \frac{1}{n}\right)^{\bar{X}_n n} \xrightarrow{c.p.} e^{-\lambda}$

es decir se trataría de un estimador también consistente de $e^{-\lambda}$.

Ejemplo 7

Hallar el estimador UMVU de $P(X > a)$, donde

$X \sim \text{Exponencial}(\alpha)$ y a es una constante positiva conocida, a partir de una muestra aleatoria simple de tamaño n .

Sabemos que $T = \sum_{i=1}^n X_i$ es un estadístico suficiente y completo para el modelo exponencial. Por tanto, por los teoremas de Rao-Blackwell y Lehmann-Scheffé bastará encontrar un estimador insesgado de $P(X > a)$. Observemos que

$$P(X > a) = \int_a^{\infty} \alpha e^{-\alpha x} dx = \left[-e^{-\alpha x} \right]_a^{\infty} = \lim_{x \rightarrow \infty} -e^{-\alpha x} - (-e^{-\alpha a}) = e^{-\alpha a}$$

-11-

Un estimador insesgado de $P(X > a) = e^{-\alpha a}$ será, por ejemplo,

$$\mathbb{1}_{\{X_1 > a\}} \text{ ya que } E(\mathbb{1}_{\{X_1 > a\}}) = P(X_1 > a) = P(X > a) = e^{-\alpha a}$$

(indicador de $\{X_1 > a\}$)

Por tanto, el estimador UMVU buscado es:

$$\varphi(t) = E_{\alpha}(\mathbb{1}_{\{X_1 > a\}} | T=t)$$

Ahora bien:

$$E_{\alpha}(\mathbb{1}_{\{X_1 > a\}} | T=t) = P(X_1 > a | T=t)$$

Habría que hallar la densidad condicionada $X_1 | T$.

Puesto que X_1, \dots, X_n son independientes, también serán variables independientes X_1 y $S = \sum_{i=2}^n X_i$. Escribamos su densidad conjunta; sabiendo que $X_1 \sim \text{Exponencial}(\alpha)$, $S \sim \text{Gamma}(\alpha, n-1)$ por tanto:

$$f_{(X_1, S)}(x_1, s) = \alpha e^{-\alpha x_1} \frac{\alpha^{n-1} s^{n-2} e^{-\alpha s}}{\Gamma(n-1)} \quad \text{para } x_1 > 0, s > 0$$

(cero en caso contrario)

$$= \frac{\alpha^n}{\Gamma(n-1)} e^{-\alpha(x_1 + s)} s^{n-2}$$

Efectuemos ahora el cambio de variable $(X_1, S) \rightarrow (X_1, T)$

definido por:

$$\begin{aligned} X_1 &= X_1 \\ T &= X_1 + S \quad (S = T - X_1) \end{aligned}$$

El determinante del jacobiano del cambio es:

$$\det \begin{pmatrix} \frac{\partial x_1}{\partial x_1} & \frac{\partial x_1}{\partial t} \\ \frac{\partial s}{\partial x_1} & \frac{\partial s}{\partial t} \end{pmatrix} = \det \begin{pmatrix} 1 & 0 \\ -1 & 1 \end{pmatrix} = 1$$

por tanto la densidad conjunta resultante será:

$$f_{(x_1, T)}(x_1, t) = f_{(x_1, S)}(x, t - x_1) \cdot 1 \quad \text{para } x_1 > 0 \\ \text{y } t \geq x_1 \\ (\text{cero en caso contrario})$$

por tanto:

$$f_{(x_1, T)}(x_1, t) = \frac{\alpha^n}{\Gamma(n-1)} (t - x_1)^{n-2} e^{-\alpha t} \quad t \geq x_1 > 0 \\ (\text{cero en caso contrario})$$

para calcular $f_{x_1|T}(x_1)$ necesitamos saber cual es la marginal de T .
 Aunque dicha marginal podriamos hallarla calculando $\int_0^t f_{(x_1, T)}(x_1, t) dx_1$
 el resultado ya lo sabemos: como $T = \sum_{i=1}^n X_i \sim \text{Gamma}(\alpha, n)$
 resultara:

$$f_T(t) = \frac{\alpha^n}{\Gamma(n)} t^{n-1} e^{-\alpha t} \quad \text{para } t > 0 \\ (\text{cero en caso contrario})$$

Por tanto,

$$\left[f_{x_1|T}(x_1) = \frac{f_{(x_1, T)}(x_1, t)}{f_T(t)} = \frac{\alpha^n (t - x_1)^{n-2} e^{-\alpha t} / \Gamma(n-1)}{\alpha^n t^{n-1} e^{-\alpha t} / \Gamma(n)} \right. \\ = \frac{\Gamma(n)}{\Gamma(n-1)} \frac{(t - x_1)^{n-2}}{t^{n-1}} \quad \text{para } x_1 \in (0, t) \\ (\text{cero en caso contrario}) \\ = (n-1) \frac{1}{t} \left(1 - \frac{x_1}{t}\right)^{n-2} \quad \left. \begin{array}{l} t > 0 \\ x_1 \in (0, t) \quad t > 0 \end{array} \right] \\ (\text{cero en caso contrario})$$

Hay que hallar ahora:

$$P(X_1 > a \mid T = t) = \int_0^\infty f_{x_1|T}(x_1) dx_1 = \\ = \int_a^t (n-1) \frac{1}{t} \left(1 - \frac{x_1}{t}\right)^{n-2} dx_1 \quad \text{caso } a < t \\ = 0 \quad \text{caso } a > t$$

pero:

$$\int_a^t \frac{1}{t} (1 - \frac{x_1}{t})^{n-2} dx_1 = \int_{a/t}^1 (n-1) (1-y)^{n-2} dy = \left[- (1-y)^{n-1} \right]_{a/t}^1$$

haciendo $\frac{x_1}{t} = y$
 $x_1 = ty$

$$= 0 + \left(1 - \frac{a}{t}\right)^{n-1}$$

por tanto el estimador buscado es:

$$\varphi(T) = \begin{cases} 0 & T < a \\ \left(1 - \frac{a}{T}\right)^{n-1} & T \geq a \end{cases}$$

es el estimador UMVU,
uniformemente insesgado y de mínima varianza.

Para completar el tema de suficiencia, aprenderemos alguna definición y comentaremos alguna propiedad.

Definición 4

Sea $X \sim f(x, \theta)$ $x \in \mathbb{R}^k$, $\theta \in \Theta \subset \mathbb{R}^m$ X_1, \dots, X_n i.i.d X

$S = S(X_1, \dots, X_n)$ es un estadístico suficiente minimal si y solo si es en primer lugar un estadístico suficiente, y en segundo lugar, dado otro estadístico suficiente $T(X_1, \dots, X_n)$ para el mismo modelo, resulta que existe un aplicación medible g tal que:

$$\underline{S = g(T)} \quad \text{con probabilidad 1 (casi seguramente)}$$

es decir si siempre será posible expresar S como función de cualquier otro estadístico suficiente.

Observación: podría demostrarse que $S = \sum_{i=1}^n X_i$ es un

estadístico suficiente minimal del modelo exponencial, pero $T = (X_1, \sum_{i=2}^n X_i)$ es también un estadístico suficiente pero no es minimal (S puede expresarse como función de T , pero T no puede expresarse como función de S).

Definición 5

Sea $X \sim f(x, \theta)$ $x \in \mathbb{R}^k$ $\theta \in \Theta \subset \mathbb{R}^m$ X_1, \dots, X_n iid X

$S = S(X_1, \dots, X_n)$ es un estadístico libre si y sólo si la distribución de S no depende de θ (o a libre distribución)

Ejemplo 8

Sea $X \sim N(\mu, 1)$ X_1, \dots, X_n iid X

$S = X_{(n)} - X_{(1)}$ Vamos a comprobar que es un estadístico libre.

Introducimos $Z_i = X_i - \mu$ $Z_i \sim N(0, 1)$ y son todas ellas independientes. Entonces, la distribución de $Z_{(n)} - Z_{(1)}$ no dependerá de μ puesto que se calculará a partir de la distribución conjunta de Z_1, \dots, Z_n , distribución conjunta que no depende de μ .

Por tanto, si observamos que $Z_{(n)} = X_{(n)} - \mu$ y $Z_{(1)} = X_{(1)} - \mu$, resulta que $X_{(n)} - X_{(1)} = Z_{(n)} - Z_{(1)}$ y deducimos pues que $X_{(n)} - X_{(1)}$, su distribución, no depende de μ : es pues un estadístico libre.

Observación:

Un estadístico libre no nos aporta información útil para estimar el parámetro θ .

Algunos resultados

* Dado un modelo estadístico si S es un estadístico suficiente, y si g es una aplicación medible y biyectiva, cuyo dominio sea el espacio muestral de los valores de S , entonces $g(S)$ es también un estadístico suficiente.

* Si tenemos un modelo exponencial:

$f(x; \theta) = A(x)K(\theta) \exp\left(\sum_{j=1}^r \theta_j T_j(x)\right)$ y el espacio vectorial generado por Θ es todo \mathbb{R}^r
 $\theta \in \Theta \subset \mathbb{R}^r$ $x \in \mathbb{R}^k$

entonces $T(x) = (T_1(x), \dots, T_r(x))$ es un estadístico suficiente y minimal.

Si $\text{int}(\Theta) \neq \emptyset$ podemos asegurar que T es completo.

Observar que si $\text{int}(\Theta) \neq \emptyset$ entonces seguro que el espacio vectorial generado por Θ es todo \mathbb{R}^r y por tanto se concluye que T es suficiente, minimal y completo.