

1. Sea X una variable aleatoria absolutamente continua con función de densidad:

$$f(x; \theta) = \theta(1-x)^{\theta-1} \mathbf{1}_{(0,1)}(x) \quad \theta > 0$$

Consideremos una muestra aleatoria simple de tamaño n de X .

- Encuentre el MLE (estimador máximo verosímil) y el estimador obtenido por el método de los momentos de θ .
- Halle el sesgo del MLE de θ . También su error cuadrático medio.
- Calcule la Cota de Cramér-Rao correspondiente a estimadores insesgados de θ .
- Halle un estadístico suficiente para θ . Suponga que la familia de probabilidades es completa, halle el estimador UMVU (uniformemente insesgado y de mínima varianza) de θ .
- Construya un intervalo de confianza $(1 - \alpha)$ para θ .

Indicación: Puede ayudar a resolver el problema el calcular la función de densidad de la variable $Y = -\ln(1 - X)$.

2. Sea X una variable aleatoria absolutamente continua con función de densidad

$$f(x; \lambda) = 2\lambda x \exp(-\lambda x^2) \mathbf{1}_{(0,+\infty)}(x) \quad \lambda > 0$$

Fijemos dos números reales conocidos $0 < \lambda_0 < \lambda_1$. Consideremos una muestra aleatoria simple de tamaño n de X .

- Halle un test de potencia máxima (MP), fijado el nivel de significación $\alpha \in (0, 1)$, para contrastar:

$$H_0 : \lambda = \lambda_0 \quad H_1 : \lambda = \lambda_1$$

y resuélvalo para el caso particular $n = 6$, $\lambda_0 = 1$, $\lambda_1 = 1.5$, $\alpha = 0.05$.

- Demuestre que la región crítica del test del primer apartado, también es la región crítica de un test UMP (uniformemente MP) para contrastar:

$$H_0 : \lambda = \lambda_0 \quad H_1 : \lambda > \lambda_0$$

- Utilitze el test de la razón de verosimilitud para contrastar:

$$H_0 : \lambda = \lambda_0 \quad H_1 : \lambda \neq \lambda_0$$

Indicación: Puede ayudar a resolver el problema el calcular la función de densidad de la variable $Y = X^2$.

3. Contestar **verdadero (V)** o **falso (F)** en esta misma hoja.

- V ■ Sea X una variable aleatoria cuya ley probabilística es una distribución Binomial $B(m, p)$ con $m \in \mathbb{N} \setminus \{0\}$ y $p \in (0, 1)$, y sean X_1, \dots, X_n las variables aleatorias muestrales correspondientes a una muestra de tamaño n . Entonces la distribución conjunta de (X_1, \dots, X_n) sigue una distribución de la familia exponencial.
- F ■ Todo estimador consistente es asintóticamente eficiente.
- F ■ El MLE de un parámetro, si existe, siempre es un estimador insesgado de dicho parámetro.
- F ■ Un pivote es un estadístico insesgado del parámetro que pretendemos estimar por regiones.
- V ■ El Teorema de Fisher nos proporciona bastante directamente pivotes para estimar la esperanza o la desviación típica de una distribución normal univariante.
- V ■ El Lema (o Teorema) de Neyman-Pearson nos garantiza la existencia de tests óptimos (puros o aleatorizados) en el caso de que tanto la hipótesis nula como la alternativa sean simples.
- V ■ La Razón de verosimilitud es un estadístico con esperanza finita, tanto bajo la hipótesis nula como la alternativa.
- F ■ Bajo condiciones de regularidad $-2 \ln \Lambda(X_1, \dots, X_n)$ converge en ley (también: converge débilmente o en distribución) a una distribución χ^2 con sus correspondientes grados de libertad.

NOTA: Cada apartado de los dos problemas vale 1 punto. Las respuestas deben ser debidamente justificadas, exceptuando las preguntas tipo test finales. El test vale 2 puntos de la nota final del examen. La nota del test, sobre 2 puntos, es igual a 0,25 multiplicado por el número de aciertos menos fallos.

1.a) La función de verosimilitud será:

$$L_x(\theta) = \prod_{i=1}^m \left\{ \theta(1-x_i)^{\theta-1} \mathbb{1}_{(0,1)}(x_i) \right\}$$
$$= \theta^m \left\{ \prod_{i=1}^m (1-x_i) \right\}^{\theta-1} \mathbb{1}_{(0,1)}(x_{(1)}) \mathbb{1}_{(0,1)}(x_{(m)}) \quad \theta > 0$$

con probabilidad 1 cero:

$$L_x(\theta) = \theta^m \left\{ \prod_{i=1}^m (1-x_i) \right\}^{\theta-1} \quad x_1, \dots, x_m \in (0,1) \quad \theta > 0$$

Hemos de hallar su máximo. Facilita el problema tomar logaritmos:

$$\ln L_x(\theta) = n \ln \theta + (\theta-1) \sum_{i=1}^m \ln(1-x_i)$$

$$\frac{\partial \ln L_x(\theta)}{\partial \theta} = \frac{n}{\theta} + \sum_{i=1}^m \ln(1-x_i)$$

La ecuación de verosimilitud es:

$$\frac{n}{\theta} + \sum_{i=1}^m \ln(1-x_i) = 0$$

que proporciona la solución:

$$\theta^* = - \frac{n}{\sum_{i=1}^m \ln(1-x_i)}$$

obsérvese que:

$$\frac{\partial \ln L_x(\theta)}{\partial \theta} > 0 \quad \text{si} \quad \theta < \theta^*$$

$$\text{y} \quad \frac{\partial \ln L_x(\theta)}{\partial \theta} < 0 \quad \text{si} \quad \theta > \theta^*$$

por lo que al ser $\ln L_x(\theta)$ creciente antes de θ^* y decreciente después, podemos asegurar que la función presenta un máximo absoluto en la (única) raíz obtenido por lo que el MLE es:

$$\theta^*(x_1, \dots, x_m) = - \frac{n}{\sum_{i=1}^m \ln(1-x_i)}$$

En cuanto al método de los momentos, notemos que

$$\begin{aligned} E(X) &= \int_0^1 x f_x(x) dx = \int_0^1 x \theta (1-x)^{\theta-1} dx = \\ &= \theta \int_0^1 x^{2-1} (1-x)^{\theta-1} dx = \theta B(2, \theta) = \theta \frac{\Gamma(2)\Gamma(\theta)}{\Gamma(\theta+2)} = \\ &= \theta \frac{1! \Gamma(\theta)}{(\theta+1)\theta \Gamma(\theta)} = \frac{1}{\theta+1} \end{aligned}$$

por tanto para obtener dicho estimador igualaremos:

$$\bar{x}_m = \frac{1}{\theta+1} \Leftrightarrow \theta = \frac{1}{\bar{x}_m} - 1$$

por tanto:

$$\hat{\theta}(x_1, \dots, x_m) = \frac{1}{\bar{x}_m} - 1 = \frac{m}{\sum_{i=1}^m x_i} - 1$$

o expresión equivalente.

1.b) Para hallar el sesgo del MLE usaremos la indicación. lo haremos de dos formas distintas.

/ * primera forma */ Sea $Y = -\ln(1-X)$, definida con probabilidad 1

$$\begin{aligned} F_Y(y) &= P(Y \leq y) = P(-\ln(1-X) \leq y) = P(\ln(1-X) \geq -y) = \\ &= P(1-X \geq e^{-y}) = P(-X \geq -1 + e^{-y}) = P(X \leq 1 - e^{-y}) \\ &= F_X(1 - e^{-y}) \end{aligned}$$

pero:

$$F_X(u) = \begin{cases} 0 & u \leq 0 \\ 1 - (1-u)^\theta & u \in (0,1) \\ 1 & u \geq 1 \end{cases}$$

por tanto:

$$F_Y(y) = \begin{cases} 0 & y \leq 0 \\ 1 - e^{-\theta y} & y > 0 \end{cases}$$

por tanto Y sigue una distribución exponencial de parámetro θ .

/* segunda forma */

A través de las funciones de densidad.

$$f_Y(y) = f_X(x(y)) \left| \frac{dx}{dy} \right| \quad \text{para } y > 0, \text{ cero en caso contrario.}$$

donde $x(y) = 1 - e^{-y}$ ya que $y(x) = -\ln(1-x)$.
por tanto:

$$\frac{dx}{dy} = -e^{-y}(-1) = e^{-y}$$

y resulta:

$$\begin{aligned} f_Y(y) &= \theta (1 - (1 - e^{-y}))^{\theta-1} \mathbb{1}_{(0,1)}(1 - e^{-y}) \cdot |e^{-y}| \\ &= \theta (e^{-y})^{\theta-1} e^{-y} \mathbb{1}_{(0,1)}(1 - e^{-y}) \\ &= \theta e^{-y\theta+y} e^{-y} \mathbb{1}_{(0,\infty)}(y) \\ &= \theta e^{-\theta y} \mathbb{1}_{(0,\infty)}(y) \end{aligned}$$

por tanto Y sigue una distribución exponencial de parámetro θ .

Cualquiera de los dos caminos es válido.

El MLE será:

$$\theta^* = \frac{n}{\sum_{i=1}^n Y_i} \quad \text{y por tanto, como } \sum_{i=1}^n Y_i \sim \text{Gamma}(\theta, n)$$

resultará que:

$$\begin{aligned} E_{\theta}((\theta^*)^p) &= \int_0^{\infty} \left(\frac{n}{u}\right)^p \frac{\theta^n u^{n-1}}{\Gamma(n)} e^{-\theta u} du = \\ &= \frac{n^p \theta^p}{\Gamma(n)} \int_0^{\infty} \theta^{n-p} u^{n-p-1} e^{-\theta u} du = \\ &= \frac{n^p \theta^p}{\Gamma(n)} \Gamma(n-p) \quad \text{siempre que } n-p > 0 \end{aligned}$$

para $p=1$

$(n > p)$

$$E_{\theta}(\theta^*) = \frac{n \theta}{\Gamma(n)} \Gamma(n-1) = \frac{n}{n-1} \theta$$

El sesgo del MLE será:

$$B(\theta) = \frac{n}{n-1} \theta - \theta = \frac{1}{n-1} \theta \quad (\text{para } n > 1)$$

Para calcular el error cuadrático medio calculamos

$$E_{\theta}(\theta^{*2}) = \frac{n^2 \theta^2}{\Gamma(n)} \Gamma(n-2) = \frac{n^2 \theta^2}{(n-1)(n-2)} \quad (\text{para } n > 2)$$

por tanto

$$\text{var}_{\theta}(\theta^*) = E_{\theta}(\theta^{*2}) - E_{\theta}(\theta^*)^2 =$$

$$\begin{aligned} &= \frac{n^2 \theta^2}{(n-1)(n-2)} - \frac{n^2 \theta^2}{(n-1)^2} = \frac{n^2 ((n-1) - (n-2))}{(n-2)(n-1)^2} \theta^2 \\ &= \frac{n^2}{(n-2)(n-1)^2} \theta^2 \end{aligned}$$

para $n > 2$

-3-
El error cuadrático medio será:

$$\begin{aligned} \boxed{EQM(\theta^*)} &= \text{var}_{\theta}(\theta^*) + B(\theta^*)^2 = \\ &= \frac{n^2}{(n-2)(n-1)^2} \theta^2 + \frac{1}{(n-1)^2} \theta^2 = \\ &= \frac{(n^2 + n - 2) \theta^2}{(n-2)(n-1)^2} = \frac{(n-1)(n+2)}{(n-2)(n-1)^2} \theta^2 = \\ &= \boxed{\frac{n+2}{(n-2)(n-1)} \theta^2} \end{aligned}$$

1.c) En cuanto la cota de Cramér-Rao resulta:

$$\ln f(x, \theta) = \ln \theta + (\theta-1) \ln(1-x) \quad (\text{con probabilidad 1})$$

$$\frac{\partial \ln f(x, \theta)}{\partial \theta} = \frac{1}{\theta} + \ln(1-x)$$

$$\boxed{I(\theta) = E_{\theta} \left(\left\{ \frac{1}{\theta} + \ln(1-x) \right\}^2 \right)} = E_{\theta} \left(\left\{ \frac{1}{\theta^2} + \ln^2(1-x) + \frac{2}{\theta} \ln(1-x) \right\} \right)$$

$$\begin{aligned} &= \frac{1}{\theta^2} + E_{\theta}(Y^2) - \frac{2}{\theta} E_{\theta}(Y) = \frac{1}{\theta^2} + \left(\frac{1}{\theta^2} + \frac{1}{\theta^2} \right) - \frac{2}{\theta} \frac{1}{\theta} = \\ &= \boxed{\frac{1}{\theta^2}} \end{aligned}$$

$$\left(\text{ya que } E_{\theta}(Y) = \frac{1}{\theta} \quad \text{var}_{\theta}(Y) = \frac{1}{\theta^2} \right)$$

Por tanto la cota de Cramér-Rao, para insesgados, será:

$$\boxed{CCR = \frac{1}{n I(\theta)} = \frac{1}{n \frac{1}{\theta^2}} = \frac{\theta^2}{n}}$$

/ * Alternativamente * /

Por condiciones de regularidad:

$$I(\theta) = -E_{\theta} \left(\frac{\partial^2 \ln f(x, \theta)}{\partial \theta^2} \right) = -E_{\theta} \left(-\frac{1}{\theta^2} \right) = \frac{1}{\theta^2}$$

1.d) La función de densidad conjunta de la muestra es:

$$\begin{aligned} \tilde{f}(x_1, \dots, x_n, \theta) &= \prod_{i=1}^n \left\{ \theta (1-x_i)^{\theta-1} \mathbb{1}_{(0,1)}(x_i) \right\} = \\ &= \theta^n \left(\prod_{i=1}^n (1-x_i) \right)^{\theta-1} \mathbb{1}_{(0,1)}(x_{(1)}) (x_{(n)}) \\ &= \theta^n \left\{ e^{\ln \left(\prod_{i=1}^n (1-x_i) \right)} \right\}^{\theta-1} \mathbb{1}_{(0,1)}(x_{(1)}) (x_{(n)}) \\ &= \theta^n e^{-\left(- \sum_{i=1}^n \ln(1-x_i) \right) (\theta-1)} \mathbb{1}_{(0,1)}(x_{(1)}) (x_{(n)}) \end{aligned}$$

(Neyman-Fisher) $g(\theta, -\sum_{i=1}^n \ln(1-x_i)) \quad h(x_1, \dots, x_n)$

por tanto $-\sum_{i=1}^n \ln(1-x_i)$ es un estadístico suficiente.

Además, nos añadiremos la hipótesis de completitud, por tanto para aplicar Lehmann-Scheffé bastará corregir el sesgo del MLE:

$$\left[U \equiv \frac{n-1}{n} \theta^* = - \frac{n-1}{\sum_{i=1}^n \ln(1-x_i)} \right]$$

este estimador es insesgado y función del suficiente y completo $-\sum_{i=1}^n \ln(1-x_i)$ por tanto es UMVU.

Su varianza será:

$$\left[\text{var}_{\theta}(U) = \left(\frac{n-1}{n} \right)^2 \text{var}_{\theta}(\theta^*) = \frac{(n-1)^2}{n^2} \frac{n^2}{(n-2)(n-1)^2} \theta^2 = \frac{\theta^2}{n-2} \right]$$

por tanto: U no es eficiente ya que

$$\left[\text{var}_{\theta}(U) = \frac{\theta^2}{n-2} > \frac{\theta^2}{n} \right]$$

1.e) observamos que conocemos la distribución de

$$\sum_{i=1}^m Y_i = - \sum_{i=1}^m \ln(1-X_i) \sim G(\theta, m)$$

Por tanto:

$$2\theta \sum_{i=1}^m Y_i = -2\theta \sum_{i=1}^m \ln(1-X_i) \sim G\left(\frac{1}{2}, m\right) = \chi_{2m}^2$$

Podemos usar esta expresión como prueba:

$$P\left(a \leq -2\theta \sum_{i=1}^m \ln(1-X_i) \leq b\right) = 1 - \alpha$$

a y b determinadas en tablas.

$$F_{\chi_{2m}^2}(a) = \alpha_1$$

$$\text{con } \alpha_1 + \alpha_2 = \alpha \in (0, 1)$$

$$F_{\chi_{2m}^2}(b) = 1 - \alpha_2$$

$$a \leq -2\theta \sum_{i=1}^m \ln(1-X_i) \leq b.$$

$$-\frac{a}{2 \sum_{i=1}^m \ln(1-X_i)} \geq \theta \geq -\frac{b}{2 \sum_{i=1}^m \ln(1-X_i)}$$

$$\left[a = F_{\chi_{2m}^2}^{-1}(\alpha_1) \right]$$

[como aproximación podemos
escoger $\alpha_1 = \alpha_2 = \alpha/2$ ⁽¹⁾]

$$\left[b = F_{\chi_{2m}^2}^{-1}(1 - \alpha_2) \right]$$

$$\left[-\frac{b}{2 \sum_{i=1}^m \ln(1-X_i)} \leq \theta \leq -\frac{a}{2 \sum_{i=1}^m \ln(1-X_i)} \right]$$

(1) en caso contrario implementáramos algún método numérico.

2a) la región crítica óptima vendrá dada por el lema o teorema de Neyman - Pearson

$$\tilde{f}_1(x_1 - x_n) \geq K f_0(x_1 - x_n)$$

$$\prod_{i=1}^m \{2\lambda_1 x_i e^{-\lambda_1 x_i^2} \mathbb{1}_{(0,\infty)}(x_i)\} \geq K \prod_{i=1}^m \{2\lambda_0 x_i e^{-\lambda_0 x_i^2} \mathbb{1}_{(0,\infty)}(x_i)\}$$

$$\begin{aligned} 2^m \lambda_1^m \left(\prod_{i=1}^m x_i\right) e^{-\lambda_1 \sum_{i=1}^m x_i^2} \mathbb{1}_{(0,\infty)}(x_{(1)}) &\geq \\ &\geq K 2^m \lambda_0^m \left(\prod_{i=1}^m x_i\right) e^{-\lambda_0 \sum_{i=1}^m x_i^2} \mathbb{1}_{(0,\infty)}(x_{(1)}) \end{aligned}$$

simplificando y teniendo en cuenta que con probabilidad 1 $x_{(1)} > 0$:

$$\lambda_1^m e^{-\lambda_1 \sum_{i=1}^m x_i^2} \geq K \lambda_0^m e^{-\lambda_0 \sum_{i=1}^m x_i^2}$$

$$e^{(\lambda_0 - \lambda_1) \sum_{i=1}^m x_i^2} \geq K \left(\frac{\lambda_0}{\lambda_1}\right)^m$$

$$(\lambda_0 - \lambda_1) \sum_{i=1}^m x_i^2 \geq \ln \left(K \left(\frac{\lambda_0}{\lambda_1}\right)^m \right)$$

como lo hemos de resolver para $\lambda_0 = 1$ y $\lambda_1 = 1.5$, $\lambda_1 > \lambda_0$ resultará:

$$\sum_{i=1}^m x_i^2 \leq \underbrace{\frac{1}{\lambda_0 - \lambda_1} \ln \left(K \left(\frac{\lambda_0}{\lambda_1}\right)^m \right)}_{\text{llamémosle "c"}}$$

(óptima)

Una región crítica será de la forma:

$$\boxed{W = \{ (x_1 - x_n) \in \mathbb{R}^m / \sum_{i=1}^m x_i^2 \leq c \}}$$

donde c dependerá del nivel de significación α que queramos trabajar.

Si hacemos $\alpha = 0.05$ podemos hallar c teniendo en cuenta la inducción.

Si llamamos $y = x^2$ entonces:

para $y > 0$

$$f_y(y) = f_x(x(y)) \cdot \left| \frac{dx}{dy} \right| =$$

$$= 2\lambda \sqrt{y} e^{-\lambda y} \frac{1}{2\sqrt{y}} = \lambda e^{-\lambda y}$$

para $y > 0$ y en caso continuo; luego Y sigue una exponencial de parámetro λ .

Entonces:

$$\left[\sum_{i=1}^m X_i^2 \sim G(\lambda, m) \right]$$

$$\text{y } 2\lambda \sum_{i=1}^m X_i^2 \sim G\left(\frac{1}{2}, m\right) \equiv \chi_{2m}^2$$

Por tanto hemos de determinar c de forma que:

$$0.05 = \alpha = P\left(\sum_{i=1}^m X_i^2 \leq c \mid H_0\right) = P\left(2 \sum_{i=1}^m X_i^2 \leq 2c\right) = P(U \leq 2c)$$

donde U es una v.a que sigue una distribución χ^2 con $2m$ grados de libertad. Por tanto:

$$F_{\chi_{2m}^2}(2c) = 0.05 \Rightarrow 2c = F_{\chi_{2m}^2}^{-1}(0.05)$$

$$c = \frac{1}{2} F_{\chi_{2m}^2}^{-1}(0.05)$$

para $m = 6$ resultará:

$$\left[c = \frac{1}{2} F_{\chi_{12}^2}^{-1}(0.05) = \frac{1}{2} 5.226 = 2.613 \right]$$

2.b.) Observamos que la región crítica obtenida es idéntica a la que obtendríamos reemplazando λ_1 por cualquier otro valor mayor que λ_0 . Por tanto no que existe una región crítica óptima uniformemente para contrastar

$$H_0: \lambda = \lambda_0 \quad H_1: \lambda > \lambda_0$$

$$\left[W = \left\{ (x_1, \dots, x_n) \in \mathbb{R}^n \mid 2 \sum_{i=1}^n x_i^2 \leq a \right\} \right] \quad \text{con } a = 2c$$

y determinado de forma que

$$\left[\begin{aligned} F_{\chi^2_{2n}}(a) &= \alpha \\ a &= F_{\chi^2_{2n}}^{-1}(\alpha) \end{aligned} \right]$$

2.c.) Observamos que $\Theta \equiv \mathbb{R}^+$ $\Theta_0 = \{\lambda_0\}$
 $\dim \Theta = 1 \quad \dim \Theta_0 = 0$.

$$L_X(\lambda) = 2^n \lambda^n \left(\prod_{i=1}^n x_i \right) e^{-\lambda \sum_{i=1}^n x_i^2} 1_{\mathbb{R}^+}(x_{(1)})$$

con probabilidad 1 igual a:

$$L_X(\lambda) = 2^n \lambda^n \left(\prod_{i=1}^n x_i \right) e^{-\lambda \sum_{i=1}^n x_i^2}$$

teniendo en cuenta la introducción, al ser $x^2 \sim \text{Exponencial}(\lambda)$ el MLE es bien sabido que es igual a:

$$\left[\lambda^* = \frac{n}{\sum_{i=1}^n x_i^2} \right] \quad \begin{aligned} &\text{(la inversa de la media)} \\ &\text{caso: modelo exponencial ordinario} \end{aligned}$$

por tanto:

$$\widehat{L}_X(\Theta) = L_X\left(\frac{n}{\sum_{i=1}^n x_i^2}\right) = 2^n \left(\frac{n}{\sum_{i=1}^n x_i^2}\right)^n \left(\prod_{i=1}^n x_i\right) e^{-n}$$

$$\widehat{L}_X(\Theta_0) = L_X(\lambda_0) = 2^n \lambda_0^n \left(\prod_{i=1}^n x_i\right) e^{-\lambda_0 \sum_{i=1}^n x_i^2}$$

$$\Lambda(x_1, \dots, x_n) = \frac{\widehat{L}_X(\Theta_0)}{\widehat{L}_X(\Theta)} = \left(\frac{\lambda_0 \sum_{i=1}^n x_i^2}{n} \right)^n e^{-\lambda_0 \sum_{i=1}^n x_i^2 + n}$$

Si introducimos la función

$$h(w) = w^m e^{-m(w-1)}$$

para $w \geq 0$

resulta que

$$\Lambda(x_1, \dots, x_n) = h\left(\frac{\lambda_0 \sum_{i=1}^n x_i^2}{n}\right)$$

$$\begin{aligned} \text{observar que } h'(w) &= m w^{m-1} e^{-m(w-1)} + w^m e^{-m(w-1)} (-m) \\ &= m w^{m-1} e^{-m(w-1)} \{1 - w\} \end{aligned}$$

por tanto h es creciente cuando $0 \leq w < 1$ y decreciente cuando $w > 1$ y $\Lambda(x_1, \dots, x_n) = c$ cuando $h(A) = h(B) = c$

con $A < 1$ y $B > 1$. La región crítica será pues:

$$W = \left\{ (x_1, \dots, x_n) \in \mathbb{R}^n \mid \frac{\lambda_0}{n} \sum_{i=1}^n x_i^2 < A \text{ o } \frac{\lambda_0}{n} \sum_{i=1}^n x_i^2 > B \right\}$$

donde A y B verifican:

$$A^m e^{-m(A-1)} = B^m e^{-m(B-1)}$$

equivalente a:

$$\left(\frac{A}{B}\right)^m = e^{-m(B-A)}$$

y además como $P(W|H_0) = \alpha \Leftrightarrow P(W^c|H_0) = 1 - \alpha$

tendremos, como bajo H_0 $\frac{\lambda_0}{n} \sum_{i=1}^n X_i^2 \sim G(n, n)$, que

$$\int_A^B \frac{n^m t^{m-1}}{\Gamma(m)} e^{-nt} dt = 1 - \alpha$$

Alternativamente, podemos usar una aproximación asintótica basada en el Teorema de Wilks.

Calculando:

$$\begin{aligned} \left[-2 \ln \Lambda(x_1, \dots, x_n) = -2 \left\{ n \ln \left(\frac{\lambda_0 \sum_{i=1}^n x_i^2}{n} \right) - \lambda_0 \sum_{i=1}^n x_i^2 + n \right\} \right. \\ \left. = 2n \left\{ \frac{\lambda_0 \sum_{i=1}^n x_i^2}{n} - 1 - \ln \frac{\lambda_0 \sum_{i=1}^n x_i^2}{n} \right\} \right] \end{aligned}$$

pues sabemos que bajo la hipótesis nula con condiciones de regularidad, $-2 \ln \Lambda \xrightarrow{L} U$ con $U \sim \chi_r^2$ siendo

$$r = \dim(\Theta) - \dim(\Theta_0) = 1 - 0 = 1.$$

Por tanto, podemos determinar un valor A de forma que

$$P(U > A) = \alpha \iff P(U \leq A) = F_{\chi_1}(A) = 1 - \alpha$$

$$A = F_{\chi_1}^{-1}(1 - \alpha)$$

y la región crítica de nivel de significación α aproximado será:

$$\left[W = \left\{ (x_1, \dots, x_n) \in \mathbb{R}^n \mid -2 \ln \Lambda(x_1, \dots, x_n) > A \right\} \right]$$