

# Econometria

## Tema 2: MRLM: Especificació i Estimació

Ramon Alemany

Grau Estadística UB-UPC

**Curs 2017-18**

# Presentació

- 1 Bibliografia
- 2 Formulació i Hipòtesis Bàsiques del Model
- 3 Estimació per Mínims Quadrats Ordinaris (MQO)  
Propietats estadístiques
- 4 Residus de l'estimació
- 5 Estimació de la variància del terme de pertorbació
- 6 L'estimador Màxim Versemblant (MV). Propietats

# Bibliografia

- GREENE, W. (1999)  
**Análisis econométrico. 3a Ed.**  
*Capítol 6*
- WOOLDRIDGE, J. (2009)  
**Introducción a la Econometría. Un enfoque moderno. 4a Ed.**  
*Capítol 3*
- STOCK, J. & WATSON, M. (2012)  
**Introducción a la Econometría. 3a Ed.**  
*Capítol 6*

# Formulació i Hipòtesis Bàsiques del Model

## Formulació del Model de Regressió Lineal Múltiple

Especificarem un model economètric per a explicar el comportament d'una variable econòmica  $Y$ , que anomenarem **variable endògena, variable dependent o variable a explicar**, a partir dels valors observats per a un conjunt de  $k$  variables que anomenarem **explicatives (independents o exògenes)** i que, en general, representarem mitjançant la lletra  $X$ .

És a dir:

$$Y = f(X_1, X_2, X_3, \dots, X_k)$$

Aquesta relació de causalitat és unidireccional

# Formulació i Hipòtesis Bàsiques del Model

## Formulació del Model de Regressió Lineal Múltiple

El Model de Regressió Lineal Múltiple és doncs:

$$y_t = \beta_1 x_{1t} + \beta_2 x_{2t} + \dots + \beta_k x_{kt} + u_t \quad t = 1, 2, \dots, T$$

- La variable  $y$  és l'**ENDÒGENA** i les  $x_1, x_2, \dots, x_k$  les **EXÒGENES**
- $\beta_1, \beta_2, \dots, \beta_k$  són els **PARÀMETRES** a estimar.
- El subíndex  $t$  indica un moment en el temps i s'utilitza quan treballem amb dades de sèrie temporal. Si treballem amb dades transversals utilitzarem el subíndex  $i$  amb  $i = 1, 2, \dots, N$
- El terme independent en l'equació es pot interpretar com la presència d'una variable constant  $x_{1t} = 1 \quad \forall t$ .
- $u_t$  és el **terme de pertorbació aleatòria**.

# Formulació i Hipòtesis Bàsiques del Model

## Formulació del Model de Regressió Lineal Múltiple

Agafant dades de tall transversal ( $i = 1, 2, \dots, N$ ) podem especificar una equació per cada individu:

$$\begin{cases} y_1 = \beta_1 + \beta_2 x_{21} + \dots + \beta_k x_{k1} + u_1 \\ y_2 = \beta_1 + \beta_2 x_{22} + \dots + \beta_k x_{k2} + u_2 \\ y_3 = \beta_1 + \beta_2 x_{23} + \dots + \beta_k x_{k3} + u_3 \\ \dots \\ y_N = \beta_1 + \beta_2 x_{2N} + \dots + \beta_k x_{kN} + u_N \end{cases}$$

# Formulació i Hipòtesis Bàsiques del Model

## Formulació del Model de Regressió Lineal Múltiple

Aquest sistema es pot escriure en forma matricial:

$$\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix} = \begin{bmatrix} 1 & x_{21} & x_{31} & \cdots & x_{k1} \\ 1 & x_{22} & x_{32} & \cdots & x_{k2} \\ \vdots & \vdots & \vdots & \vdots & \\ 1 & x_{2N} & x_{3N} & \cdots & x_{kN} \end{bmatrix} \times \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_k \end{bmatrix} + \begin{bmatrix} u_1 \\ u_2 \\ \vdots \\ u_N \end{bmatrix}$$

$$Y = X\beta + U$$

$$Y_{(N \times 1)} \quad X_{(N \times k)} \quad \beta_{(k \times 1)} \quad U_{(N \times 1)}$$

# Formulació i Hipòtesis Bàsiques del Model

## Hipòtesis del MRLM

Per poder determinar les propietats dels estimadors i el tipus de contrastos a realitzar és necessari formular un conjunt d'hipòtesis bàsiques:

- a) Hipòtesis bàsiques generals sobre el model
- b) Hipòtesis bàsiques sobre el terme de pertorbació
- c) Hipòtesis bàsiques sobre les variables explicatives
- d) Hipòtesis bàsiques sobre els paràmetres



# Hipòtesis Bàsiques del MRLM

## a) Hipòtesis bàsiques generals sobre el model

### 1.- El model és ESTOCÀSTIC

La introducció del terme de pertorbació aleatòria  $u_t$  en el model fa que la relació no sigui determinista i que la variable  $y_t$  sigui també aleatòria.

La inclusió de  $u_t$  ve justificada per:

- Omissió de variables que també expliquen l'endògena  $y_t$  però no introduïdes com a explicatives (d'efecte conjunt sobre  $y_t$  nul).
- El propi comportament aleatori de  $y_t$  (en general, de totes les relacions econòmiques).
- Errors de mesura en les variables incloses dins el model o possibles errors d'especificació.

# Hipòtesis Bàsiques del MRLM

## a) Hipòtesis bàsiques generals sobre el model

### 2.- El model és LINEAL o linealitzable

La relació que lliga la variable endògena  $y_t$  amb les explicatives  $x_1, x_2, \dots, x_k$  és lineal.

Hi ha relacions que són no lineals però que es poden linealitzar fent alguna transformació en el model. Són lineals respecte els paràmetres però no respecte les variables.

$$Y_i = A L_i^{\beta_1} K_i^{\beta_2} \implies \ln Y_i = \ln A + \beta_1 \ln L_i + \beta_2 \ln K_i$$

No podrem treballar amb models intrínsecament no lineals; aquells que no es poden linealitzar, que són no lineals respecte els paràmetres.

# Hipòtesis Bàsiques del MRLM

## a) Hipòtesis bàsiques generals sobre el model

### 3.- Informació estadística suficient

El requisit mínim és que el nombre d'observacions sigui més gran o igual que el nombre de paràmetres a estimar.

Tot i que això és el mínim, és desitjable tenir un nombre relativament elevat d'observacions per garantir la fiabilitat de les estimacions

$$N \geq k \implies N - k \geq 0$$



Graus de llibertat

# Hipòtesis Bàsiques del MRLM

## b) Hipòtesis bàsiques sobre el terme de pertorbació

### 1.- L'esperança matemàtica de $U$ és igual a 0

$$E(u_i) = 0 \quad \forall i$$

$$E(U) = 0_{N \times 1} \quad E(U) = \begin{bmatrix} E(u_1) \\ E(u_2) \\ \vdots \\ E(u_N) \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

# Hipòtesis Bàsiques del MRLM

## b) Hipòtesis bàsiques sobre el terme de pertorbació

### 2.- Homoscedasticitat

La variància del terme de pertorbació és constant:

$$Var(u_i) = \sigma_u^2 \quad \forall i$$

Tenim Heteroscedasticitat quan no es verifica aquesta hipòtesi.

$$Var(u_i) = \sigma_{ui}^2 \neq Var(u_j) = \sigma_{uj}^2 \quad \forall i \neq j$$

# Hipòtesis Bàsiques del MRLM

## b) Hipòtesis bàsiques sobre el terme de pertorbació

### 3.- No Autocorrelació

Els termes de pertorbació associats a dues observacions diferents són independents entre sí, és a dir, no existeix autocorrelació entre els diferents termes de pertorbació.

$$\text{Cov}(u_i u_j) = E [(u_i - E(u_i))(u_j - E(u_j))] = E(u_i u_j) = 0$$
$$\forall i, j = 1, 2, \dots, N \quad i \neq j$$

# Hipòtesis Bàsiques del MRLM

## b) Hipòtesis bàsiques sobre el terme de pertorbació

Si el terme de pertorbació és homoscedàstic i no autocorrelacionat direm que és **ESFÈRIC**, i la matriu de variàncies i covariàncies de  $U$  aleshores és escalar.

$$\begin{aligned}\Omega &= \begin{bmatrix} \text{Var}(u_1) & \text{Cov}(u_1 u_2) & \cdots & \text{Cov}(u_1 u_N) \\ & \text{Var}(u_2) & \cdots & \text{Cov}(u_2 u_N) \\ & & \ddots & \vdots \\ & & & \text{Var}(u_N) \end{bmatrix} = \\ &= \begin{bmatrix} \sigma_u^2 & 0 & \cdots & 0 \\ 0 & \sigma_u^2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_u^2 \end{bmatrix} = \sigma_u^2 \begin{bmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{bmatrix} = \sigma_u^2 I_N\end{aligned}$$

# Hipòtesis Bàsiques del MRLM

## b) Hipòtesis bàsiques sobre el terme de pertorbació

### 4.- $U$ es distribueix segons una Normal multivariant

Per tant, les Hipòtesis Bàsiques del terme de pertorbació es poden resumir mitjançant l'expressió:

$$u_i \sim N(0, \sigma_u^2) \quad U \sim N(0, \sigma_u^2 I_N)$$



# Hipòtesis Bàsiques del MRLM

## c) Hipòtesis bàsiques sobre les variables explicatives

### 1.- Regressors fixes

Les variables explicatives del model són fixes o deterministes, és a dir, són no aleatòries. Les úniques variables aleatòries són l'endògena i el terme de pertorbació.

### 2.- Les exògenes estan incorrelacionades amb el terme de pertorbació

$$\begin{aligned} E(x_{ji} u_i) &= 0 \quad \forall i = 1, 2, \dots, N \\ &\quad \forall j = 1, 2, \dots, k \end{aligned}$$

# Hipòtesis Bàsiques del MRLM

## c) Hipòtesis bàsiques sobre les variables explicatives

### 3.- Les exògenes són linealment independents

No existeix cap combinació lineal exacta entre les variables explicatives.

No existeix multicol·linealitat perfecta.

Les columnes de la matriu  $X$  són linealment independents i el seu rang és màxim i igual al número de variables explicatives del model:

$$\rho(X) = k$$

# Hipòtesis Bàsiques del MRLM

## c) Hipòtesis bàsiques sobre les variables explicatives

**4.- Les exògenes estan mesurades sense error**

**5.- Absència d'errors d'especificació**

En el model no s'ha omès cap variable rellevant ni s'ha inclòs cap variable irrellevant.

# Hipòtesis Bàsiques del MRLM

## d) Hipòtesis bàsiques sobre els paràmetres

### 1.- Hipòtesi de permanència estructural

Els coeficients  $\beta_j$  són constants per tota la mostra

# Formulació del model

Amb les anteriors hipòtesis, els valors que prenen l'Esperança i la Variància de la variable endògena són:

$$E(Y) = E(X\beta + U) = X\beta + E(U) = X\beta$$

$$\begin{aligned} Var(Y) &= E\left[(X\beta + U) - E(Y)\right]\left[(X\beta + U) - E(Y)\right]' = \\ &= E\left[(X\beta + U) - X\beta\right]\left[(X\beta + U) - X\beta\right]' = \\ &= E\left[U U'\right] = \sigma_u^2 I_N \end{aligned}$$

$$Y \sim N(X\beta, \sigma_u^2 I_N)$$

# Estimació dels paràmetres del model

## Mètodes d'estimació

Un cop hem especificat el model de regressió, el següent pas és estimar-lo, és a dir, obtenir valors numèrics dels paràmetres del MRLM a partir de la informació mostral disponible:


$$\hat{\beta}_1, \hat{\beta}_2, \dots, \hat{\beta}_k$$

Analitzarem dos mètodes d'estimació:

- a) Estimació per Mínims Quadrats Ordinaris (MQO)
- b) Estimació per Màxima Versemblança (MV)

# Estimació per Mínims Quadrats Ordinaris (MQO)

Començarem pel primer mètode, l'estimació per MQO, i ho aplicarem al cas més senzill, el MRLS:  $Y_i = \beta_1 + \beta_2 X_i + u_i$



La recta que millor ajusta el núvol de punts, és a dir, que faci menor la distància entre cada punt i la seva representació a la recta.

# Estimació per Mínims Quadrats Ordinaris (MQO)

Així, definint els errors o **RESIDUS** com:

$$e_i = y_i - \hat{y}_i = y_i - (\hat{\beta}_1 + \hat{\beta}_2 x_i)$$

O en termes matricials:

$$e = Y - \hat{Y} = Y - X\hat{\beta}$$

Caldrà obtenir els valors de  $\hat{\beta}_1$  i  $\hat{\beta}_2$  que facin mínims els errors o residus de l'estimació.



# Estimació per Mínims Quadrats Ordinaris (MQO)

Per tal de minimitzar els errors podríem usar diferents criteris:

- Minimitzar la suma dels errors comesos.  
Això, però, no resulta útil ja que els errors poden ser positius o negatius i en sumar-los es poden compensar.
- Minimitzar la suma dels errors en valor absolut.  
Aquesta, però, tampoc no és una alternativa útil ja que l'operador "valor absolut" no és diferenciable.
- Minimitzar la suma dels quadrats dels errors.  
Aquesta és l'alternativa emprada.

# Estimació per Mínims Quadrats Ordinaris (MQO)

Caldrà obtenir els valors de  $\hat{\beta}_1$  i  $\hat{\beta}_2$  que facin mínima la **SUMA DE QUADRATS DEL ERRORS (SQE)** o del residus de l'estimació.

On:

$$SQE = \sum_{i=1}^N e_i^2 = \sum_{i=1}^N (y_i - \hat{y}_i)^2 = e_1^2 + e_2^2 + \dots + e_N^2$$

# Estimació per Mínims Quadrats Ordinaris (MQO)

O en termes matricials:

$$\begin{aligned}SQE &= \sum_{i=1}^N e_i^2 = e'e = \begin{pmatrix} e_1 & e_2 & \dots & e_N \end{pmatrix} \begin{pmatrix} e_1 \\ e_2 \\ \vdots \\ e_N \end{pmatrix} = \\&= (Y - \hat{Y})'(Y - \hat{Y}) = (Y - X\hat{\beta})'(Y - X\hat{\beta}) = \\&= (Y' - \hat{\beta}'X')(Y - X\hat{\beta}) = Y'Y - Y'X\hat{\beta} - \hat{\beta}'X'Y + \hat{\beta}'X'X\hat{\beta} = \\&= Y'Y - 2\hat{\beta}'X'Y + \hat{\beta}'X'X\hat{\beta}\end{aligned}$$

# Estimació per Mínims Quadrats Ordinaris (MQO)

Així doncs:

$$\text{Min } SQE = \text{Min} \left( Y'Y - 2\hat{\beta}'X'Y + \hat{\beta}'X'X\hat{\beta} \right)$$

$$\begin{aligned} \frac{\partial SQE}{\partial \hat{\beta}} &= \frac{\partial e'e}{\partial \hat{\beta}} = \frac{\partial \left( Y'Y - 2\hat{\beta}'X'Y + \hat{\beta}'X'X\hat{\beta} \right)}{\partial \hat{\beta}} = \\ &= -2X'Y + 2X'X\hat{\beta} \end{aligned}$$

$$\frac{\partial SQE}{\partial \hat{\beta}} = 0 \implies -2X'Y + 2X'X\hat{\beta} = 0$$

$$\hat{\beta}_{MQO} = (X'X)^{-1}X'Y$$

# Estimació per Mínims Quadrats Ordinaris (MQO)

$$\begin{aligned}
 (X'X) &= \begin{bmatrix} 1 & 1 & \cdots & 1 \\ x_{21} & x_{22} & \cdots & x_{2N} \\ \vdots & \vdots & \vdots & \vdots \\ x_{k1} & x_{k2} & \cdots & x_{kN} \end{bmatrix} \begin{bmatrix} 1 & x_{21} & \cdots & x_{k1} \\ 1 & x_{22} & \cdots & x_{k2} \\ \vdots & \vdots & \vdots & \vdots \\ 1 & x_{2N} & \cdots & x_{kN} \end{bmatrix} = \\
 &= \begin{bmatrix} N & \sum_{i=1}^N x_{2i} & \cdots & \sum_{i=1}^N x_{ki} \\ \sum_{i=1}^N x_{2i} & \sum_{i=1}^N x_{2i}^2 & \cdots & \sum_{i=1}^N x_{2i}x_{ki} \\ \cdots & \cdots & \cdots & \cdots \\ \sum_{i=1}^N x_{ki} & \sum_{i=1}^N x_{ki}x_{2i} & \cdots & \sum_{i=1}^N x_{ki}^2 \end{bmatrix}
 \end{aligned}$$

# Estimació per Mínims Quadrats Ordinaris (MQO)

$$(X'Y) = \begin{bmatrix} 1 & 1 & \cdots & 1 \\ x_{21} & x_{22} & \cdots & x_{2N} \\ \vdots & \vdots & \vdots & \vdots \\ x_{k1} & x_{k2} & \cdots & x_{kN} \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^N y_i \\ \sum_{i=1}^N x_{2i} y_i \\ \cdots \\ \sum_{i=1}^N x_{ki} y_i \end{bmatrix}$$

# Estimació per Mínims Quadrats Ordinaris (MQO)

Per comprovar que realment s'ha obtingut un mínim cal calcular la segona derivada i veure si el resultat és positiu:

$$\begin{aligned}\frac{\partial^2 SQE}{\partial \hat{\beta}^2} &= \frac{\partial^2 e'e}{\partial \hat{\beta}^2} = \frac{\partial^2 (Y'Y - 2\hat{\beta}'X'Y + \hat{\beta}'X'X\hat{\beta})}{\partial \hat{\beta}^2} = \\ &= \frac{\partial (-2X'Y + 2X'X\hat{\beta})}{\partial \hat{\beta}} = 2X'X\end{aligned}$$

I aquesta expressió és positiva ja que la matriu  $X'X$  és sempre definida positiva.

Això és així perquè a la diagonal principal d'aquesta matriu hi ha la suma de quadrats de les observacions per a cada variable explicativa.

# Estimació per Mínims Quadrats Ordinaris (MQO)

És important observar que si no es verifica la hipòtesi que les variables explicatives són linealment independents,  $\rho(X) = k$ , aleshores:

- la matriu  $X'X$  és **SINGULAR**,
- és a dir, el seu determinant  $|X'X| = 0$ ,
- no existeix la seva inversa  $\nexists (X'X)^{-1}$ ,
- i no hi ha una solució única al sistema d'EQUACIONS NORMALS MQO:

$$X'Y = (X'X)\hat{\beta}$$



# Propietats estadístiques dels estimadors MQO

## LINEALITAT

Els estimadors MQO són una combinació lineal dels veritables paràmetres poblacionals  $\beta$ , de les variables explicatives i del terme de pertorbació. Així,

$$\begin{aligned}\hat{\beta}_{MQO} &= (X'X)^{-1}X'Y = (X'X)^{-1}X'(X\beta + U) = \\ &= (X'X)^{-1}(X'X)\beta + (X'X)^{-1}(X'U) = \\ &= \beta + (X'X)^{-1}(X'U)\end{aligned}$$

Atès que el terme de pertorbació és una variable aleatòria que es distribueix segons una llei normal, aleshores l'estimador MQO també és una variable aleatòria normal.

# Propietats estadístiques dels estimadors MQO

## ESPERANÇA MATEMÀTICA - BIAIX

Un estimador és **NO ESBIAXAT** quan el seu valor esperat coincideix amb el paràmetre poblacional que es vol estimar:

$$\begin{aligned}E(\hat{\beta}) &= E\left((X'X)^{-1}X'Y\right) = E\left(\beta + (X'X)^{-1}(X'U)\right) = \\&= \beta + (X'X)^{-1}X'E(U) = \beta\end{aligned}$$

$$Biaix(\hat{\beta}) = E(\hat{\beta}) - \beta = 0$$

L'estimador MQO és doncs NO ESBIAXAT.

# Propietats estadístiques dels estimadors MQO

## VARIANÇA - EFICIÈNCIA

$$\begin{aligned} \text{Var}(\hat{\beta}_{MQO}) &= E\left[(\hat{\beta} - \beta)(\hat{\beta} - \beta)'\right] = \\ &= E\left[\left((X'X)^{-1}(X'U)\right)\left((X'X)^{-1}(X'U)\right)'\right] = \\ &= (X'X)^{-1}X' E(UU') X(X'X)^{-1} = \\ &= \sigma_u^2 (X'X)^{-1}X' I_N X(X'X)^{-1} = \\ &= \sigma_u^2 (X'X)^{-1} \end{aligned}$$

# Propietats estadístiques dels estimadors MQO

Matricialment:

$$\text{Var}(\hat{\beta}_{MQO}) = \sigma_u^2 (X'X)^{-1}$$

Per cada paràmetre:

$$\text{Var}(\hat{\beta}_j) = \sigma_u^2 a_{jj} \quad \forall j = 1, 2, \dots, k$$

$a_{jj}$  és l'element  $j$ -éssim de la diagonal principal de  $(X'X)^{-1}$ .

# Propietats estadístiques dels estimadors MQO

## TEOREMA DE GAUSS-MARKOV

L'estimador MQO és **Lineal, No Esbiaixat i Òptim (ELIO)** atès que, de tots els estimadors lineals i no esbiaixats, els estimadors MQO són els que tenen variància mínima.

Sigui  $\tilde{\beta} = \left[ (X'X)^{-1}X' + A \right] Y$  un estimador lineal de  $\beta$ .

Aleshores,

$$\begin{aligned}\tilde{\beta} &= \left[ (X'X)^{-1}X' + A \right] Y = \left[ (X'X)^{-1}X' + A \right] (X\beta + u) = \\ &= \left[ (X'X)^{-1}X'X\beta + (X'X)^{-1}X'u + AX\beta + Au \right] \\ E[\tilde{\beta}] &= \beta + AX\beta\end{aligned}$$

# Propietats estadístiques dels estimadors MQO

L'estimador  $\tilde{\beta}$  serà NO ESBIAIXAT només si  $AX = 0$ .

$$E[\tilde{\beta}] = \beta + AX\beta = \beta$$

Aleshores,

$$\tilde{\beta} = \beta + [(X'X)^{-1}X' + A]U$$

$$\begin{aligned} \text{Var}(\tilde{\beta}) &= E[(\tilde{\beta} - \beta)(\tilde{\beta} - \beta)'] = \\ &= E\left[\left((X'X)^{-1}X' + A\right)UU'\left(A' + X(X'X)^{-1}\right)\right] = \\ &= \left[\left((X'X)^{-1}X' + A\right)E(UU')\left(A' + X(X'X)^{-1}\right)\right] = \\ &= \sigma_u^2 \left[(X'X)^{-1}X'A' + AX(X'X)^{-1} + AA' + (X'X)^{-1}\right] \\ &= \sigma_u^2 \left[AA' + (X'X)^{-1}\right] = \sigma_u^2 AA' + \sigma_u^2 (X'X)^{-1} \end{aligned}$$

# Propietats estadístiques dels estimadors MQO

$$\begin{cases} \text{Var}(\hat{\beta}_{MQO}) = \sigma_u^2 (X'X)^{-1} \\ \text{Var}(\tilde{\beta}) = \sigma_u^2 AA' + \sigma_u^2 (X'X)^{-1} \end{cases}$$

$$\text{Var}(\tilde{\beta}) - \text{Var}(\hat{\beta}_{MQO}) = \sigma_u^2 AA' \quad \text{i} \quad \text{Var}(\tilde{\beta}) > \text{Var}(\hat{\beta}_{MQO})$$

atès que  $AA'$  és semidefinida positiva.

Així doncs l'estimador MQO és de variància mínima.

Aquesta propietat és important perquè l'absència de biaix no garanteix que el valor numèric d'un estimador estigui molt a prop del veritable valor poblacional, sinó que només diu que en mitjana coincidirà amb aquest valor (o que la seva distribució estarà centrada al voltant del valor poblacional).

# Propietats estadístiques dels estimadors MQO

## CONSISTÈNCIA

Un estimador és consistent si s'aproxima al seu valor poblacional a mesura que s'incrementa la mida de la mostra.

També es diu que un estimador és consistent quan el límit del seu error quadràtic mig quan  $N$  tendeix a infinit és igual a 0:

$$\lim_{n \rightarrow \infty} EQM(\hat{\beta}) = 0$$



# Propietats estadístiques dels estimadors MQO

Sabent que:

$$EQM(\hat{\beta}) = Var(\hat{\beta}) + [Biaix(\hat{\beta})]^2$$

i que:

$$Var(\hat{\beta}_{MQO}) = \sigma_u^2 (X'X)^{-1} \quad Biaix(\hat{\beta}_{MQO}) = 0$$

$$\begin{aligned} \lim_{n \rightarrow \infty} EQM(\hat{\beta}_{MQO}) &= \lim_{n \rightarrow \infty} Var(\hat{\beta}_{MQO}) = \\ &= \lim_{n \rightarrow \infty} \sigma_u^2 (X'X)^{-1} = \\ &= \lim_{n \rightarrow \infty} \frac{\sigma_u^2}{N} \left( \frac{X'X}{N} \right)^{-1} = 0 \end{aligned}$$

Suposem que  $\left( \frac{X'X}{N} \right)^{-1}$  existeix i és un número finit.

# Propietats estadístiques dels estimadors MQO

L'estimador MQO és doncs:

$$\hat{\beta}_{MQO} \sim N(\beta, \sigma_u^2 (X'X)^{-1})$$

$$\hat{\beta}_{j,MQO} \sim N(\beta_j, \sigma_u^2 a_{jj}) \quad \forall j = 1, 2, \dots, k$$

# Anàlisi dels residus de l'estimació

S'utilitzen els errors o residus de l'estimació com estimadors de les pertorbacions:

$$e_{MQO} = Y - X\hat{\beta}_{MQO}$$

## Propietats dels errors o residus de l'estimació MQO

1<sup>a</sup>) *El vector  $e$  és una combinació lineal de la variable endògena.*

$$\begin{aligned} e_{MQO} &= Y - \hat{Y} = Y - X\hat{\beta} = Y - X(X'X)^{-1}X'Y = \\ &= [I - X(X'X)^{-1}X'] Y = MY \end{aligned}$$

# Anàlisi dels residus de l'estimació

on  $M = I - X(X'X)^{-1}X'$  és:

- una matriu quadrada de dimensió  $N \times N$
- simètrica
- idempotent ( $MM = M$ ). Donat que és simètrica es compleix també que  $MM' = M'M = M'M' = M$
- matriu singular:  $|M| = 0$
- ortogonal respecte  $X$  ( $MX = 0$ )
- traça  $M = N - k$

# Anàlisi dels residus de l'estimació

2<sup>a</sup>) *e és una combinació lineal de U*

$$e = MY = M(X\beta + U) = MX\beta + MU = MU$$

3<sup>a</sup>) *e és ortogonal a la matriu X*

$$e'X = (MY)'X = (MU)'X = U'M'X = 0$$

$$X'e = X'(MY) = 0$$

# Anàlisi dels residus de l'estimació

4<sup>a</sup>) *La mitjana mostral dels residus és igual a 0 quan el model té terme independent*

$$X'e = \begin{bmatrix} 1 & 1 & \cdots & 1 \\ x_{21} & x_{22} & \cdots & x_{2N} \\ \vdots & \vdots & \vdots & \vdots \\ x_{k1} & x_{k2} & \cdots & x_{kN} \end{bmatrix} \begin{bmatrix} e_1 \\ e_2 \\ \vdots \\ e_N \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

$$\sum_{i=1}^N e_i = 0 \quad \text{i} \quad \bar{e} = \frac{1}{N} \sum_{i=1}^N e_i = 0$$

# Anàlisi dels residus de l'estimació

5<sup>a</sup>) *e es distribueix segons una llei Normal*

Atès que  $e = MU$  i que  $U \sim N(0, \sigma_u^2 I_N)$ , llavors:

$$e \sim N(0, \sigma_u^2 M)$$

$$E(e) = E(MU) = ME(U) = 0$$

$$\begin{aligned} \text{Var}(e) &= E(ee') = E(MUU'M') = \\ &= ME(UU')M' = \sigma_u^2 MM' = \sigma_u^2 M \end{aligned}$$

Per tant, els residus no són esfèrics

# Estimació de la variància del terme de pertorbació

Donat que  $U$  és un terme no observable, tampoc ho és la seva variància  $\sigma_u^2 I_N$ .

Aquest fet és molt important donat que necessitem conèixer aquesta variància del terme de pertorbació per tal de poder fer contrastos relatius al vector de coeficients estimats per MQO.

$$\hat{\beta}_{MQO} \sim N\left(\beta, \sigma_u^2 (X'X)^{-1}\right)$$

Així, precisarem d'una estimació de  $\sigma_u^2$ .

Per obtenir-la, partirem de la idea que el vector  $e$  de residus de l'estimació MQO és una estimació del vector  $U$ .



## Estimació de la variància del terme de pertorbació

$$\begin{aligned} E(SQE) &= E(e'e) = E[(MU)'(MU)] = E[U'M'MU] = \\ &= E[U'MU] = E[\text{tr}(UU'M)] = E[\text{tr}(MUU')] = \\ &= \text{tr}(E[MUU']) = \text{tr}(ME[UU']) = \text{tr}(M\sigma_u^2 I_N) = \\ &= \sigma_u^2 \text{tr}(MI_N) = \sigma_u^2 \text{tr}(M) = \sigma_u^2 (N - k) \end{aligned}$$

D'aquesta manera, obtenim l'estimador no esbiaixat de la variància del terme de pertorbació com:

$$\hat{\sigma}_{u,MQO}^2 = \frac{e'e}{N - k}$$

# Estimació de la variància del terme de pertorbació

Per tant tindrem que:

$$\text{Var}(\hat{\beta}) = \sigma_u^2 (X'X)^{-1} \implies \widehat{\text{Var}}(\hat{\beta}) = \hat{\sigma}_u^2 (X'X)^{-1}$$

$$\text{Var}(\hat{\beta}) = \sigma_u^2 a_{jj} \implies \widehat{\text{Var}}(\hat{\beta}) = \hat{\sigma}_u^2 a_{jj}$$

Calcularem la SQE a partir de qualsevol d'aquestes tres vies:

$$\begin{aligned} e'e &= \sum_{i=1}^n e_i^2 \\ e'e &= Y'Y - \hat{\beta}'X'Y \\ e'e &= Y'Y - \hat{Y}'\hat{Y} \end{aligned}$$

# Estimació Màxim Versemblant (MV)

El mètode de màxima versemblança proposa com a estimador del paràmetre aquell valor que maximitza la probabilitat d'obtenir les observacions mostrals disponibles.

Aquest mètode d'estimació es basa en les hipòtesis que s'estableixin per a la distribució de les variables aleatòries que apareixen en el model:

$$Y = X\beta + U$$

suposant que:

$$U \sim N(0, \sigma_u^2 I_N)$$

# Estimació Màxim Versemblant (MV)

A partir de la hipòtesi sobre la distribució de  $U$  es deriva que cadascun dels termes de pertorbació tindrà la funció de densitat següent:

$$f(u_i) = \frac{1}{\sqrt{2\pi\sigma_u^2}} \exp \left\{ -\frac{1}{2\sigma_u^2} (u_i)^2 \right\} \quad \forall i = 1, 2, \dots, N$$

Amb una funció de densitat conjunta pel vector  $U$  (atès que les  $u_i$  són i.i.d.):

$$\begin{aligned} f(U) &= \prod_{i=1}^N f(u_i) = (2\pi\sigma_u^2)^{-N/2} \exp \left\{ -\frac{1}{2\sigma_u^2} \sum_{i=1}^N u_i^2 \right\} = \\ &= (2\pi)^{-N/2} (\sigma_u^2)^{-N/2} \exp \left\{ -\frac{1}{2\sigma_u^2} U'U \right\} \end{aligned}$$

# Estimació Màxim Versemblant (MV)

Donat que  $U$  es distribueix segons una normal multivariant d'ordre  $N$ , aleshores  $Y$  també ho farà (atès que  $Y = X\beta + U$ ):

$$f^*(Y) = f(U) = (2\pi)^{-N/2}(\sigma_u^2)^{-N/2} \exp \left\{ -\frac{1}{2\sigma_u^2} U'U \right\}$$

Per aconseguir que la funció de densitat sigui una funció de versemblança, s'haurà d'expressar el vector  $U$  en funció de  $Y$   
 $U = Y - X\beta$ , de manera que:

$$L(Y; \beta, \sigma_u^2) = (2\pi)^{-N/2}(\sigma_u^2)^{-N/2} \exp \left\{ -\frac{1}{2\sigma_u^2} (Y - X\beta)'(Y - X\beta) \right\}$$

# Estimació Màxim Versemblant (MV)

Els estimadors per màxima versemblança s'obtenen a partir de maximitzar la funció de versemblança  $L$ .

Així, caldrà calcular les derivades parcials de la funció de versemblança respecte  $\beta$  i  $\sigma_u^2$ , i igualar-les a 0.

Per facilitar els càlculs, aquesta maximització es farà, no de la funció de versemblança, sinó del seu logaritme:

$$\ln L(Y; \beta, \sigma_u^2) = -\frac{N}{2} \ln(2\pi) - \frac{N}{2} \ln(\sigma_u^2) - \frac{1}{2\sigma_u^2} (Y - X\beta)'(Y - X\beta)$$

# Estimació Màxim Versemblant (MV)

$$\frac{\partial \ln L}{\partial \beta} = -\frac{1}{2\hat{\sigma}_u^2} \left[ -2X'(\Upsilon - X\hat{\beta}) \right] = 0$$

$$\frac{\partial \ln L}{\partial \sigma_u^2} = -\frac{N}{2\hat{\sigma}_u^2} + \frac{1}{2\hat{\sigma}_u^4} \left[ (\Upsilon - X\hat{\beta})'(\Upsilon - X\hat{\beta}) \right] = 0$$

Aïllant, obtindrem les estimacions per màxima versemblança de  $\beta$  i  $\sigma_u^2$ :

$$\hat{\beta}_{MV} = (X'X)^{-1}X'\Upsilon$$

$$\hat{\sigma}_{u,MV}^2 = \frac{(\Upsilon - X\hat{\beta})'(\Upsilon - X\hat{\beta})}{N} = \frac{e'e}{N}$$

# Estimació Màxim Versemblant (MV)

$\hat{\beta}_{MQO} = \hat{\beta}_{MV}$  de manera que l'estimador MV tindrà les mateixes propietats que l'estimador per MQO.

No succeeix el mateix, però, amb l'estimació MV de  $\sigma_u^2$ . De fet aquest estimador serà esbiaixat:

$$\begin{aligned} E(\hat{\sigma}_{u.MV}^2) &= E\left[\frac{e'e}{N}\right] = \frac{1}{N}E[e'e] = \frac{1}{N}E\left[\sigma_u^2(N-k)\right] = \\ &= \frac{N-k}{N}\sigma_u^2 \neq \sigma_u^2 \end{aligned}$$

Tanmateix, l'estimador MV de  $\sigma_u^2$  és asimptòticament no esbiaixat donat que el biaix s'aproxima a 0 a mesura que creix la mida mostral.



# Econometria

## Tema 2: MRLM: Especificació i Estimació

Ramon Alemany

Grau Estadística UB-UPC

**Curs 2017-18**