



**MÈTODES NO PARAMÈTRICS I DE
REMOSTREIG. Grau en Estadística. 2014-15**

Prova de síntesi. 18 de juny de 2015.

Respon als mateixos fulls de l'examen. Si no tens prou espai: fes servir la darrera plana, en blanc, o fulls "UB" addicionals.

Com s'haurà pogut comprovar, aquest examen es basa en les dades del parcial d'aquest curs i part de les preguntes són iguals o molt similars a les que es van fer llavors. Si s'ha fet allò que en el seu moment vaig demanar (revisar i entendre a fons la solució del parcial), no s'haurà tingut cap dificultat en respondre aquesta part de l'examen; crec que es pot exigir una resposta gairebé perfecta d'aquesta part. La resposta a tot aquest grup de preguntes es pot trobar a la solució del parcial, alguna vegada amb petites adaptacions. Només ressaltaré alguns errors greus i detectats amb excessiva freqüència (i molt impropis d'un graduat o graduada en estadística).

Solament detallaré la solució de les preguntes realment noves.

lloc	agost	novembre
1	8.1	11.2
2	10.0	16.3
3	16.5	15.3
4	13.6	15.6
5	9.5	10.5
6	8.3	15.5
7	18.3	12.7
8	13.3	11.1
9	7.9	19.9
10	8.1	20.4
11	8.9	14.2
12	12.6	12.7
13	13.4	36.8

Problema 1. En un estudi sobre els efectes de la contaminació en els boscos, es van escollir 13 llocs a l'atzar d'una zona molt contaminada, i per cada lloc es va mesurar el nivell d'alumini (en micrograms per gram de fusta) d'un pollancre. Per cada lloc la mesura es va fer el mes d'agost i el mes de novembre.

Respon les següents qüestions, utilitzant els llistats del final de l'enunciat de l'examen quan ho creguis convenient. En tot moment considerarem un nivell de significació de 0.05 o un nivell de confiança de 0.95. Quan realitzis una prova d'hipòtesis has d'expressar clarament les hipòtesis nul·la i alternativa.

- 1) Realitza una prova d'hipòtesis basada en rangs que sigui adequada per a intentar demostrar que la mediana del nivell d'alumini ha crescut d'agost a novembre. En concret, respon les següents qüestions:

- a. Nom de la prova triada, raons per triar-la i condicions de validesa (0.5 punts):

En indicar les condicions de validesa ha estat bastant freqüent una resposta molt absurda, de l'estil de "les medianes han de ser

COGNOMS, NOM:	FIRMA:

contínues i simètriques'. Les medianes poblacionals són constants, no variables aleatòries. Allò que ha de ser continuu i simètric és la distribució de la variable diferència, condició (la de simetria) que queda assegurada per la igualtat de les distribucions (llevat de paràmetre de localització) del nivell d'alumini a l'agost i al novembre. Lògicament, aquesta igualtat de distribucions inclou la dels paràmetres de dispersió.

- b. Hipòtesis nul·la i alternativa, valor de l'estadística de test (justificant els passos per obtenir-lo) i conclusió final (0.75 punts):
- 2) Que l'increment de contaminació sigui significatiu (o no) i que sigui important no són la mateixa cosa. Per valorar aquest segon aspecte pot ser útil disposar d'una estimació de la mediana de les diferències.
 - a. Indica el valor de l'estimació puntual que correspondria a la prova d'hipòtesis realitzada a l'apartat anterior (0.5 punts):
 - b. Calcula l'interval de confiança **bilateral** que correspondria a la prova d'hipòtesis realitzada a l'apartat anterior (estadísticament, seria un interval unilateral, però aquí es demana el bilateral, que també pot ser interessant quant a la interpretació) (0.75 punts):
- 3) Realitza una prova de permutacions per intentar demostrar que el nivell d'alumini mitjà ha variat d'agost a novembre. Indica clarament, explicant els passos o càlculs realitzats quan calgui:
 - a. Les hipòtesis contrastades i el valor de l'estadístic de test (0.5 punts):
 - b. El p-valor i la conclusió final (0.5 punts):
- 4) Suposa que, en les mateixes condicions d'abans (els mateixos llocs del bosc en mesos diferents, etc.), el nivell d'alumini s'hagués mesurat en més de 2 mesos (per exemple: agost, octubre i desembre). Indica el nom d'una prova basada en rangs adequada per a intentar demostrar que la mediana del nivell d'alumini ha variat segons els mesos (0.5 punts).
- 5) Continuant amb la suposició de la pregunta anterior (més de 2 mesos), explica com realitzaries una prova de permutacions per demostrar diferències en les mitjanes dels mesos (no l'has de fer, només explicar com ho faries). En concret, respon les següents qüestions:

(Evidentment aquesta pregunta té molta relació amb el treball de permutacions que es va proposar, de fet planteja una situació idèntica a la plantejada allí.)

- a. Què caldria permutar? (0.5 punts)
Per separat dins cada lloc del bosc, els 3 mesos.
- b. Justifica **si seria possible** (o no) fer una prova de permutacions **exacta** per aquestes dades (0.5 punts):
Llevat que es disposés de mitjans extraordinàriament potents, NO seria possible fer una prova de permutacions exacta. Dins cada lloc del bosc hi ha $3! = 6$ permutacions possibles dels valors dels mesos. Com que tenim una mostra de 13 llocs, el

nombre de permutacions possibles seria 6^{13} que és una quantitat enorme, més de 13000 milions.

Problema 2. Per les mateixes dades del problema anterior, atès que cada parella de valors de contaminació per alumini es refereix al mateix lloc del bosc, seria d'esperar que hi hagués un cert grau de dependència entre les variables $X = \text{'agost'}$ i $Y = \text{'novembre'}$.

Respon les següents qüestions, utilitzant els llistats del final de l'enunciat quan ho creguis convenient. En tot moment considerarem un nivell de significació de 0.05 o un nivell de confiança de 0.95.

- 1) Pel coeficient de correlació de Kendall, ignorant el empats:
 - a. Obtén la seva estimació puntual (0.5 punts):
 - b. Determina si és significativament diferent de zero, indicant les hipòtesis, l'estadístic de test, el valor crític de les taules i la conclusió final (0.5 punts):
 - c. El resultat del test anterior, demostra que els nivells d'alumini d'agost i novembre són estocàsticament independents? (0.5 punts)

A la pregunta anterior no es pot rebutjar H_0 d'independència.

Malauradament continua fallant bastant sovint un concepte molt bàsic: continuen prenent això com una demostració que H_0 és certa, que les variables són independents. L'única conclusió admissible és que no tenim prou evidència per rebutjar H_0 , no que sigui certa. No rebutjar una hipòtesi nul·la no la demostra.

- 2) Indica justificadament el valor del coeficient de correlació de Spearman (0.5 punts):
- 3) Realitza una prova de permutacions per a determinar si el coeficient de correlació lineal de Pearson entre X i Y és negatiu. En concret:
 - a. Indica les hipòtesis nul·la i alternativa i el valor de l'estadístic de test (0.5 punts):
 - b. Calcula el p-valor i indica la conclusió final (0.5 punts):
- 4) Calcula els següents intervals de confiança bootstrap (no paramètric) **bilaterals** pel coeficient de correlació de Pearson ρ :

- a. Percentil bootstrap (0.5 punts):

Agafem directament els quantils mostrals 0.025 i 0.975 de la mostra de 10000 valors bootstrap de r (ordre:

`quantile(r.boots["r",], probs = c(0.025, 0.975))`). Per tant el resultat demanat serà $[-0.6081624, 0.4646415]$.*

- b. Bootstrap-t (0.5 punts):

Recordem que, per aquest cas concret, la fórmula d'aquest

interval de confiança seria: $\left[r - t_{0.975}^ \widehat{SE}_r, r - t_{0.025}^* \widehat{SE}_r \right]$.*

Els valors t^ corresponen als quantils mostrals 0.025 i 0.975*

(però fixeu-vos en l'ordre que els restem!) de la mostra de

10000 valors bootstrap $t^ = (r^* - r) / \widehat{SE}_r$. Els obtindríem de*

la sentència `quantile(t.boots, probs = c(0.975, 0.025))`, ja

directament en l'ordre desitjat. Serien per tant 1.80654 i -3.13579. r i \widehat{SE}_r són les estimacions de la correlació i del seu error estàndard directament obtingudes de les dades originals, per tant són 0.01669772 i 0.3161396 respectivament (i no 0.05319807 i 0.3153328 que només eren exemples de com es calculen aquests estadístics sobre remostres bootstrap). Finalment:
 $[0.01669772 - 1.80654 \cdot 0.3161396, 0.01669772 + 3.13579 \cdot 0.3161396] = [-0.5544211, 1.0080451]$.

L'extrem superior d'aquest interval no té sentit com a valor de coeficient de correlació. Encara que numèricament aquestes coses poden passar, tindria més sentit deixar reduït l'interval a $[-0.5544211, 1]$.

c. Bootstrap-t simetritzat (0.5 punts):

Aquest interval seria $r \pm t_{[0.95]}^* \widehat{SE}_r$ on $t_{[0.95]}^*$ correspon al valor positiu tal que, entre $-t_{[0.95]}^*$ i $t_{[0.95]}^*$ hi ha una proporció 0.95 dels valors t^* . Per tant és 2.654493, obtingut de `quantile(abs(t.boots), probs = 0.95)`. Tindrem: $0.01669772 \pm 2.654493 \cdot 0.3161396 = [-0.8224926, 0.8558881]$.

d. A la darrera pàgina de llistats, a partir del comentari: `# 10000 rèpliques bootstrap no paramètric d'r i del seu error estàndard`: hi ha les instruccions R per realitzar la simulació bootstrap i obtenir els intervals de confiança anteriors. Indica **què caldria canviar** per obtenir els intervals de confiança **bootstrap paramètric** suposant que (X,Y) segueix una distribució normal bivariant:

L'única cosa que caldria canviar seria la manera d'obtenir les resmostres bootstrap. Les ordres que generen remostres no paramètriques:

```
i.boot = sample(1:n, replace = TRUE)
r.boot = cor(x[i.boot], y[i.boot])
```

es podrien substituir per qualsevol codi vàlid que generés valors segons una distribució normal bivariant amb vector de mitjanes i matriu de covariàncies estimats a partir de les dades originals.

Totes les altres coses es mantenen igual, en particular la manera d'estimar l'error estàndard de la correlació mostral, que de fet ja responia a un enfoc "paramètric normal".

La manera concreta d'implementar-ho no és important de cara a la resposta, el que compta és la idea (es considerarà bé si s'explica què caldria fer, encara que no es concreti en codi R). Una manera de fer-ho podria ser substituir les dues sentències anteriors per:

```
r.boot = cor(rmvnorm(1, mean = m, sigma = s))[2,1]
```

havent afegit, abans del “replicate” instruccions com:

```
library(mvtnorm) # Carrego la llibreria on és “rmvnorm”
# Estimo els paràmetres:
m = colMeans(pollancres)
s = cov(pollancres)
```

No confonguem “bootstrap paramètric normal” amb

“paramètric normal”. En aquest segon cas podria ser que tinguéssim una forma analítica d'obtenir els valors crítics t .

En canvi, sota l'enfoc bootstrap, “paramètric” voldria dir que les remostres bootstrap s'obtidrien generant una distribució assumida com a vàlida (normal bivariant a la present situació), estimant els paràmetres d'aquesta distribució a partir de les dades originals, i buscant els valors crítics t com a quantils empírics dels molts valors t^* simulats.

LLISTATS R

```
> # *****
> # PROBLEMA 1
> # *****
> pollancres = read.table("pollancres.txt", header = TRUE)
>
> agost = pollancres$agost
> novembre = pollancres$novembre
>
> # Diferència dins cada lloc (13 valors possibles):
> d = agost - novembre
> d
[1] -3.1 -6.3 1.2 -2.0 -1.0 -7.2 5.6 2.2 -12.0 -12.3 -5.3 -0.1 -23.4
> n = length(d)
> n
[1] 13
> # Valors absoluts de les diferències:
> abs.d = abs(d)
> abs.d
[1] 3.1 6.3 1.2 2.0 1.0 7.2 5.6 2.2 12.0 12.3 5.3 0.1 23.4
> #
> # Rangs dels valors absoluts de les diferències:
> rabs.d = rank(abs.d)
> rabs.d
[1] 6 9 3 4 2 10 8 5 11 12 7 1 13
> #
> # Suma de rangs de diferències positives:
> r.plus = sum(rabs.d[d > 0])
> r.plus
[1] 16
> # Suma de rangs de diferències negatives:
> r.minus = sum(rabs.d[d < 0])
> r.minus
[1] 75
> #
> # Mediana de totes les diferències:
> median(d)
```

```

[1] -3.1
> # Mediana de totes les semisums entre diferències:
> sSums = outer(d, d, "+") / 2
> median(sSums[lower.tri(sSums, diag = TRUE)])
[1] -4.1
> #
> #
> #
> # Totes les dades en un únic vector:
> alumini = c(agost, novembre)
>
> N = length(alumini)
> N
[1] 26
> n1 = n
> n2 = n
>
> # rang de cada observació dins el total de N = 26 valors:
> rangs <- rank(alumini)
> rangs
[1] 2.5 7.0 22.0 16.0 6.0 4.0 23.0 14.0 1.0 2.5 5.0 11.0 15.0 10.0 21.0
[16] 18.0 20.0 8.0 19.0 12.5 9.0 24.0 25.0 17.0 12.5 26.0
> # rangs de les observacions "agost"
> rangs[1:n1]
[1] 2.5 7.0 22.0 16.0 6.0 4.0 23.0 14.0 1.0 2.5 5.0 11.0 15.0
> # rangs de les observacions "novembre"
> rangs[(n1+1):N]
[1] 10.0 21.0 18.0 20.0 8.0 19.0 12.5 9.0 24.0 25.0 17.0 12.5 26.0
>
> # Sumes de rangs dins cada grup:
> sum(rangs[1:n1])
[1] 129
> sum(rangs[(n1+1):N])
[1] 222
>
> # Totes les diferències possibles (13 * 13 = 169 valors)
> # entre "agost" i "novembre":
> dd = outer(agost, novembre, "-")
> dd
      [,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8] [,9] [,10] [,11] [,12] [,13]
[1,] -3.1 -8.2 -7.2 -7.5 -2.4 -7.4 -4.6 -3.0 -11.8 -12.3 -6.1 -4.6 -28.7
[2,] -1.2 -6.3 -5.3 -5.6 -0.5 -5.5 -2.7 -1.1 -9.9 -10.4 -4.2 -2.7 -26.8
[3,] 5.3 0.2 1.2 0.9 6.0 1.0 3.8 5.4 -3.4 -3.9 2.3 3.8 -20.3
[4,] 2.4 -2.7 -1.7 -2.0 3.1 -1.9 0.9 2.5 -6.3 -6.8 -0.6 0.9 -23.2
[5,] -1.7 -6.8 -5.8 -6.1 -1.0 -6.0 -3.2 -1.6 -10.4 -10.9 -4.7 -3.2 -27.3
[6,] -2.9 -8.0 -7.0 -7.3 -2.2 -7.2 -4.4 -2.8 -11.6 -12.1 -5.9 -4.4 -28.5
[7,] 7.1 2.0 3.0 2.7 7.8 2.8 5.6 7.2 -1.6 -2.1 4.1 5.6 -18.5
[8,] 2.1 -3.0 -2.0 -2.3 2.8 -2.2 0.6 2.2 -6.6 -7.1 -0.9 0.6 -23.5
[9,] -3.3 -8.4 -7.4 -7.7 -2.6 -7.6 -4.8 -3.2 -12.0 -12.5 -6.3 -4.8 -28.9
[10,] -3.1 -8.2 -7.2 -7.5 -2.4 -7.4 -4.6 -3.0 -11.8 -12.3 -6.1 -4.6 -28.7
[11,] -2.3 -7.4 -6.4 -6.7 -1.6 -6.6 -3.8 -2.2 -11.0 -11.5 -5.3 -3.8 -27.9
[12,] 1.4 -3.7 -2.7 -3.0 2.1 -2.9 -0.1 1.5 -7.3 -7.8 -1.6 -0.1 -24.2
[13,] 2.2 -2.9 -1.9 -2.2 2.9 -2.1 0.7 2.3 -6.5 -7.0 -0.8 0.7 -23.4
>
> # mediana de les 169 diferències:
> median(dd)
[1] -3.2
>
> # Les 169 diferències ordenades (continua a la pàgina següent):
> sort(dd)
[1] -28.9 -28.7 -28.7 -28.5 -27.9 -27.3 -26.8 -24.2 -23.5 -23.4 -23.2 -20.3 -18.5
[14] -12.5 -12.3 -12.3 -12.1 -12.0 -11.8 -11.8 -11.6 -11.5 -11.0 -10.9 -10.4 -10.4
[27] -9.9 -8.4 -8.2 -8.2 -8.0 -7.8 -7.7 -7.6 -7.5 -7.5 -7.4 -7.4 -7.4
[40] -7.4 -7.3 -7.3 -7.2 -7.2 -7.2 -7.1 -7.0 -7.0 -6.8 -6.8 -6.7 -6.6
[53] -6.6 -6.5 -6.4 -6.3 -6.3 -6.3 -6.1 -6.1 -6.1 -6.0 -5.9 -5.8 -5.6
[66] -5.5 -5.3 -5.3 -4.8 -4.8 -4.7 -4.6 -4.6 -4.6 -4.6 -4.4 -4.4 -4.2
[79] -3.9 -3.8 -3.8 -3.7 -3.4 -3.3 -3.2 -3.2 -3.2 -3.1 -3.1 -3.0 -3.0
[92] -3.0 -3.0 -2.9 -2.9 -2.9 -2.8 -2.7 -2.7 -2.7 -2.7 -2.6 -2.4 -2.4
[105] -2.3 -2.3 -2.2 -2.2 -2.2 -2.2 -2.1 -2.1 -2.0 -2.0 -1.9 -1.9 -1.7
[118] -1.7 -1.6 -1.6 -1.6 -1.6 -1.2 -1.1 -1.0 -0.9 -0.8 -0.6 -0.5 -0.1
[131] -0.1 0.2 0.6 0.6 0.6 0.7 0.7 0.9 0.9 0.9 1.0 1.2 1.4 1.5
[144] 2.0 2.1 2.1 2.2 2.2 2.3 2.3 2.4 2.5 2.7 2.8 2.8 2.9
[157] 3.0 3.1 3.8 3.8 4.1 5.3 5.4 5.6 5.6 6.0 7.1 7.2 7.8
> #
> #
> # Permutacions sobre el vector de 13 diferències
> # =====
> # Enumeració de TOTES les permutacions possibles, maneres segons les quals
> # podem permutar DINS cada parella de valors (agost, novembre).

```

```

> # En altres paraules, maneres possibles segons les quals podem donar
> # un signe - o + a les diferències:
> sgn = c(-1, +1)
> signsTab = expand.grid(as.data.frame(matrix(rep(sgn, n), ncol = n)))
> signsTab = apply(signsTab, 1, "*", abs.d)
> # Cada columna de 'signsTab' conté les diferències sobre una permutació
> # possible. Per exemple les 10 primeres:
> signsTab[,1:10]
      [,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8] [,9] [,10]
v1    -3.1  3.1 -3.1  3.1 -3.1  3.1 -3.1  3.1 -3.1  3.1
v2    -6.3 -6.3  6.3  6.3 -6.3 -6.3  6.3  6.3 -6.3 -6.3
v3    -1.2 -1.2 -1.2 -1.2  1.2  1.2  1.2  1.2 -1.2 -1.2
v4    -2.0 -2.0 -2.0 -2.0 -2.0 -2.0 -2.0 -2.0  2.0  2.0
v5    -1.0 -1.0 -1.0 -1.0 -1.0 -1.0 -1.0 -1.0 -1.0 -1.0
v6    -7.2 -7.2 -7.2 -7.2 -7.2 -7.2 -7.2 -7.2 -7.2 -7.2
v7    -5.6 -5.6 -5.6 -5.6 -5.6 -5.6 -5.6 -5.6 -5.6 -5.6
v8     -2.2 -2.2 -2.2 -2.2 -2.2 -2.2 -2.2 -2.2 -2.2 -2.2
v9   -12.0 -12.0 -12.0 -12.0 -12.0 -12.0 -12.0 -12.0 -12.0 -12.0
v10  -12.3 -12.3 -12.3 -12.3 -12.3 -12.3 -12.3 -12.3 -12.3 -12.3
v11   -5.3 -5.3 -5.3 -5.3 -5.3 -5.3 -5.3 -5.3 -5.3 -5.3
v12   -0.1 -0.1 -0.1 -0.1 -0.1 -0.1 -0.1 -0.1 -0.1 -0.1
v13 -23.4 -23.4 -23.4 -23.4 -23.4 -23.4 -23.4 -23.4 -23.4 -23.4
> # Nombre de permutacions possibles:
> nperm = ncol(signsTab)
> nperm
[1] 8192
> #
> # Estimació de la mitjana de les diferències sobre cada possible permutació:
> m.perm = apply(signsTab, 2, mean)
> #
> # La mitjana de les diferències a la mostra original és:
> m.d = mean(d)
> m.d
[1] -4.9
> #
> sum(m.perm >= m.d)
[1] 8070
> sum(abs(m.perm) >= abs(m.d))
[1] 246
> sum(m.perm <= m.d)
[1] 123
>
>
>
>
>
> # *****
> # PROBLEMA 2
> # *****
> x = pollancres$agost
> y = pollancres$novembre
>
> # Taula amb totes les possibles diferències entre x[i] i x[j]:
> difs.x = outer(x, x, "-")
> # Descartem les diferències de la diagonal (i == j) i de la meitat
> # triangular superior:
> difs.x = difs.x[ltri <- lower.tri(difs.x)]
> # Totes les possibles diferències entre y[i] i y[j]:
> difs.y = outer(y, y, "-")[ltri]
> #
> # Nombre de concordances:
> concor = sum(sign(difs.x)*sign(difs.y) > 0)
> concor
[1] 33
> # Nombre de discordances:
> discor = sum(sign(difs.x)*sign(difs.y) < 0)
> discor
[1] 43
> #
> #
> #
> cor.test(rank(x), rank(y))

```

Pearson's product-moment correlation

data: rank(x) and rank(y)

```
t = -0.4612, df = 11, p-value = 0.6536
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
-0.6401437 0.4471824
sample estimates:
      cor
-0.137741
```

```
> #
> #
> # Coeficient de correlació lineal de Pearson sobre la mostra original:
> r = cor(x,y)
> r
[1] 0.01669772
> # En tot el problema, com a estimació de l'error estàndard del coeficient
> # de correlació de Pearson mostral farem servir l'estimació paramètrica
> # normal  $(1 - r^2) / \sqrt{n - 3}$ :
> se.r =  $(1 - r*r) / \sqrt{n - 3}$ 
> se.r
[1] 0.3161396
>
> # Una permutació aleatòria del vector 'y':
> y.perm = sample(y, replace = FALSE)
> # 9999 permutacions aleatòries i càlcul de la correlació:
> nperm = 9999
> set.seed(5719)
> r.perms = replicate(nperm, cor(x, sample(y, replace = FALSE)))
> #
> sum(r.perms >= r)
[1] 4291
> sum(abs(r.perms) >= abs(r))
[1] 9645
> sum(r.perms <= r)
[1] 5708
>
> # 1 remostra bootstrap:
> # Determino quins llocs formaran part de la mostra aleatòria i amb
> # reemplaçament:
> i.boot = sample(1:n, replace = TRUE)
> i.boot
[1] 8 12 1 3 3 7 13 6 1 7 9 1 4
> # Remostra bootstrap:
> x[i.boot]
[1] 13.3 12.6 8.1 16.5 16.5 18.3 13.4 8.3 8.1 18.3 7.9 8.1 13.6
> y[i.boot]
[1] 11.1 12.7 11.2 15.3 15.3 12.7 36.8 15.5 11.2 12.7 19.9 11.2 15.6
> # Correlació sobre la remostra bootstrap:
> r.boot = cor(x[i.boot], y[i.boot])
> r.boot
[1] 0.05319807
> # (és el que normalment hauríem anomenat un valor  $r^*$ )
> #
> #
> # Error estàndard de la correlació mostral per aquesta remostra
> # bootstrap concreta (se*, atenció, NO és l'error estàndard de la
> # correlació mostral per les dades originals):
> se.boot =  $(1 - r.boot*r.boot) / \sqrt{n - 3}$ 
> se.boot
[1] 0.3153328
> #
> #
> #
> # 10000 rèpliques bootstrap no paramètric d'r i del seu error estàndard:
> nboot = 10000
> set.seed(5719)
> r.boots = replicate(nboot,
+ {
+   i.boot = sample(1:n, replace = TRUE)
+   r.boot = cor(x[i.boot], y[i.boot])
+   se.boot =  $(1 - r.boot*r.boot) / \sqrt{n - 3}$ 
+   c(r.boot, se.boot)
+ })
> rownames(r.boots) = c("r*", "se*")
> # Faltava dividir per  $\sqrt{n - 3}$ :
> r.boots[2,] = r.boots[2,] /  $\sqrt{n - 3}$ 
```



```

> #
> # r.boots és una matriu de 2 files i 10000 columnes,
> # la primera fila són les rèpliques bootstrap de la correlació,
> # la segona fila son els corresponents errors estàndard.
> # Les 10 primeres rèpliques bootstrap:
> r.boots[,1:10]
      [,1]      [,2]      [,3]      [,4]      [,5]      [,6]      [,7]
r* -0.2623799 0.4303000 0.03881186 -0.0244792 0.3868921 0.09051152 -0.08380535
se* 0.2944576 0.2576756 0.31575141 0.3160383 0.2688931 0.31363712 0.31400679
      [,8]      [,9]      [,10]
r* -0.01902641 -0.3155566 -0.05463458
se* 0.31611329 0.2847391 0.31528385
> # Valors estudentitzats:
> t.boots = (r.boots["r*",] - r) / r.boots["se*",]
> # Els 10 primers:
> t.boots[1:10]
[1] -0.94776831 1.60512768 0.07003654 -0.13029094 1.37673455 0.23534777
[7] -0.32006657 -0.11301055 -1.16687290 -0.22624789
> #
> # Alguns quantils:
> quantile(r.boots["r*",], probs = c(0.025, 0.975))
      2.5%      97.5%
-0.6081624 0.4646415
> quantile(t.boots, probs = c(0.975, 0.025))
      97.5%      2.5%
1.80654 -3.13579
> quantile(abs(r.boots["r*",]), probs = 0.95)
      95%
0.5635586
> quantile(abs(t.boots), probs = 0.95)
      95%
2.654493

```