

Mètodes basats en rangs **tècniques concretes: test de** **Wilcoxon "rangs amb signe", dades** **aparellades**

Mètodes no paramètrics i de remostratge
Grau interuniversitari en Estadística UB – UPC

Prof. Jordi Ocaña Rebull
Departament d'Estadística, Universitat de Barcelona

- Adequada per a **comparar** paràmetres de **localització** per **dades aparellades**

- $\mathbf{Y} = \begin{matrix} Y_{11} & Y_{12} & \dots & Y_{1n} \\ Y_{21} & Y_{22} & & Y_{2n} \end{matrix}$ mostra aleatòria

- (Y_{1j}, Y_{2j}) obtingudes sota 2 condicions diferents pel mateix subjecte o bloc $j \rightarrow$ variables **dependents** amb distribució contínua univariant

Test de Wilcoxon dels signes-rangs
planteig – condicions de validesa

- Definim $D_j = Y_{1j} - Y_{2j}$ (o $Y_{2j} - Y_{1j}$ sempre que posteriorment actuem coherentment amb aquesta elecció), $\mathbf{D} = (D_1, \dots, D_n)$
- Suposarem que D és contínua i **simètrica** al voltant de la seva mediana δ
- Igualtat de distribucions d' Y_1 i Y_2 (potser llevat de mesura de localització) implica distribució de D simètrica (però també pot ser-ho en condicions més generals)

Test de Wilcoxon dels signes-rangs
planteig – condicions de validesa

$$H_0: \delta = 0$$

$H_1: \delta \neq 0$	$H_1: \delta > 0$	$H_1: \delta < 0$
(bilateral)	(unilateral)	(unilateral)

Hipòtesis nul·la i alternativa

- Si només comptéssim quantes vegades una diferència és positiva o negativa:

$$S^+ = \sum_{i=1}^n I_{\{D_i > 0\}} \quad \text{o} \quad S^- = \sum_{i=1}^n I_{\{D_i < 0\}}$$

- Sota H_0 S^+ (o S^-) seguiria una distribució binomial de paràmetres $p = 1/2$ i n
- Aquesta és la idea del “test dels signes”, menys exigent quant a requeriments
- El test de Wilcoxon aprofita més informació (a més del signe, el rang)

Test dels signes

- **R** = (R_1, \dots, R_n) rangs de les diferències **en valor absolut** $|D|$
- Suma de rangs de diferències positives i suma de rangs de diferències negatives:

$$R^+ = \sum_{i=1}^n R_i I_{\{D_i > 0\}} \quad R^- = \sum_{i=1}^n R_i I_{\{D_i < 0\}}$$

Test de Wilcoxon dels signes-rangs
procediment

- Estadístic de Wilcoxon:

$$V = R^+$$

- $R^+ + R^- = n(n + 1)/2$, novament, per comoditat (brevetat de la taula) s'acostuma a tabular l'estadístic:

$$T = \min\{R^+, R^-\}$$

Estadístic de test

$$H_0: \delta = 0$$

$H_1: \delta \neq 0$	$H_1: \delta > 0$	$H_1: \delta < 0$
es rebutja H_0 si:	es rebutja H_0 si:	es rebutja H_0 si:
$T \leq t_\alpha(n)$	$T \leq t_\alpha^*(n)$	$T \leq t_\alpha^*(n)$
	i $R^+ > R^-$	i $R^+ < R^-$

$t_\alpha(n)$ valor crític a taula per prova bilateral

$t_\alpha^*(n)$ valor crític a taula per prova unilateral

per nivell de significació α i mida mostral n

Criteri de test, procediment "a ma"

- Si H_0 és certa:
 - (conseqüència de les propietats bàsiques de rangs)

$$E(V) = \frac{n(n+1)}{4}$$

$$\text{var}(V) = \frac{n(n+1)(2n+1)}{24}$$

Esperança i variància de l'estadístic de Wilcoxon si H_0 és certa

- Per mides mostrals “grans”
 - (si l’aproximació pel Teorema central del límit es considera prou vàlida; a la pràctica per n fora de la taula)

$$Z \approx N(0, 1)$$

$$Z = \frac{v - \frac{n(n+1)}{4}}{\sqrt{\frac{n(n+1)(2n+1)}{24}}}$$

Aproximació normal

$$H_0: \delta = 0$$

$$\begin{array}{c}
 H_1: \delta \neq 0 \\
 \text{es rebutja } H_0 \text{ si:} \\
 |Z| \geq z_\alpha
 \end{array}
 \left| \begin{array}{c}
 H_1: \delta > 0 \\
 \text{es rebutja } H_0 \text{ si:} \\
 Z \geq z_{2\alpha}
 \end{array} \right|
 \begin{array}{c}
 H_1: \delta < 0 \\
 \text{es rebutja } H_0 \text{ si:} \\
 Z \leq -z_{2\alpha}
 \end{array}$$

z_p valor crític >0 a taula $N(0,1)$ per prova **bilateral**
per nivell de significació p

**Criteri de test per l'aproximació
normal**

- En teoria (variables aleatòries contínues...) no hi pot haver empats
- A la pràctica n'hi ha moltes vegades
- Dos tipus d'empats possibles:
 1. $Y_{1j} = Y_{2j} \Rightarrow D_j = 0$
 2. $|D_j| = |D_{j'}|$ per $D_j \neq 0, D_{j'} \neq 0, j \neq j'$
- Cas "1" més problemàtic, no solució clara. Més habitual: ignorar, mida real $< n$
- Pel cas "2" procedirem de la forma habitual, amb els rangs mitjans

Cas d'empats

- Criteri de decisió pel test de rangs exacte (amb taula) és l'habitual (aproximat)
- Aproximació normal: correcció per variància de V :

$$\frac{n(n+1)(2n+1)}{24} - \frac{\sum_{i=1}^s (t_i^3 - t_i)}{48}$$

s = nombre de sèries de valors empatats

t_i = llargada de sèrie i de valors empatats

Empats però cap $D_j = 0$

- Independentment de la presència d'empats, alguns autors recomanen la correcció per continuïtat:

$$Z = \frac{\left| V - \frac{n(n+1)}{4} \right| - \frac{1}{2}}{\sqrt{\frac{n(n+1)(2n+1)}{24}}}$$

- No hi ha unanimitat que això representi cap millora

Correcció per continuïtat

- En test de Wilcoxon, interpretació habitual (i adequada) de δ : mediana de $D = Y_{2j} - Y_{1j}$
- “med” de diferència \neq diferència de “med”
- Possibles estimadors de δ :

$$\tilde{\delta} = \text{med}(\mathbf{D})$$

$$\hat{\delta} = \text{med} \left(\left\{ \frac{1}{2} (D_j + D_k) \right\}_{1 \leq j \leq k \leq n} \right)$$

- $\hat{\delta}$ directament associat a test Wilcoxon
 - (màx. balanç entre rangs positius i negatius si “centrem” les diferències: $D_j - \hat{\delta}$)

Estimació puntual de δ

- Ordenem les n diferències $D = Y_{2j} - Y_{1j}$ (NO rangs, NO $|D|$): $D_{(1)}, D_{(2)}, \dots, D_{(n)}$
- IC de nivell $1 - \alpha$: $[D_{(\lambda)}, D_{(\nu)}]$, on:

$$\nu^* = \frac{n+1}{2} + \frac{1}{2} z_{\alpha} \sqrt{n}$$

$$\nu = \begin{cases} \nu^* & \text{si } \nu^* \text{ és enter} \\ \lceil \nu^* + 1 \rceil & \text{en cas contrari} \end{cases} \quad \lambda = n - \nu + 1$$

z_{α} valor t.q. $\Pr(|Z| \leq z_{\alpha}) = 1 - \alpha, Z \sim N(0,1)$

Interval de confiança per δ