

Mètodes basats en rangs tècniques concretes: test de Kruskal-Wallis

Mètodes no paramètrics i de remostratge
Grau interuniversitari en Estadística UB – UPC

Prof. Jordi Ocaña Rebull
Departament d'Estadística, Universitat de Barcelona

- Considerat l'alternativa basada en rangs a l'ANOVA d'un factor A amb a nivells. Adequat per a **comparar** paràmetres de **localització** d' **a grups independents**
- $\mathbf{Y} = (Y_{11}, \dots, Y_{1n_1}, \dots, Y_{a1}, \dots, Y_{an_a})$ mostra aleatòria formada per a submostres de mides n_1, n_2, \dots, n_a , obtingudes independentment, sota " a " condicions diferents associades a distribucions F_1, F_2, \dots, F_a , respectivament
- F_i contínues univariants
- $N = n_1 + \dots + n_a$ mida mostral total

Test de Kruskal-Wallis

planteig – condicions de validesa

- μ_i i σ_i paràmetres de localització i escala (o dispersió) per cada grup $i = 1, 2, \dots, a$
 - (no necessàriament mitjana i desviació típica)
- La distribució és la mateixa entre nivells excepte possibles \neq de localització i escala:
$$F_1\left(\frac{Y - \mu_1}{\sigma_1}\right) = \dots = F_a\left(\frac{Y - \mu_a}{\sigma_a}\right)$$
- Però també suposarem que $\sigma_1 = \dots = \sigma_a \rightarrow$ hipòtesi d'igualtat de distribucions esdevé:

Test de Kruskal-Wallis

planteig – condicions de validesa

$$H_0: \mu_1 = \mu_2 = \dots = \mu_a$$

$$H_1: \mu_i \neq \mu_j$$

per alguna parella de nivells i, j

Test de Kruskal-Wallis
hipòtesis nul·la i alternativa

- $\mathbf{R} = (R_{11}, \dots, R_{1n_1}, \dots, R_{a1}, \dots, R_{an_a})$ rangs de la mostra
- Suma de rangs dins cada grup:

$$R_{i.} = \sum_{j=1}^{n_i} R_{ij}$$

- Com més heterogenis siguin els $R_{i.}$, o les seves mitjanes $\bar{R}_{i.}$ en cas no balancejat, més evidència a favor de H_1

Test de Kruskal-Wallis

procediment

- Kruskal i Wallis van tenir la idea de fer un ANOVA sobre els rangs

$$F = \frac{MS_A}{MS_R} = \frac{SS_A / (a - 1)}{SS_R / (N - a)} = \frac{\sum_{i=1}^a n_i (\bar{R}_{i.} - \bar{R}_{..})^2 / (a - 1)}{\sum_{i=1}^a \sum_{j=1}^{n_i} (R_{ij} - \bar{R}_{i.})^2 / (N - a)}$$

$$SS_{Tot} = \sum_{i=1}^a \sum_{j=1}^{n_i} (R_{ij} - \bar{R}_{..})^2 = SS_A + SS_R$$

Test de Kruskal-Wallis
procediment: estadístic de test

$$H = \frac{12}{N(N+1)} \sum_{i=1}^a \frac{R_{i.}^2}{n_i} - 3(N+1)$$

si H_0 és certa, $H \approx \chi^2(a-1)$
és a dir, " H té distribució
asimptòticament khi-quadrat
amb $a-1$ graus de llibertat"

Test de Kruskal-Wallis
procediment: estadístic de test

$$H_0: \mu_1 = \dots = \mu_a$$

$$H_1: \mu_i \neq \mu_j \text{ per algun } i \neq j.$$

"Rebutjarem H_0 si $H \geq \chi^2_{\alpha}(a-1)$ "

(o bé si $p\text{-valor} = \Pr\{\chi^2 \geq H | H_0\} \leq \alpha$)

per $\chi^2 \sim \chi^2(a-1)$

Test de Kruskal-Wallis
procediment: criteri de test

- Si en realitat Y es mesura en escala ordinal o amb insuficient precisió, hi poden haver “empats” (ties)
- Estratègia habitual: assignar a cada sèrie de valors empatats els rangs que els tocarien (com si no estessin empatats) i posteriorment substituir-los per la seva mitjana → tota la sèrie de valors empatats queda amb el mateix rang mitjà

Test de Kruskal-Wallis
empats

- Alguns autors recomanen l'estadístic "corregit pels empats", $H' = H / C$, amb la mateixa distribució asimptòtica khi-quadrat, on:

$$C = 1 - \frac{\sum_{i=1}^s (t_i^3 - t_i)}{N^3 - N}$$

s = nombre de sèries de valors empatats

t_i = llargada de sèrie i de valors empatats

Test de Kruskal-Wallis
empats

- Alternativa vàlida a l'enfoc paramètric normal si possibles diferències als paràmetre de localització, però no als d'escala
- El test de Kruskal-Wallis quan $a = 2$ coincideix amb la versió asimptòtica del test de Mann-Whitney-Wilcoxon per una alternativa bilateral

Test de Kruskal-Wallis
comentaris finals