



Intervalos de confianza bootstrap métodos percentil

Grau en Estadística

**Mètodes no paramètrics i de
remostreig**

Jordi Ocaña Rebull

Departament d'Estadística

El método percentil. Definición

- ☞ Situación de partida: θ parámetro de interés, $\hat{\theta}$ su estimador “plug-in”, \hat{G} estimador bootstrap de la distribución de $\hat{\theta}$
- ☞ IC *percentil bootstrap* de θ , con recubrimiento nominal $1 - \alpha$: $\left[\hat{G}^{-1}\left(\frac{\alpha}{2}\right), \hat{G}^{-1}\left(1 - \frac{\alpha}{2}\right) \right]$
- ☞ En la práctica se suele aproximar mediante $\left[\hat{\theta}_{(\alpha/2)}^*, \hat{\theta}_{(1-\alpha/2)}^* \right]$ donde $\hat{\theta}_{(p)}^*$ corresponde al percentil muestral p obtenido a partir de B réplicas bootstrap: $\hat{\theta}_1^*, \hat{\theta}_2^*, \dots, \hat{\theta}_B^*$

Motivación método percentil (i)

Sea $\hat{\sigma}_{\hat{\theta}}$ un estimador de la desviación estándar de $\hat{\theta}$

Recordemos: si $\frac{\hat{\theta} - \theta}{\hat{\sigma}_{\hat{\theta}}} \approx N(0,1)$

entonces $\hat{\theta} \pm z_{\alpha/2} \hat{\sigma}_{\hat{\theta}}$ es IC “estándar” con recubrimiento $1 - \alpha$, aproximadamente

Extremos del IC estándar equivalentes a percentiles $\alpha/2$ y $1 - \alpha/2$ de la distribución de $\hat{\theta}^* \sim N(\hat{\theta}, \hat{\sigma}_{\hat{\theta}})$

Motivación método percentil (ii)

Si cierto $\hat{\theta} \approx N(\theta, \sigma_{\hat{\theta}})$, en general también $\hat{\theta}^* \approx N(\hat{\theta}, \hat{\sigma}_{\hat{\theta}})$, a su vez bien emulada por \hat{G} , la estima bootstrap de la distribución de $\hat{\theta}$

Es decir:

$$\hat{\theta} - z_{\alpha/2} \hat{\sigma}_{\hat{\theta}} \approx \hat{G}^{-1}(\alpha / 2)$$
$$\hat{\theta} + z_{\alpha/2} \hat{\sigma}_{\hat{\theta}} \approx \hat{G}^{-1}(1 - \alpha / 2)$$

Pero ¿y si $\hat{\theta}$ no normal? (p.e. $\theta = \rho$, coef. de correlación): ¿existe transformación normalizadora y estabilizadora de varianza?

Motivación método percentil (y iii)

Si existe h , monótona creciente, tal que
 $\phi = h(\theta)$, $\hat{\phi} = h(\hat{\theta})$, $\hat{\phi} \approx N(\phi, \sigma_{\hat{\phi}})$, $\sigma_{\hat{\phi}}$ cte.

$$\text{p.e. } \phi = \frac{1}{2} \log \frac{1 + \rho}{1 - \rho} = \tanh^{-1}(\rho), \quad \hat{\phi} \approx N\left(\phi, \frac{1}{\sqrt{n-3}}\right)$$

En escala ϕ , intervalo percentil \approx estándar

Monotonicidad de $h \Rightarrow$ en escala $\theta = h^{-1}(\phi)$,
IC percentil (¡obtenido directamente, sin
conocer h !) aproximadamente correcto

En resumen:

Esquemáticamente:

$$\underbrace{\hat{\theta}_{(p)}^* = \hat{G}^{-1}(p)}_{h^{-1}}, \quad \underbrace{\phi_{(p)}^* = \hat{Q}^{-1}(p) \cong \hat{\phi} + \Phi^{-1}(p)\sigma_{\hat{\theta}}}_{\text{interpretable como percentil}}$$

donde \hat{Q} es la distribución bootstrap de $\hat{\phi}$ y Φ es la función de distribución $N(0,1)$

Entonces justificada la validez del IC

$$\left[\hat{G}^{-1}\left(\frac{\alpha}{2}\right), \hat{G}^{-1}\left(1 - \frac{\alpha}{2}\right) \right] = \hat{G}^{-1}\left(\Phi\left(-z_{\frac{\alpha}{2}}\right), \Phi\left(z_{\frac{\alpha}{2}}\right)\right)$$

Modelo para el sesgo y la heteroscedasticidad

Supongamos que existe una transformación h , normalizadora, pero que no corrige el sesgo ni estabiliza la varianza, en concreto sea

$$\phi = h(\theta), \quad \hat{\phi} = h(\hat{\theta})$$
$$\frac{\hat{\phi} - \phi}{\sigma_{\hat{\phi}}(\phi)} + z_0 \approx N(0,1), \quad \text{con } \sigma_{\hat{\phi}}(\phi) = 1 + a\phi$$

y por lo tanto, también

$$\frac{\hat{\phi}^* - \hat{\phi}}{1 + a\hat{\phi}} + z_0 \approx N(0,1)$$

Construcción de los IC BCa. Intervalo en la escala normal

De $1 - \alpha \cong \Pr \left\{ -z_{\frac{\alpha}{2}} \leq \frac{\hat{\phi} - \phi}{1 + a\phi} + z_0 \leq z_{\frac{\alpha}{2}} \right\}$

o, equivalentemente,

$$\alpha \cong \Pr \left\{ -z_{\frac{\alpha}{2}} > \frac{\hat{\phi} - \phi}{1 + a\phi} + z_0 \right\} + \Pr \left\{ z_{\frac{\alpha}{2}} > \frac{\hat{\phi} - \phi}{1 + a\phi} + z_0 \right\},$$

llegamos a la conclusión de que un IC de nivel, aproximado, $1 - \alpha$ para ϕ viene dado por:

$$\Pr \left\{ \hat{\phi} + \frac{z_0 - z_{\frac{\alpha}{2}}}{1 - a \left(z_0 - z_{\frac{\alpha}{2}} \right)} \sigma_{\hat{\phi}}(\hat{\phi}) \leq \phi \leq \hat{\phi} + \frac{z_0 + z_{\frac{\alpha}{2}}}{1 - a \left(z_0 + z_{\frac{\alpha}{2}} \right)} \sigma_{\hat{\phi}}(\hat{\phi}) \right\}$$

Construcción de los IC Bca. Intervalo en la escala normal

Los extremos del intervalo anterior pueden considerarse percentiles de una distribución $N(\hat{\phi} - z_0 \sigma_{\hat{\phi}}(\hat{\phi}), \sigma_{\hat{\phi}}(\hat{\phi}))$ pero no los percentiles $\frac{\alpha}{2}$ y $1 - \frac{\alpha}{2}$, sino percentiles

$$\alpha_1 = \Phi \left(z_0 + \frac{z_0 - z_{\frac{\alpha}{2}}}{1 - a \left(z_0 - z_{\frac{\alpha}{2}} \right)} \right) \text{ y}$$
$$1 - \alpha_2 = \Phi \left(z_0 + \frac{z_0 + z_{\frac{\alpha}{2}}}{1 - a \left(z_0 + z_{\frac{\alpha}{2}} \right)} \right)$$

respectivamente

Construcción de los IC Bca. Intervalo en la escala original

Por lo tanto, el intervalo en la escala θ :

$$\left[h^{-1} \left(\hat{\phi} + \frac{z_0 - z_{\frac{\alpha}{2}}}{1 - a \left(z_0 - z_{\frac{\alpha}{2}} \right)} \sigma_{\hat{\phi}} \left(\hat{\phi} \right) \right), h^{-1} \left(\hat{\phi} + \frac{z_0 + z_{\frac{\alpha}{2}}}{1 - a \left(z_0 + z_{\frac{\alpha}{2}} \right)} \sigma_{\hat{\phi}} \left(\hat{\phi} \right) \right) \right]$$

tendrá extremos de la forma:

$$\hat{\theta}_{(\alpha_1)}^* = \hat{G}^{-1} \left(\Phi \left(z_0 + \frac{z_0 - z_{\frac{\alpha}{2}}}{1 - a \left(z_0 - z_{\frac{\alpha}{2}} \right)} \right) \right) \text{ y}$$

$$\hat{\theta}_{(1-\alpha_2)}^* = \hat{G}^{-1} \left(\Phi \left(z_0 + \frac{z_0 + z_{\frac{\alpha}{2}}}{1 - a \left(z_0 + z_{\frac{\alpha}{2}} \right)} \right) \right)$$

Intervalos de confianza percentil bootstrap

Estima de la corrección del sesgo z_0

Falta determinar el valor del parámetro de corrección del sesgo, z_0 , y de la “constante de aceleración”, a

Estima de z_0 : $\hat{z}_0 = \Phi^{-1}(\hat{G}(\hat{\theta}))$.

– En efecto:

$$\begin{aligned}\hat{G}(\hat{\theta}) &= P_* \{ \hat{\theta}^* \leq \hat{\theta} \} \\ &= P_* \{ \hat{\phi}^* \leq \hat{\phi} \} = P_* \left\{ \frac{\hat{\phi}^* - \hat{\phi}}{1 + a\hat{\phi}} + z_0 \leq z_0 \right\} \cong \Phi(z_0)\end{aligned}$$

Estima de la constante de aceleración

Efron, para funcionales $\theta = t(F)$, $\hat{\theta} = t(\hat{F})$:

$$\hat{a} = \frac{\sum_{i=1}^n U_i^3}{6 \left\{ \sum_{i=1}^n U_i^2 \right\}^{3/2}}$$

- U_i es la función empírica de influencia asociada al dato i :

$$U_i = U(x_i, \hat{F}) = \lim_{\varepsilon \rightarrow 0} \frac{t((1 - \varepsilon)\hat{F} + \varepsilon\delta_i) - t(\hat{F})}{\varepsilon}$$

Alternativamente, aproximación jackknife:

$$\hat{a} = \frac{\sum_{i=1}^n \left(\hat{\theta}_{(\cdot)} - \hat{\theta}_{(-i)} \right)^3}{6 \left\{ \sum_{i=1}^n \left(\hat{\theta}_{(\cdot)} - \hat{\theta}_{(-i)} \right)^2 \right\}^{3/2}}$$

Resumen de intervalos percentil

IC percentil:

- Validez: \exists transformación normalizante, centradora y estabilizadora de varianza (no necesario conocerla)
- Definición: $\left[\hat{G}^{-1} \left(\frac{\alpha}{2} \right), \hat{G}^{-1} \left(1 - \frac{\alpha}{2} \right) \right]$

IC percentil corregido para el sesgo, acelerado (BCa):

- Validez: \exists transformación normalizante (no necesario conocerla)
- Definición:

$$\left[\hat{G}^{-1} \left(\Phi \left(\hat{z}_0 + \frac{\hat{z}_0 - z_{\frac{\alpha}{2}}}{1 - \hat{a} \left(\hat{z}_0 - z_{\frac{\alpha}{2}} \right)} \right) \right), \hat{G}^{-1} \left(\Phi \left(\hat{z}_0 + \frac{\hat{z}_0 + z_{\frac{\alpha}{2}}}{1 - \hat{a} \left(\hat{z}_0 + z_{\frac{\alpha}{2}} \right)} \right) \right) \right]$$

Si sesgo pero homoscedasticidad $\Rightarrow a = 0$: intervalo “corregido para el sesgo”: BC