



MODEL LINEAL
GENERALITZAT

APUNTS DE CLASSE: TEMA 5
MODELS MIXTOS

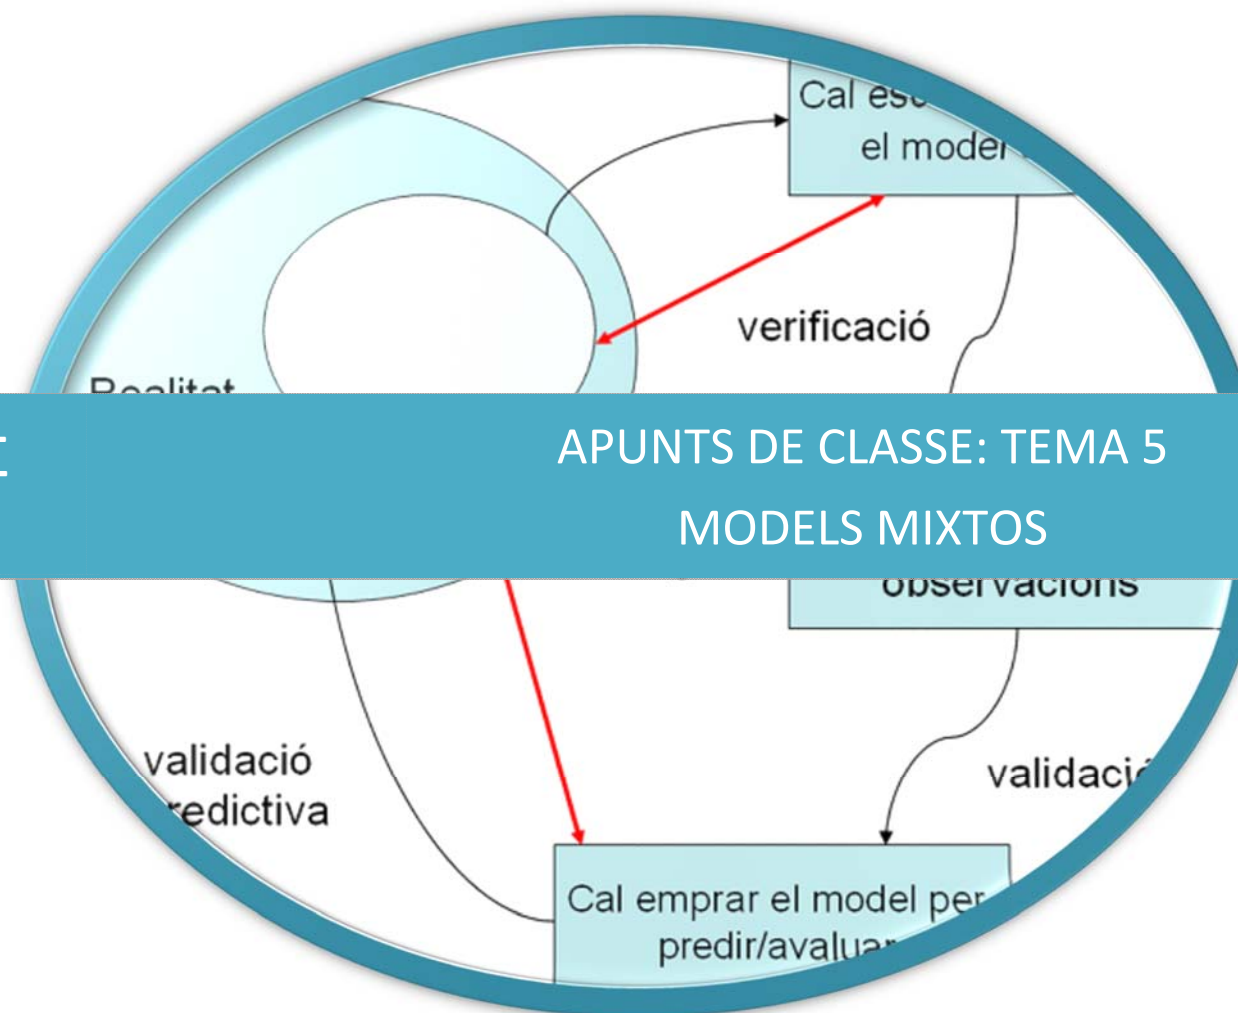


TABLA DE CONTENIDOS

<u>5.1</u>	<u>EXTENSIONES DEL MODELO LINEAL</u>	<u>3</u>
<u>5.2</u>	<u>DATOS AGRUPADOS</u>	<u>8</u>
<u>5.3</u>	<u>MODELOS LINEALES MIXTOS</u>	<u>10</u>
<u>5.4</u>	<u>EJEMPLO 1: MODELO DE BLOQUES ALEATORIZADOS</u>	<u>14</u>
<u>5.5</u>	<u>EJEMPLO 2: MODELO DE PENDIENTES ALEATORIAS</u>	<u>18</u>

EXTENSIONES DEL MODELO LINEAL

Objetivo:

Extender la metodología de los Modelos Lineales Generalizados para tratar datos no independientes: medidas repetidas y datos longitudinales.

Modelo Lineal:

Distribución condicional de la respuesta (parte aleatoria):

$$Y_i|X_i \sim N(\mu_i, \sigma)$$

$$E(Y_i|X_i) = \mu_i$$

$$V(Y_i|X_i) = \sigma^2$$

Relación del parámetro Esperanza Condicionada con covariables (parte sistemática)

$$\mu_i = X_i\beta$$

Premisas:

- Linealidad: $E(Y_i|X_i) = \mu_i = X_i\beta$
- Homocedasticidad (var. cte.): $V(Y_i|X_i) = \sigma^2$
- Normalidad: $Y_i|X_i \sim Normal$
- Independència: $Y_i|X_i \perp Y_j|X_j, i \neq j$

EXTENSIONES DEL MODELO LINEAL

1ª Extensión:

Relajamos las condiciones de la distribución condicional de la respuesta

Modelo Lineal Generalizado:

Distribución condicional de la respuesta (parte aleatoria):

$$Y_i|X_i \sim F(\cdot; \mu_i, \phi)$$

$$E(Y_i|X_i) = \mu_i$$

$$V(Y_i|X_i) = \phi v(\mu_i)$$

Relación del parámetro Esperanza Condicionada con covariables (parte sistemática)

$$g(\mu_i) = X_i\beta$$

Premisas:

- Linealidad en la escala del predictor: $g(E(Y_i|X_i)) = g(\mu_i) = X_i\beta$
- Varianza determinada por la distribución: $V(Y_i|X_i) = \phi v(\mu_i)$
- Distribución condicional: $Y_i|X_i \sim F$
- Independència: $Y_i|X_i \perp Y_j|X_j, i \neq j$

EXTENSIONES DEL MODELO LINEAL

Modelo Lineal Generalizado con Respuesta Binaria:

Distribución condicional de la respuesta (parte aleatoria): Binomial

$$Y_i|X_i \sim \text{Bern}(\pi_i), \phi = 1$$

$$E(Y_i|X_i) = \pi_i$$

$$V(Y_i|X_i) = \phi\pi_i(1 - \pi_i)$$

Relación del parámetro Esperanza Condicionada con covariables (parte sistemática)

$$g(\pi_i) = X_i\beta$$

$$g(.) \text{ logit, probit, clog-log, ...}$$

Premisas:

- Linealidad en la escala del predictor: $g(E(Y_i|X_i)) = g(\mu_i) = X_i\beta$
- Varianza determinada por la distribución: $V(Y_i|X_i) = \pi_i(1 - \pi_i)$ (si $\phi \neq 1$, sobre(o infra)-dispersión)
- Distribución condicional: $Y_i|X_i \sim \text{Bern}$
- Independència: $Y_i|X_i \perp Y_j|X_j, i \neq j$

EXTENSIONES DEL MODELO LINEAL

Modelo Lineal Generalizado con Recuentos:

Distribución condicional de la respuesta (parte aleatoria): Poisson

$$Y_i|X_i \sim \text{Pois}(\lambda_i), \phi = 1$$

$$E(Y_i|X_i) = \lambda_i$$

$$V(Y_i|X_i) = \phi \lambda_i$$

Relación del parámetro Esperanza Condicionada con covariables (parte sistemática)

$$g(\lambda_i) = X_i \beta$$

$$g(.) \text{ log}$$

Premisas:

- Linealidad en la escala del predictor: $g(E(Y_i|X_i)) = g(\lambda_i) = X_i \beta$
- Varianza determinada por la distribución: $V(Y_i|X_i) = \lambda_i$ (si $\phi \neq 1$, sobre(o infra)-dispersión)
- Distribución condicional: $Y_i|X_i \sim \text{Pois}$
- Independència: $Y_i|X_i \perp Y_j|X_j, i \neq j$

EXTENSIONES DEL MODELO LINEAL

Modelo Lineal Generalizado con Valores Positivos (p.ej. tiempos):

Distribución condicional de la respuesta (parte aleatoria): Gamma

$$Y_i | X_i \sim \Gamma(\alpha, \beta_i)$$

$$E(Y_i | X_i) = \mu_i = \alpha \beta_i$$

$$V(Y_i | X_i) = \phi v(\mu_i) = \alpha \beta_i^2, \phi = \frac{1}{\alpha}, v(\mu_i) = \mu_i^2$$

Relación del parámetro Esperanza Condicionada con covariables (parte sistemática)

$$g(\mu_i) = X_i \beta$$

$$g(\cdot) \text{ inversa } (\mu^{-1})$$

Premisas:

- Linealidad en la escala del predictor: $g(E(Y_i | X_i)) = g(\mu_i) = X_i \beta$
- Varianza determinada por la distribución: $V(Y_i | X_i) = \frac{\mu_i}{\alpha}$ ($CV(Y_i | X_i) = \frac{\sqrt{V(Y_i | X_i)}}{E(Y_i | X_i)} = \frac{1}{\sqrt{\alpha}}$ constante)
- Distribución condicional: $Y_i | X_i \sim \Gamma$
- Independència: $Y_i | X_i \perp Y_j | X_j, i \neq j$

DATOS AGRUPADOS

En todos los casos, la premisa de independencia es necesaria. La muestra ha de ser aleatoria y simple: cada observación se ha obtenido de unidades experimentales independientes y cada unidad experimental contribuye a la muestra con una sola observación.

Datos Agrupados

En multitud de situaciones es muy común que exista algún tipo de agrupación en los datos:

- Se desea medir el efecto de cuatro fertilizantes (A,B,C y D) en la producción de un cereal. Se realiza un diseño por bloques aleatorizados seleccionando 10 parcelas que se subdividen en cuatro subparcelas a las que se aplican cada uno de los tratamientos
- Se desea comparar la productividad de tres máquinas (A,B y C). Puesto que los operarios tienen diferentes habilidades, se seleccionan 5 operarios y se les hace utilizar las tres máquinas
- Se quiere analizar el efecto de dos metodologías docentes (A y B) en el rendimiento escolar en matemáticas de los estudiantes de secundaria. Se seleccionan 20 escuelas (10 de tipo A y 10 de tipo B) , dentro de cada escuela 3 clases y dentro de cada clase 5 estudiantes
- Se desea comparar la evolución de la altura según el género en la adolescencia. Se seleccionan 10 niños y 10 niñas y se mide su altura semestralmente durante 8 años

DATOS AGRUPADOS

En los casos mencionados anteriormente, la respuesta se podría considerar gaussiana y los tratamientos a analizar son de tipo factor (fertilizantes, máquinas, metodología y género) pero podrían existir covariantes de tipo numérico y otros factores que podrían afectar a la respuesta.

¿Es posible utilizar el Modelo Lineal para estimar el modelo y hacer inferencia u obtener predicciones?

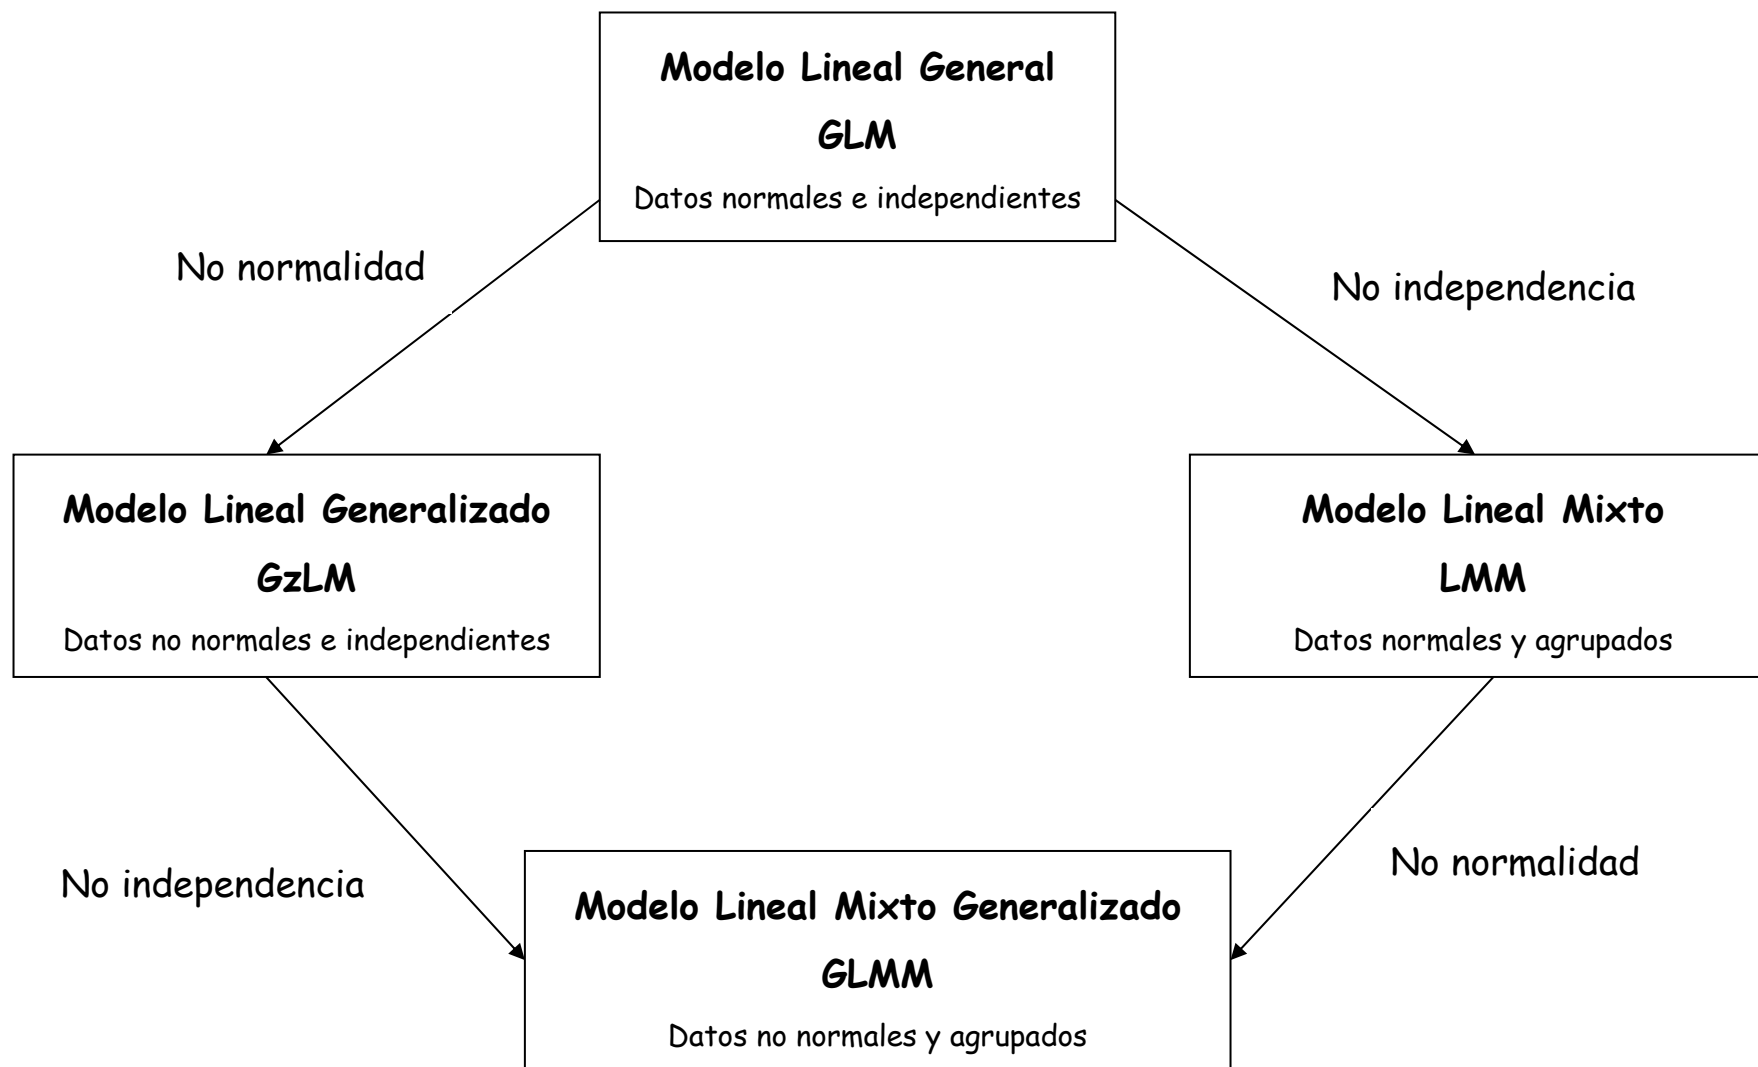
Los datos no son independientes:

- Las 4 observaciones obtenidas en la misma parcela (bloque) están relacionadas
- Las productividades obtenidas por las 3 máquinas cuando el operario es el mismo están relacionadas
- Las 5 notas obtenidas por alumnos de la misma clase en el mismo colegio están relacionadas y las 15 notas de alumnos del mismo colegio, también
- Las 16 medidas realizadas en cada individuo están relacionadas

En todos los casos, además de la respuesta y del tratamiento a testar, existe al menos una variable de tipo categórico que induce una partición de la muestra, haciendo que los datos estén agrupados (parcela, operario, clase/colegio, individuo) y no se puedan considerar independientes. Además, esta variable tiene carácter aleatorio (sus niveles corresponden a una selección aleatoria dentro de la población)

Es necesario extender el Modelo Lineal para relajar la condición de independencia. Hay diferentes formas de hacerlo, pero una de las más potentes son los Modelos Lineales Mixtos

MODELOS LINEALES MIXTOS



MODELOS LINEALES MIXTOS

Diferentes situaciones habituales que dan lugar a datos agrupados:

- Diseños de bloques aleatorizados (parcelas): Los diferentes tratamientos de interés se aplican en cada bloque.
- Diseños de medidas repetidas (operarios): Cada unidad experimental contribuye con más de una observación, pero no existe estructura temporal ni espacial
- Diseños jerárquicos o multinivel (colegios/clases): Hay diferentes capas de agrupación
- Diseños de datos longitudinales (individuos): Existe una covariable temporal/espacial que supone una estructura particular de dependencia entre observaciones

Diseño con k grupos, no necesariamente balanceado (diferente número de observaciones por grupo)

Vector de observaciones del individuo i-ésimo de dimensión $(1 \times n_i)$:

$$Y_i = (y_{i1}, \dots, y_{in_i})' \quad i = 1..k$$

Matriz de diseño del individuo i-ésimo de dimensión $(p \times n_i)$:

$$X_i = \begin{pmatrix} x_{i1}^{(1)} & \dots & x_{i1}^{(p)} \\ \vdots & \ddots & \vdots \\ x_{in_i}^{(1)} & \dots & x_{in_i}^{(p)} \end{pmatrix} \quad i = 1..k$$

MODELOS LINEALES MIXTOS

Si realizamos un modelo poblacional con todas las observaciones sin tener en cuenta la estructura de agrupación → modelo con pocos parámetros pero no válido por no ser datos independientes

$$Y_i = X_i\beta + \varepsilon_i \quad \varepsilon_i \sim N(0, \sigma^2 I)$$

p+1 parámetros: vector β (1xp) y escalar σ desviación estándar residual

Si realizamos un modelo individual con los datos de cada grupo → modelo válido (dentro de cada grupo las observaciones son independientes) pero con muchos parámetros y solo útiles para esas unidades experimentales que han sido seleccionadas aleatoriamente.

$$Y_i = X_i\beta_i + \varepsilon_i \quad \varepsilon_i \sim N(0, \sigma^2 I)$$

kp+1 parámetros: vectores β_i (1xp) y escalar σ desviación estándar residual

MODELOS LINEALES MIXTOS

Solució: Asumimos un modelo poblacional subyacente válido, que servirá para hacer inferencia, y el modelo para cada individuo posee coeficientes que son "desviaciones" aleatorias de los coeficientes del modelo poblacional.

Los parámetros asociados al modelo poblacional son los efectos fijos. Las "desviaciones" para obtener el modelo individual se denominan efectos aleatorios. La presencia de efectos fijos y aleatorios en el modelo da lugar a los Modelos Mixtos. Hay diferentes terminologías para el mismo modelo, según el área de aplicación, pero el modelo es el mismo:

Modelos jerárquicos/Multinivel:

$$\begin{cases} Y_i = X_i\beta_i + \varepsilon_i & \varepsilon_i \sim N(0, \sigma^2 I) \\ \beta_i = \beta + b_i & b_i \sim N(0, D) \end{cases}$$

Modelos de coeficientes aleatorios:

$$Y_i = X_i\beta_i + \varepsilon_i, \quad \beta_i \sim N(\beta, D), \quad \varepsilon_i \sim N(0, \sigma^2 I)$$

Modelos con efectos aleatorios

$$Y_i = X_i(\beta + b_i) + \varepsilon_i, \quad b_i \sim N(0, D), \quad \varepsilon_i \sim N(0, \sigma^2 I)$$

Modelos Mixtos:

$$Y_i = X_i\beta + Z_ib_i + \varepsilon_i, \quad b_i \sim N(0, D), \quad \varepsilon_i \sim N(0, \sigma^2 I)$$

EJEMPLO 1: MODELO DE BLOQUES ALEATORIZADOS

Ejemplo: galletas (Valoración sensorial de un tipo de galletas ("filipinos") según marca, tipo de chocolate y enmascaramiento)


Diseño factorial 2^3 con 31 réplicas por condición experimental. Se recogen datos de la valoración sensorial de una galleta realizada por un individuo, en una escala de 0 a 100. Hay dos tipos de chocolate (Blanco:B y Negro:X), las galletas pueden ser de Marca o no, y la degustación se ha realizado con o sin enmascaramiento. En total hay 8 posibles condiciones experimentales, y puesto que existen réplicas, es posible analizar interacciones.

```
>Anova(lm(Valoracion~Tipo*Marca*Enmascaramiento,galletas))
```

Anova Table (Type II tests)

Response: Valoracion

	Sum Sq	Df	F value	Pr(>F)	
Tipo	16551	1	62.2081	1.088e-13	***
Marca	7701	1	28.9457	1.767e-07	***
Enmascaramiento	158	1	0.5942	0.44158	
Tipo:Marca	883	1	3.3194	0.06971	.
Tipo:Enmascaramiento	2	1	0.0061	0.93800	
Marca:Enmascaramiento	632	1	2.3766	0.12448	
Tipo:Marca:Enmascaramiento	285	1	1.0723	0.30146	
Residuals	63855	240			



EJEMPLO 1: MODELO DE BLOQUES ALEATORIZADOS

El ajuste del modelo, manteniendo términos con significación inferior a 0.15 es:

```
lm(formula = Valoracion ~ Tipo + Marca + Enmascaramiento + Tipo:Marca +
    Marca:Enmascaramiento, data = galletas)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	69.540	2.532	27.462	< 2e-16	***
TipoX	-20.113	2.924	-6.879	5.13e-11	***
MarcaS	10.565	3.581	2.950	0.00349	**
Enmascaramientos	4.790	2.924	1.638	0.10267	
TipoX:MarcaS	7.548	4.135	1.825	0.06917	.
MarcaS:Enmascaramientos	-6.387	4.135	-1.545	0.12376	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 16.28 on 242 degrees of freedom

Multiple R-squared: 0.2879, Adjusted R-squared: 0.2731

F-statistic: 19.56 on 5 and 242 DF, p-value: 2.345e-16

Ahora bien, si los datos son independientes el número de individuos que ha participado en el estudio ha de ser el mismo que el tamaño de muestra ($n=248!$). En realidad, el diseño se realizó con los 31 alumnos de una clase que probaron y valoraron cada uno de ellos las 8 posibles condiciones experimentales. Por lo tanto, los datos **NO** son independientes y el procedimiento realizado NO es correcto!

EJEMPLO 1: MODELO DE BLOQUES ALEATORIZADOS


En realidad, el diseño es un diseño 2^3 completo con bloques aleatorizados a 31 niveles sin réplicas por condición experimental. Para resolver el diseño en base a modelos mixtos, hemos de suponer que existe un efecto aleatorio no observable (b_i) que justifica la correlación entre las observaciones recogidas en cada individuo.

```
> Anova(lme(Valoracion~Tipo*Marca*Enmascaramiento,galletas,random=~1|ID))
```

Analysis of Deviance Table (Type II tests)

Response: Valoracion

	Chisq	Df	Pr(>Chisq)	
Tipo	93.6437	1	< 2.2e-16	***
Marca	43.5728	1	4.085e-11	***
Enmascaramiento	0.8944	1	0.34429	
Tipo:Marca	4.9968	1	0.02539	*
Tipo:Enmascaramiento	0.0091	1	0.92390	
Marca:Enmascaramiento	3.5776	1	0.05856	.
Tipo:Marca:Enmascaramiento	1.6142	1	0.20390	



EJEMPLO 1: MODELO DE BLOQUES ALEATORIZADOS

La estimación puntual de la parte fija coincide con el análisis anterior, pero la significación de los factores es muy diferente, ya que antes se ignoró que existen componentes de la varianza (debido a los individuos y la residual)

```
> summary(mod<-lme(Valoracion~Tipo*Marca+Marca*Enmascaramiento,galletas,random=~1|ID))
```

Linear mixed-effects model fit by REML

Data: galletas

AIC	BIC	logLik
2026.584	2054.495	-1005.292

Random effects:

Formula: ~1 | ID

(Intercept) Residual

StdDev: 9.452726 13.28276

Fixed effects: Valoracion ~ Tipo * Marca + Marca * Enmascaramiento

	Value	Std.Error	DF	t-value	p-value
(Intercept)	69.54032	2.674116	212	26.004976	0.0000
TipoX	-20.11290	2.385654	212	-8.430772	0.0000
MarcaS	10.56452	2.921817	212	3.615735	0.0004
Enmascaramientos	4.79032	2.385654	212	2.007970	0.0459
TipoX:MarcaS	7.54839	3.373824	212	2.237339	0.0263
MarcaS:Enmascaramientos	-6.38710	3.373824	212	-1.893133	0.0597

EJEMPLO 2: MODELO DE PENDIENTES ALEATORIAS

Ejemplo: sleepstudy (Tiempo diario de reacción promedio para sujetos en un estudio de privación del sueño)

Se seleccionan 18 individuos. En el día 0 los sujetos tenían su cantidad normal de sueño. Desde aquella noche se limita a 3 horas de sueño por noche. Las observaciones representan el tiempo medio de reacción en una serie de ensayos cada día a cada sujeto.


Reaction Days Subject

249.5600	0	308
258.7047	1	308
250.8006	2	308
321.4398	3	308
356.8519	4	308
414.6901	5	308
382.2038	6	308
290.1486	7	308
430.5853	8	308
466.3535	9	308
222.7339	0	309
205.2658	1	309
202.9778	2	309
204.7070	3	309
207.7161	4	309
215.9618	5	309
213.6303	6	309
217.7272	7	309
224.2957	8	309

:

:

:



EJEMPLO 2: MODELO DE PENDIENTES ALEATORIAS


Modelo lineal "poblacional": Si ignoramos la estructura de correlación para los datos de un mismo individuo, podemos aplicar el modelo lineal general (OLS) a todo el conjunto:

$$R_{ij} = \beta_0 + \beta_1 D_{ij} + \varepsilon_{ij} \quad \varepsilon_{ij} \sim N(0, \sigma^2 I)$$

```
> (mod.pobl<-lm(Reaction~Days,sleepstudy))
```

Coefficients:

(Intercept)	Days
251.41	10.47



EJEMPLO 2: MODELO DE PENDIENTES ALEATORIAS


Modelo lineal "individual": Hacemos un modelo para cada individuo

$$R_{ij} = \beta_{0i} + \beta_{1i}D_{ij} + \varepsilon_{ij} \quad \varepsilon_{ij} \sim N(0, \sigma^2 I)$$

```
> (mod.indiv=lmList(Reaction~Days|Subject,sleepstudy))
```

Coefficients:

	(Intercept)	Days
308	244.1927	21.764702
309	205.0549	2.261785
310	203.4842	6.114899
330	289.6851	3.008073
331	285.7390	5.266019
332	264.2516	9.566768
333	275.0191	9.142045
334	240.1629	12.253141
335	263.0347	-2.881034
337	290.1041	19.025974
349	215.1118	13.493933
350	225.8346	19.504017
351	261.1470	6.433498
352	276.3721	13.566549
369	254.9681	11.348109
370	210.4491	18.056151
371	253.6360	9.188445
372	267.0448	11.298073



EJEMPLO 2: MODELO DE PENDIENTES ALEATORIAS

Modelo Lineal Mixto: La parte fija es el modelo poblacional y el factor aleatorio sujeto tiene un efecto aleatorio en el Intercept y otro en la pendiente

$$R_{ij} = (\beta_0 + b_{0i}) + (\beta_1 + b_{1i})D_{ij} + \varepsilon_{ij} \quad (b_{0i}, b_{1i})' \sim N(0, D) \quad \varepsilon_{ij} \sim N(0, \sigma^2 I)$$

```
> (mod.mix=lmer(Reaction~Days+(Days|Subject),sleepstudy))
```

Linear mixed model fit by REML

Formula: Reaction ~ Days + (Days | Subject)

Data: sleepstudy

AIC	BIC	logLik	deviance	REMLdev
1756	1775	-871.8	1752	1744

Random effects:

Groups	Name	Variance	Std.Dev.	Corr
Subject	(Intercept)	612.092	24.7405	
	Days	35.072	5.9221	0.066
Residual		654.941	25.5918	

Number of obs: 180, groups: Subject, 18

Fixed effects:

	Estimate	Std. Error	t value
(Intercept)	251.405	6.825	36.84
Days	10.467	1.546	6.77


EJEMPLO 2: MODELO DE PENDIENTES ALEATORIAS

Efectos Fijos del modelo mixto (β):

```
> fixef(mod.mix)
(Intercept)      Days
 251.40510    10.46729
```

Efectos Aleatorios del modelo mixto (b):

```
> ranef(mod.mix)
$Subject
  (Intercept)      Days
308   2.2571870    9.1992523
309 -40.3984020   -8.6211497
310 -38.9605268   -5.4502094
330  23.6919454   -4.8137089
331  22.2613341   -3.0692765
332   9.0398323   -0.2718974
333  16.8409575   -0.2231088
334  -7.2329589    1.0743770
335  -0.3320174 -10.7524155
337  34.8900139    8.6295604
349 -25.2110300    1.1726615
350 -13.0713764    6.6139522
351   4.5784421   -3.0151846
352  20.8636459    3.5367394
369   3.2754116    0.8723379
370 -25.6143737    4.8217830
371   0.8072184   -0.9881528
372  12.3146970    1.2844399
```



EJEMPLO 2: MODELO DE PENDIENTES ALEATORIAS

```
> summary(mod.pobl<-lm(Reaction~Days,sleepstudy))
```

Residuals:

Min	1Q	Median	3Q	Max
-110.848	-27.483	1.546	26.142	139.953

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	251.405	6.610	38.033	< 2e-16 ***
Days	10.467	1.238	8.454	9.89e-15 ***

Modelo Lineal General

Incorrecto!!! Datos no independientes!

Residual standard error: 47.71 on 178 degrees of freedom
Multiple R-squared: 0.2865, Adjusted R-squared: 0.2825
F-statistic: 71.46 on 1 and 178 DF, p-value: 9.894e-15

```
> (mod.mix=lmer(Reaction~Days+(Days|Subject),sleepstudy))
```

Linear mixed model fit by REML

Formula: Reaction ~ Days + (Days | Subject)

Data: sleepstudy

AIC	BIC	logLik	deviance	REMLdev
1756	1775	-871.8	1752	1744

Modelo Lineal Mixto

Random effects:

Groups	Name	Variance	Std.Dev.	Corr
Subject	(Intercept)	612.092	24.7405	
	Days	35.072	5.9221	0.066
Residual		654.941	25.5918	

Number of obs: 180, groups: Subject, 18

Fixed effects:

	Estimate	Std. Error	t value
(Intercept)	251.405	6.825	36.84
Days	10.467	1.546	6.77

Correcto!!! Efectos aleatorios en datos agrupados

ESTIMACIÓN E INFERENCIA EN MODELOS LINEALES MIXTOS

Verosimilitud:

$$\begin{aligned} L(\beta, \theta, \sigma | y_1, \dots, y_n) &= \prod_{i=1}^n f_{\beta, \theta, \sigma}(y_i) = \prod_{i=1}^n \left(\int_{b_i} f_{\beta, \theta, \sigma}(y_i, b_i) db_i \right) \\ &= \prod_{i=1}^n \left(\int_{b_i} f_{\beta, \sigma}(y_i | b_i) f_{\theta}(b_i) db_i \right) \end{aligned}$$

Puesto que los efectos aleatorios son normales y su matriz de varianzas y covarianzas D está parametrizada con los parámetros θ :

$$b_i \sim N(0, D(\theta))$$

$$f_{\theta}(b_i) = \frac{1}{\sqrt{2\pi|D(\theta)|}} \exp\left(-\frac{1}{2} b_i' D(\theta)^{-1} b_i\right)$$

Y la distribución de y_i conodido el valor del efecto aleatorio b_i también es normal:

$$y_i | b_i \sim N(X_i \beta + Z_i b_i, \sigma^2 I)$$

$$f_{\beta, \sigma}(y_i | b_i) = \frac{1}{\sqrt{2\pi|\sigma^2 I|}} \exp\left[-\frac{1}{2\sigma^2} (y_i - (X_i \beta + Z_i b_i))' (y_i - (X_i \beta + Z_i b_i))\right]$$

ESTIMACIÓN E INFERENCIA EN MODELOS LINEALES MIXTOS

El cálculo de la verosimilitud incluye la resolución de una integral (ya que los efectos aleatorios no se observan, es necesario obtener la verosimilitud marginal, integrando la distribución conjunta respecto a los efectos aleatorios).

Estimadores de máxima verosimilitud:

$$\operatorname{argmax}_{\beta, \theta, \sigma} L(\beta, \theta, \sigma | y_1, \dots, y_n) = \operatorname{argmax}_{\beta, \theta, \sigma} \prod_{i=1}^n \left(\int_{b_i} f_{\beta, \sigma}(y_i | b_i) f_{\theta}(b_i) db_i \right)$$

Los estimadores de las componentes de la varianza están sesgados (el valor esperado del estimador infraestima los parámetros. Por ello, se trabaja con una variante de la verosimilitud, denominada Verosimilitud Restringida (Restricted Maximum Likelihood, REML)

La parte fija del modelo funciona igual que en los modelos lineales:

Inferencia para β basada en el test de Wald y razón de verosimilitudes:

$$\begin{aligned} \hat{\beta} &\approx N(\beta, I(\beta)^{-1}) \\ -2 (\log L_0 - \log L_1) &\approx \chi_p^2 \end{aligned}$$

Para las componentes de la varianza se utiliza el test de razón de verosimilitudes, pero la estimación ha de ser ML y no REML

MODELOS LINEALES MIXTOS GENERALIZADOS

Igual que pasamos del Modelo Lineal al Modelo Lineal Generalizado cambiando la distribución de la respuesta, el Modelo Lineal Mixto Generalizado es un Modelo Lineal Mixto con una distribución diferente para la respuesta.

Datos agrupados:

Vector de observaciones del individuo i -ésimo de dimensión $(1 \times n_i)$:

$$Y_i = (y_{i1}, \dots, y_{in_i})' \quad i = 1..k$$

Matriz de diseño de la parte fija del individuo i -ésimo de dimensión $(p \times n_i)$:

$$X_i = \begin{pmatrix} x_{i1}^{(1)} & \dots & x_{i1}^{(p)} \\ \vdots & \ddots & \vdots \\ x_{in_i}^{(1)} & \dots & x_{in_i}^{(p)} \end{pmatrix} \quad i = 1..k$$

Matriz de diseño de la parte aleatoria del individuo i -ésimo de dimensión $(p \times n_i)$:

$$Z_i = \begin{pmatrix} z_{i1}^{(1)} & \dots & z_{i1}^{(q)} \\ \vdots & \ddots & \vdots \\ z_{in_i}^{(1)} & \dots & z_{in_i}^{(q)} \end{pmatrix} \quad i = 1..k$$

MODELOS LINEALES MIXTOS GENERALIZADOS

Expresión del Modelo Lineal Mixto Generalizado (GLMM):

Distribución condicional de la respuesta (parte aleatoria):

$$Y_i | X_i, Z_i \sim F(\cdot; \mu_i, \phi)$$

$$E(Y_i | X_i, Z_i) = \mu_i$$

$$V(Y_i | X_i, Z_i) = \phi v(\mu_i)$$

Relación del parámetro Esperanza Condicionada con covariables (parte sistemática):


$$g(\mu_i) = X_i \beta + Z_i b_i$$

En los modelos lineales mixtos generalizados, es habitual considerar modelos simples. Si hay datos agrupados se suele trabajar inicialmente con predictores lineales con un único efecto aleatorio afectando al término independiente:

$$Z_i = \begin{pmatrix} 1 \\ : \\ 1 \end{pmatrix} \quad i = 1..k$$

EJEMPLO 3: MODELO LINEAL MIXTO POISSON

En este ejemplo, participan 30 individuos con problemas de lesiones dérmicas en el rostro (pápulas, pústulas y nódulos). A todos se les aplica un tratamiento para corregir estas lesiones. En las semanas 2, 4, 8 y 12 se cuenta el número de lesiones que presentan, para evaluar la eficacia del tratamiento.



EJEMPLO 3: MODELO LINEAL MIXTO POISSON

Para cuantificar la efectividad del tratamiento a lo largo del tiempo, podemos calcular el modelo lineal de Poisson poblacional y sus correspondientes modelos individuales:

y_{ij} Número de lesiones del individuo i -ésimo en la visita j -ésima

Distribución de la respuesta: $Y_{ij} \sim \text{Pois}(\lambda_{ij})$

Parte sistemática: $\log(\lambda_{ij}) = (\beta_0 + b_i) + \beta_1 \text{Week}_{ij}$

Parte aleatoria: $b_i \sim N(0, \sigma_b)$

```
> (mod=glmer(ppn~Week+(1|Patient),skin,family=poisson))
```

Generalized linear mixed model fit by the Laplace approximation

Formula: ppn ~ Week + (1 | Patient)

Data: skin

AIC BIC logLik deviance

301.7 309.6 -147.9 295.7

Random effects:

Groups Name Variance Std.Dev.

Patient (Intercept) 0.69306 0.8325

Number of obs: 100, groups: Patient, 20

Fixed effects:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	3.353428	0.189389	17.71	<2e-16	***
Week	-0.175595	0.006853	-25.62	<2e-16	***

EJEMPLO 3: MODELO LINEAL MIXTO POISSON

Evolución de acuerdo al modelo poblacional:

```
> fixef(mod)
(Intercept)      Week
  3.3534285   -0.1755953
```

$$\log(\lambda_{ij}) = 3.35 - 0.17Week_{ij}$$

$$\lambda_{ij} = 28.5e^{-0.17Week_{ij}}$$

Efectos aleatorios:

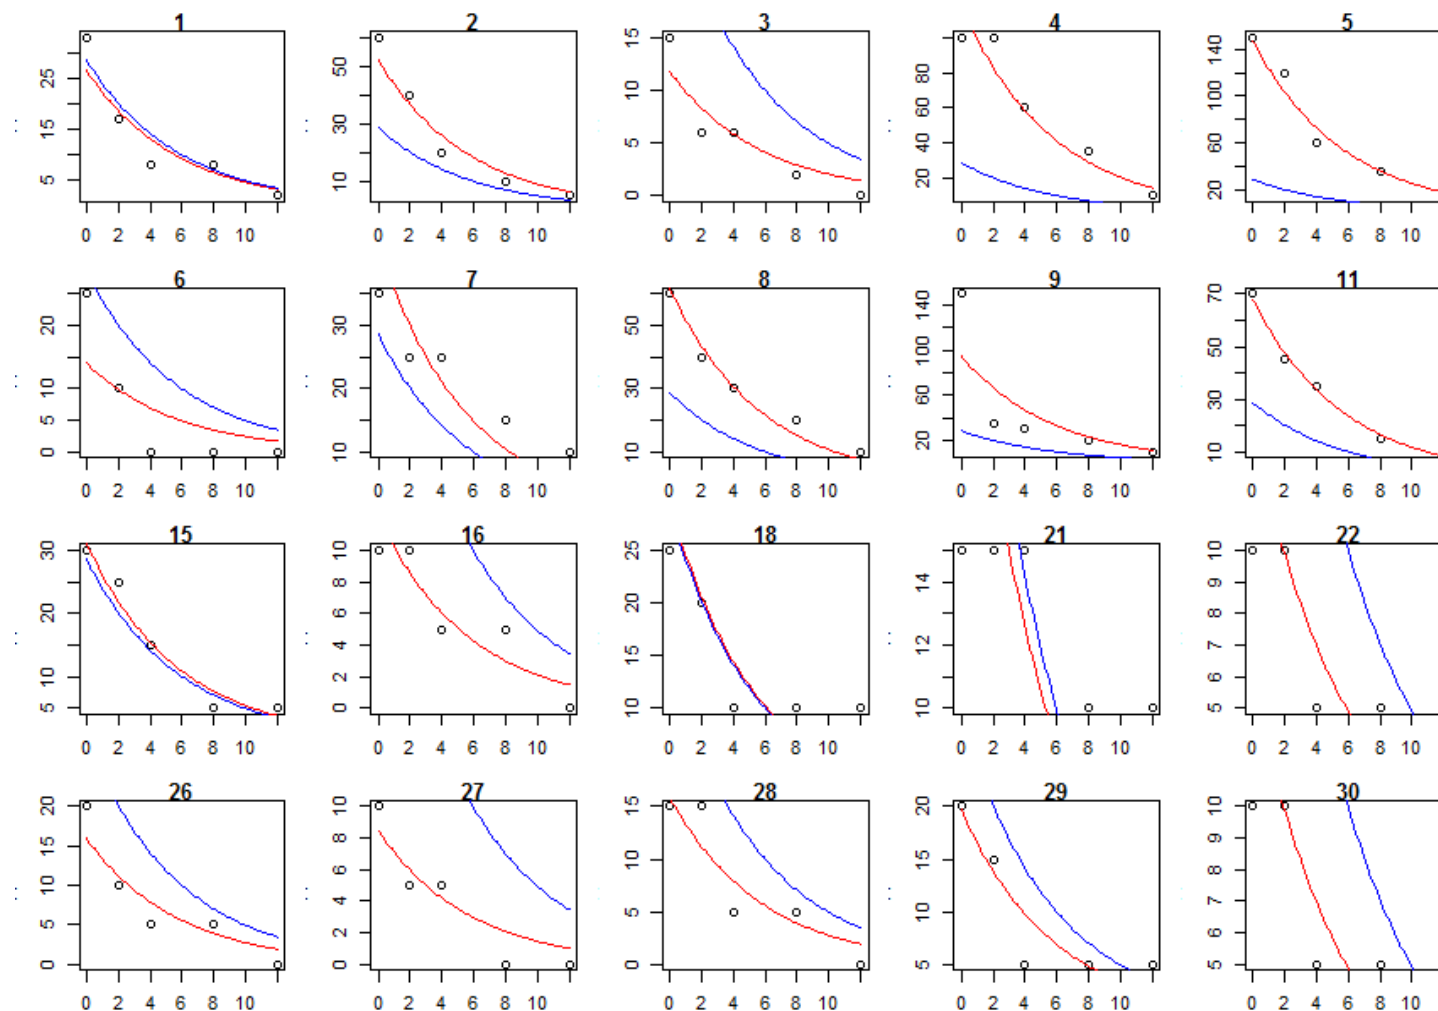
```
> ranef(mod)
```

\$Patient	7	0.39934878	22	-0.71161688
(Intercept)	8	0.77230527	26	-0.58607927
1	9	1.19829653	27	-1.21605294
2	11	0.86177572	28	-0.58607927
3	15	0.08461976	29	-0.37314591
4	16	-0.85441014	30	-0.71161688
5	18	0.02120066		
6	21	-0.11885728		

Modelo individual para el paciente 4:


$$\log(\lambda_{4j}) = (3.35 + 1.417) - 0.17Week_{4j} = 4.767 - 0.17Week_{ij}$$

EJEMPLO 3: MODELO LINEAL MIXTO POISSON



EJEMPLO 4: MODELO LINEAL MIXTO BINOMIAL

Se desea analizar los factores que determinan la supervivencia de lechones. Para ello se seleccionan 21 madres y para cada cría se registra el sexo, el peso al nacer y su temperatura. Además se desea caracterizar las madres en base a la capacidad de supervivencia de su progenie.



EJEMPLO 4: MODELO LINEAL MIXTO BINOMIAL

Para cuantificar la efectividad del tratamiento a lo largo del tiempo, podemos calcular el modelo lineal de Poisson poblacional y sus correspondientes modelos individuales:

Y_{ij} variable binaria (0=no sobrevive, 1=sí sobrevive)

Distribución de la respuesta: $Y_{ij} \sim \text{Bern}(\pi_{ij})$

Parte sistemática: $\text{logit}(\pi_{ij}) = (\beta_0 + b_i) + \beta_1 \text{Sex}_{ij} + \beta_2 \text{T0}_{ij} + \beta_3 \text{BW}_{ij}$

Parte aleatoria: $b_i \sim N(0, \sigma_b)$

```
> (mod<-glmer(Survival~Sex+T0+BW+(1|Sow1),lechones,family=binomial))
```

Generalized linear mixed model fit by the Laplace approximation

Formula: Survival ~ Sex + T0 + BW + (1 | Sow1)

Data: lechones

AIC BIC logLik deviance

120.2 136.7 -55.08 110.2

Random effects:

Groups Name Variance Std.Dev.

Sow1 (Intercept) 0.27861 0.52783

Number of obs: 201, groups: Sow1, 21

Fixed effects:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	1.4943374	19.2407750	0.078	0.938
Sex	-0.4673204	0.5521378	-0.846	0.397
T0	0.0240623	0.5198960	0.046	0.963
BW	0.0002858	0.0011247	0.254	0.799

EJEMPLO 4: MODELO LINEAL MIXTO BINOMIAL

No parece ser significativo ninguna característica recogida. Puede ser debido a la baja incidencia de defunciones que hace que el modelo sea altamente desbalanceado.

Caracterización de las madres (efectos aleatorios):

```
> ranef(mod)
$Sowl
      (Intercept)
54977  0.14320876
56026  0.22072625
56525  0.22497243
57186  0.02623120
57197 -0.30095563
      57215 -0.44747281
      58293 -0.25839649
      58482  0.12360346
      58504 -0.10307085
      58584 -0.12154502
      58641 -0.29435760
      58685 -0.46304800
      58712  0.16713390
      58757  0.18167053
      58797  0.14941353
      59915  0.10733159
      60073 -0.01759419
      60078 -0.06345183
      60169  0.06757838
      60261  0.22677368
      60266  0.10222279
```